

CHAPTER 2: DATA WRANGLING, MAKING SENSE OF DATA THROUGH VISUALIZATION, EXPLORATORY DATA ANALYSIS

(SẮP XẾP DỮ LIỆU, HIỂU DỮ LIỆU THÔNG QUA TRỰC QUAN HÓA, PHÂN TÍCH DỮ LIỆU THẨM DÒ)

Mục lục

2.0. Một số khái niệm và nội dung liên quan đến tiền xử lý dữ liệu	2
2.0.1. What is Data?	2
2.0.2. Types of Attributes	3
2.0.3. Thu thập dữ liệu	8
2.0.4. Chất lượng của dữ liệu.....	9
2.1. Data Preparation & Data Wrangling – Chuẩn bị & Tiền xử lý dữ liệu	10
2.1.1. What is Data Preparation?	11
2.1.2. Cleaning Data.....	13
2.1.2.1 Dữ liệu bị thiếu (Missing Data).....	13
2.1.2.1.1. Suy luận từ dữ liệu nội bộ để bổ sung vào dữ liệu bị thiếu (Imputation with Internal Data to Address Missing Data).....	14
2.1.2.1.2. Suy luận từ dữ liệu bên ngoài để bổ sung vào dữ liệu bị thiếu (Imputation with External Data and Other Methods to Address Missing Data)	14
2.1.2.1.3. Các lựa chọn xử lý khác.....	15
2.1.2.2. Các lưu ý khi xử lý dữ liệu bị thiếu.....	15
2.1.3. Dữ liệu bất thường (Anomalous Data)	15
2.1.4. Transforming Data	17
2.1.4.1. Biến đổi biến định lượng (Transforming Quantitative Variables).....	17
2.1.4.1.1. Tạo biến phân loại từ biến định lượng (Creating a Categorical Variable from a Quantitative Variable)	17
2.1.4.1.2. Thay đổi thang đo của biến định lượng (Changing the Scale of a Quantitative Variable)	18
2.1.4.1.3. Kết hợp các biến định lượng (Combining Quantitative Variables).....	18
2.1.4.2. Biến đổi biến phân loại (Transforming Categorical Variables).....	18
2.1.4.2.1. Tạo biến định lượng từ biến phân loại (Creating a Quantitative Variable from a Categorical Variable)	18
2.1.4.2.2. Cô đọng các danh mục - Condense the Categories of a Categorical Variable	19
2.1.4.2.3. Tách một biến thành nhiều biến (Splitting a Variable into Multiple Variables).....	20
2.1.4.3. Reshaping a Data Set (Định hình lại tập dữ liệu).....	20
2.1.5. Integrating Data/ Combining Datasets.....	21
2.1.5.1. Xếp chồng (Stacking Datasets).....	21
2.1.5.2. Mở rộng (Augmenting Datasets).....	22
2.1.5.3. Trộn/Hợp nhất (Merging Datasets)	23
2.1.6. Lưu ý khi gán giá trị “other”	24
2.2. Making Sense of Data Through Visualization - Hiểu dữ liệu thông qua sự trực quan hóa .24	24
2.2.1. Trực quan hóa với một biến định lượng (Visualizations with One Quantitative Variable)	24
2.2.1.1. Biểu đồ tần suất (Histograms)	24
2.2.1.2. Biểu đồ mật độ (Density Plots).....	26

2.2.1.3. Biểu đồ hộp (Box Plots)	27
2.2.1.4. Biểu đồ Violin (Violin Plots)	29
2.2.2. Trực quan hóa với một biến phân loại - Visualization with One Categorical Variable	30
2.2.3. Trực quan hóa với hai biến (Visualizations with Two Variables)	32
2.2.4. Trực quan hóa với ba hoặc nhiều biến (Visualizations with Three or More Variables)	36
2.2.5. Big Picture Break: Visualizing Data	38
2.3. Exploratory Data Analysis - Phân tích dữ liệu khám phá	38
2.3.1. Đo lường xu hướng tập trung (Central Tendency)	38
2.3.2. Đo lường sự biến thiên của dữ liệu (Variability)	42
2.3.3. Mối liên kết dữ liệu (Data Associations)	43
2.3.3.1. Data Associations	43
2.3.3.2. Phân vị (Percentiles)	47
2.3.3.3. Khoảng tứ phân vị (Interquartile Range - IQR)	48
2.3.4. Xác định các giá trị ngoại lệ (Identifying Outliers)	49
2.3.4.1. Phương pháp Tứ phân vị và phương pháp Trung bình/Độ lệch chuẩn (Outliers: The Quartile and Mean/SD Method)	49
2.3.4.2. Lựa chọn phương pháp tốt nhất (Choosing the Best Method for Detecting Outliers)	50
2.3.4.3. Ethics in Practice: Simpson's Paradox (Nghịch lý Simpson)	51
2.4. Normalization – Chuẩn hóa dữ liệu	52

2.0. Một số khái niệm và nội dung liên quan đến tiền xử lý dữ liệu

2.0.1. What is Data?

Structured – relational (table-like)

	A	B	C	D	E	F	G
1	Country	Region	Population	Under15	Over60	Fertil	LifeExp
2	Zimbabwe	Africa	13724	40.24	5.68	3.64	54
3	Zambia	Africa	14075	46.73	3.95	5.77	55
4	Yemen	Eastern M	23852	40.72	4.54	4.35	64
5	Viet Nam	Western P	90796	22.87	9.32	1.79	75
6	Venezuela (Bo	Americas	29955	28.84	9.17	2.44	75
7	Vanuatu	Western P	247	37.37	6.02	3.46	72
8	Uzbekistan	Europe	28541	28.9	6.38	2.38	68
9	Uruguay	Americas	3395	22.05	18.59	2.07	77

Un-structured

```
{
  "code": "1473a6fd39d1d8fa48654aac9d8cc2754232",
  "title": "[Updating] Câu chuyện xuyên mưa về :",
  "url": "http://techtalk.vn/updating-cau-chuyen",
  "labels": "techtalk/Cong nghe",
  "content": "Vào chiều tối ngày 09/12/2016 vừa",
  "image_url": "",
  "date": "2016-12-10T03:51:10Z"
}
```


texts in websites, emails, articles, tweets



2D/3D images, videos + meta



spectrograms, DNAs, ...



- Collection of data objects and their attributes
- An **attribute** is a *property* or *characteristic of an object*; also known as *variable*, *field*, or *feature*
 - Đôi khi nó còn được gọi là *observation*.
 - Examples: name, date of birth, height, occupation.
- For each object the attributes take some values.
- The collection of attribute-value pairs describes a specific **object**
 - Một (data) object đại diện cho một thực thể (entity).
 - Object** is also known as *record*, *point*, *case*, *sample*, *entity*, or *instance*


Attributes

<i>Tid</i>	<i>Refund</i>	<i>Marital Status</i>	<i>Taxable Income</i>	<i>Cheat</i>
1	Yes	Single	125K	No
2	No	Married	100K	No
3	No	Single	70K	No
4	Yes	Married	120K	No
5	No	Divorced	95K	Yes
6	No	Married	60K	No
7	Yes	Divorced	220K	No
8	No	Single	85K	Yes
9	No	Married	75K	No
10	No	Single	90K	Yes

Objects

- Size** (n): Number of objects
- Dimensionality** (d): Number of attributes
- Sparsity (mức độ thưa thớt)**: được đo bằng tỷ lệ số lượng cặp object-attribute có giá trị (được điền) so với tổng số cặp object-attribute có thể có. Nếu số lượng cặp populated ít so với tổng số, dữ liệu được coi là sparse (thưa thớt).
 - Ví dụ: Trong một bảng dữ liệu có 100 đối tượng và 50 thuộc tính, tổng số cặp có thể là $100 \times 50 = 5000$. Nếu chỉ 200 cặp được điền, sparsity là $200/5000 = 0.04(4\%)$, nghĩa là dữ liệu rất thưa thớt.

2.0.2. Types of Attributes



- Chia thành hai loại lớn: **Qualitative (định tính)** và **Quantitative (định lượng)**.
 - Qualitative**: Thuộc tính về định nghĩa, phân loại, dạng thức, kết cấu, cảm nhận, biểu hiện, *không đo đạc bằng giá trị số*.
 - Quantitative**: Thuộc tính giá trị số thu thập qua đo đạc, tính toán, tổng hợp.

- **Phân loại thuộc tính định tính (Qualitative):** Chia thành 3 loại: **nominal**, **ordinal**, và **binary**.
 - **Nominal:**
 - Giá trị là **ký hiệu hoặc tên đối tượng**, đại diện cho *danh mục, mã hoặc trạng thái*.
 - Không có ý nghĩa thứ tự/xếp hạng → không tính được trung bình (mean) hoặc trung vị (median).
 - Quan tâm đến **mốt (mode)** để thể hiện xu hướng tập trung.
 - Ví dụ: Màu tóc, Tình trạng hôn nhân, Mã khách hàng.
 - **Ordinal:**
 - Giá trị có thứ tự hoặc xếp hạng, nhưng **không xác định được độ lớn giữa các giá trị liên tiếp**.
 - Có thể tạo ra bằng cách chia giá trị số thành các khoảng và đặt tên.
 - Tính được **mốt và trung vị** để xác định xu hướng tập trung của dữ liệu, tuy nhiên không tính được trung bình.
 - Ví dụ: Education level (Primary, Secondary, Tertiary).
 Kích thước = {nhỏ, trung bình, lớn}
 Điểm = {A, B, C, D, E, F},
 - **Binary:**
 - Thuộc tính **nominal** với 2 giá trị hoặc trạng thái: **0 (có) hoặc 1 (không có)**.
 - Có thể dùng kiểu Boolean (true/false).
 - Ví dụ: Kiểm tra y tế (1: dương tính, 0: âm tính).
 - Chia thành 2 loại nhỏ:
 - **Symmetric:** Hai trạng thái có giá trị và sức nặng ngang nhau, ví dụ: Giới tính.
 - **Asymmetric:** Hai trạng thái có độ quan trọng không bằng nhau, ví dụ: Kết quả xét nghiệm Corona (dương tính, âm tính).
 - **Quy ước (Convention):** gán 1 cho kết quả quan trọng hơn. VD: dương tính với HIV
 - **Trong một số ngữ cảnh, nó có thể mang kiểu numeric (kiểu số)**
 - **Categorical Variable là một tập hợp con của Qualitative Variable**, tập trung vào các biến có giá trị thuộc các danh mục riêng biệt, không có ý nghĩa toán học về thứ tự hoặc khoảng cách.
 - Categorical Variable có thể chia thành: Nominal Variable & Ordinal Variable
- **Phân loại thuộc tính định lượng (Quantitative/Numeric) (xem thêm 2.1.4.1.1):**
 - Cũng gọi là thuộc tính dạng số, biểu diễn đại lượng đo được (số nguyên hoặc số thực).
 - Chia thành 2 loại: **interval-scaled** và **ratio-scaled**.
 - **Interval-scaled (Thuộc tính tỷ lệ khoảng thời gian)**
 - Giá trị đo trên thang đơn vị có kích thước bằng nhau, có thể **dương, 0 hoặc âm**.
 - Có thứ tự, so sánh và định lượng sự khác biệt được.
 - **Không có giá trị 0 thật sự** (ví dụ: Nhiệt độ °C/°F, Ngày trong tháng).
 - Không nhân/chia để tạo ý nghĩa (30°C không gấp đôi 15°C), nhưng có thể trừ hoặc cộng.
 - Tính được **mốt, trung vị, và trung bình**.
 - Ví dụ: Ngày, Nhiệt độ.

- **Ratio-scaled (Thuộc tính tỷ lệ):**
 - Có giá trị 0 thật sự, có thể nhân/chia để tạo ý nghĩa.
 - Có thứ tự, tính được độ chênh lệch, một, trung vị, và trung bình.
 - Ví dụ: Số tiền, Số năm kinh nghiệm, Số từ trong văn bản, độ dài...

- **Dữ liệu quan hệ số (Numeric Relational Data):**

- Data where all attributes are **numerical** (either discrete or continuous).
- Nếu **các đối tượng** dữ liệu có cùng tập hợp thuộc tính số cố định (**có cùng số lượng thuộc tính số**), chúng có thể được xem như **các điểm hoặc các vector** trong không gian đa chiều (mỗi chiều là một thuộc tính).
- Biểu diễn bằng ma trận dữ liệu $n \times d$: n hàng (mỗi hàng là một đối tượng), d cột (mỗi cột là một thuộc tính). Ma trận này chứa các giá trị số.
- **Ví dụ:** Giả sử chúng ta có 4 người, mỗi người được mô tả bằng 3 thuộc tính số: Chiều cao (cm), Cân nặng (kg), và Tuổi. Dữ liệu được biểu diễn như sau:

Người	Chiều cao (cm)	Cân nặng (kg)	Tuổi
Người 1	170	70	25
Người 2	165	65	30
Người 3	180	75	22
Người 4	175	68	28

- **Số đối tượng (n):** 4 (4 hàng).
- **Số thuộc tính (d):** 3 (3 cột: Chiều cao, Cân nặng, Tuổi).
- **Ma trận dữ liệu 4×3 :** $\begin{bmatrix} 170 & 70 & 25 \\ 165 & 65 & 30 \\ 180 & 75 & 22 \\ 175 & 68 & 28 \end{bmatrix}$
- Mỗi hàng là một vector đại diện cho một người (ví dụ: Người 1 là vector $[170, 70, 25]$).
- Mỗi cột là một thuộc tính (chiều) trong không gian 3D.
- **Ưu điểm:**
 - Dễ hình dung như điểm/vector, đặc biệt với số chiều nhỏ (có thể vẽ biểu đồ).
 - Sử dụng khái niệm hình học (geometric analogues) như khoảng cách hoặc độ tương đồng (similarity).
 - Áp dụng đại số tuyến tính để xử lý ma trận dữ liệu.

- **Categorical Relational Data (Dữ liệu quan hệ phân loại)**

- Dữ liệu gồm các bản ghi, mỗi bản ghi có tập hợp cố định các **thuộc tính phân loại**.
- Data where all attributes are categorical (nominal or ordinal).

ID	Color	Gender	Education Level
1	Red	Male	Bachelor
2	Blue	Female	Master

- **Mixed Relational Data (Dữ liệu quan hệ hỗn hợp)**

- Dữ liệu gồm các bản ghi, mỗi bản ghi có tập hợp cố định cả thuộc tính số và phân loại.
- **Về thuộc tính Boolean:**
 - Có thể xem là số (0/1) hoặc phân loại tùy ngữ cảnh.
 - Khi kết hợp với các thuộc tính khác, thường được xử lý như phân loại.

ID Number	Zip Code	Age	Marital Status	Income	Income Bracket	Refund
1129842	45221	55	Single	250000	High	No
2342345	45223	25	Married	30000	Low	Yes
1234542	45221	45	Divorced	200000	High	No
1243535	45224	43	Single	150000	Medium	No


ID Number	Zip Code	Age	Marital Status	Income	Income Bracket	Refund
1129842	45221	55	Single	250000	High	0
2342345	45223	25	Married	30000	Low	1
1234542	45221	45	Divorced	200000	High	0
1243535	45224	43	Single	150000	Medium	0

- Có thể chuyển đổi thuộc tính phân loại thành Boolean, giúp xem toàn bộ vectơ như dữ liệu số.

ID	Zip 45221	Zip 45223	Zip 45224	Age	Single	Married	Divorced	Income	Refund
1129842	1	0	0	55	0	0	0	250000	0
2342345	0	1	0	25	0	1	0	30000	1
1234542	1	0	0	45	0	0	1	200000	0
1243535	0	0	1	43	0	0	0	150000	0

- **Graph Data**

• a collection of entities and their pairwise relationships. Examples: ○ Web pages and hyperlinks ○ Facebook users and friendships ○ The connections between brain neurons • Representation: ○ a/ Adjacency matrix: Very sparse, very wasteful, but useful conceptually ○ b/ Adjacency list: Not so easy to maintain ○ c/ List of pairs: The simplest and most efficient representation	a/ $A = \begin{bmatrix} 0 & 1 & 1 & 0 & 0 \\ 1 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 & 0 \end{bmatrix}$ b/ 1: [2, 3] 2: [1, 3] 3: [1, 2, 4] 4: [3, 5] 5: [4]
---	--



- **Dataset/ Set data**

- A set of records, data objects
- Each record is a set of items from a space of possible items
- **Document data**
 - Also called bag-of-words representation
 - Document data can be represented, or thought of, as numeric vector data
 - The vector is defined over the set of **all possible words**
 - The **values** are the **counts** (number of times a word appears in the document)

Doc Id	Words
1	the, dog, follows, the, cat
2	the, cat, chases, the, cat
3	the, man, walks, the, dog

Doc Id	the	dog	follows	cat	chases	man	walks
1	2	1	1	1	0	0	0
2	2	0	0	2	1	0	0
3	1	1	0	0	0	1	1

- **Transaction data**

- Also called market-basket data
- Market-basket data can be represented, or thought of, as numeric vector data
 - The vector is defined over the set of all possible items
 - The **values** are **binary** (the item appears or not in the set)

TID	Items
1	Bread, Coke, Milk
2	Beer, Bread
3	Beer, Coke, Diaper, Milk
4	Beer, Bread, Diaper, Milk
5	Coke, Diaper, Milk

TID	Bread	Coke	Milk	Beer	Diaper
1	1	1	1	0	0
2	1	0	0	1	0
3	0	1	1	1	1
4	1	0	1	1	1
5	0	1	1	0	1

2.0.3. Thu thập dữ liệu

Input
Vấn đề cần giải quyết



Output
Mẫu dữ liệu

	A	B	C	D	E	F	G
1	Country	Region	Population	Under15	Over60	Fertil	LifeExp
2	Zimbabwe	Africa	13724	40.24	5.68	3.64	54
3	Zambia	Africa	14075	46.73	3.95	5.77	55
4	Yemen	Eastern M	23852	40.72	4.54	4.35	64
5	Viet Nam	Western F	90796	22.87	9.32	1.79	75
6	Venezuela (Bo	Americas	29955	28.84	9.17	2.44	75
7	Vanuatu	Western F	247				
8	Uzbekistan	Europe					
9	Uruguay	Americas					

- **Sampling (Lấy mẫu)**

- Sampling là kỹ thuật chính để chọn dữ liệu
- It is often used for both the **preliminary investigation** of the data and **the final data analysis**.
- **Lý do sử dụng:**
 - Đối với thống kê: Thu thập toàn bộ dữ liệu quá tốn kém hoặc mất thời gian. Ví dụ: Không thể đo chiều cao của tất cả người dân Hy Lạp để tính chiều cao trung bình.
 - Trong khai thác dữ liệu (data mining): Xử lý toàn bộ dữ liệu quá tốn kém hoặc phức tạp.
 - **Ví dụ 1:** Với 1 triệu tài liệu, tính số từ chung của tất cả cặp tài liệu (10^{12} so sánh) là không khả thi.
 - **Ví dụ 2:** Với 500 triệu tweet mỗi ngày (trung bình 100 ký tự), lưu trữ toàn bộ cần 86.5TB, khó phân tích trực tiếp.

- **Nguyên tắc lấy mẫu (Sampling):**

- WHAT: Lấy tập mẫu phổ biến, đại diện cho lĩnh vực cần học, khai thác.
- WHY: Không thể học, khai thác toàn bộ. Giới hạn về thời gian và khả năng tính toán.
- HOW: Thu thập các mẫu từ thực tế, hoặc từ các nguồn chứa dữ liệu (web, database, ...)

- **Lấy mẫu như thế nào?**

- **Variety:** Tập thu được đủ đa dạng để **phủ hết các ngữ cảnh, đặc trưng** của lĩnh vực → Dữ liệu đa dạng, cân bằng để phản ánh khách quan.
- **Bias (Thiên lệch):** Dữ liệu cần **tổng quát, cân bằng, không bị sai lệch, thiên vị** về 1 bộ phận nhỏ nào đó của lĩnh vực.
 - **Ví dụ về thiên lệch:** Lấy mẫu từ khuôn viên đại học để tính chiều cao trung bình của người ở Ioannina (Hy Lạp) có thể sai lệch, vì sinh viên thường trẻ hơn và có chiều cao khác so với dân số chung.

- **Các loại Sampling**

- **Simple Random Sampling (Lấy mẫu ngẫu nhiên đơn giản):** Mọi mục trong tập dữ liệu có xác suất chọn bằng nhau.
- **Sampling without Replacement (Lấy mẫu không hoàn lại):** Sau khi chọn một mục, nó bị loại khỏi tập dữ liệu → Giảm xác suất chọn lại, phản ánh thực tế hơn.
- **Sampling with Replacement (Lấy mẫu có hoàn lại):** Mục được chọn không bị loại, có thể chọn lại nhiều lần → Dễ tính toán xác suất hơn.

- **Stratified Sampling (Lấy mẫu phân tầng):** Chia dữ liệu thành các nhóm, sau đó lấy mẫu ngẫu nhiên từ mỗi nhóm → Đảm bảo tất cả nhóm được đại diện.
 - **Ví dụ:** Phân tích giao dịch thẻ tín dụng (0.1% là gian lận). Lấy 1000 giao dịch ngẫu nhiên chỉ cho ~1 giao dịch gian lận, không đủ để kết luận. Giải pháp: Lấy 1000 giao dịch hợp lệ và 1000 giao dịch gian lận.
- **Các kỹ thuật thu thập dữ liệu:**
 - **Crow-sourcing:** Survey – các khảo sát.
 - **Logging:** Lưu lại lịch sử tương tác, truy cập của người dùng, ...
 - **Scrapping:** Lưu lại dữ liệu từ các website
 - **Ví dụ**
 - Mục tiêu: Dữ liệu cho bài toán phân lớp văn bản (dữ liệu báo chí).
 - Hướng giải quyết: Hệ thống thu thập (crawl) dữ liệu báo


Input

Vấn đề: phân lớp văn bản báo chí



Output

Mẫu dữ liệu: Bài báo và nhãn tương ứng



2.0.4. Chất lượng của dữ liệu

- **Các yếu tố đánh giá:**
 - **Tính chính xác (Accuracy):**
 - Có các giá trị không chính xác
 - Có thể là lỗi của con người hoặc máy tính
 - **Tính đầy đủ, toàn vẹn (Completeness):**
 - Dữ liệu không đầy đủ có thể xảy ra
 - VD: thông tin khách hàng cho dữ liệu bán hàng & giao dịch có thể không phải lúc nào cũng có sẵn.
 - **Tính nhất quán (Consistency):**
 - Có thể do quy ước đặt tên, đặt mã, định dạng không nhất quán
 - Các bộ dữ liệu trùng lặp.
 - **Tính kịp thời (Currency/ Timeliness):** Dữ liệu được cập nhật đầy đủ và kịp thời?
 - **Độ tin cậy (Believability):** Mức độ người dùng tin tưởng vào dữ liệu
 - **Khả năng diễn giải (Interpretability):** Mức độ dễ hiểu của người dùng đối với dữ liệu.
- **Trên thực tế, dữ liệu có chất lượng không tốt**
 - **Dữ liệu thiếu, không đầy đủ:** Thiếu giá trị của thuộc tính, thiếu các thuộc tính quan tâm hoặc chỉ chứa dữ liệu tích hợp. VD: Tuổi, cân nặng = "".
 - **Dữ liệu bị tạp, nhiễu (noise):** lỗi hoặc sai. VD: Lương = -100.000
 - **Dữ liệu mâu thuẫn, không thống nhất.** VD: Tuổi = 23, Ngày sinh 01/01/2023; US = USA?; Rating "1, 2, 3" "A, B, C"

- **Examples of data quality problems:**

- Noise and outliers
- Missing values
- Duplicate data

A mistake or a millionaire?

Missing values

Inconsistent duplicate entries

Tid	Refund	Marital Status	Taxable Income	Cheat
1	Yes	Single	125K	No
2	No	Married	100K	No
3	No	Single	70K	No
4	Yes	Married	120K	No
5	No	Divorced	10000K	Yes
6	No	NULL	60K	No
7	Yes	Divorced	220K	NULL
8	No	Single	85K	Yes
9	No	Married	90K	No
9	No	Single	90K	No

2.1. Data Preparation & Data Wrangling – Chuẩn bị & Tiền xử lý dữ liệu

- **Tiền xử lý dữ liệu**

- Giúp ích trong việc lưu trữ, truy vấn
- Các mô hình học máy thường làm việc với dữ liệu có cấu trúc: ma trận, vector, chuỗi, ...
- Học máy thường làm việc hiệu quả nếu biểu diễn dữ liệu phù hợp

Input
Mẫu dữ liệu thô (text, image, audio,...)

	A	B	C	D	E	F	G
1	Country	Region	Population	Under15	Over60	Fertil	LifeExp
2	Zimbabwe	Africa	13724	40.24	5.68	3.64	54
3	Zambia	Africa	14075	46.73	3.95	5.77	55
4	Yemen	Eastern M	23852	40.72	4.54	4.35	64
5	Viet Nam	Western P	90796	22.87	9.32	1.79	75
6	Venezuela (Bo	Americas	29955	28.84	9.17	2.44	75
7	Vanuatu	Western P	247				
8	Uzbekistan	Europe					
9	Uruguay	Americas					

Output
Dữ liệu số theo từng model (AI/ ML)

$$x^{(n)} = \begin{bmatrix} -0.0920 \\ 3.4931 \\ -1.8493 \\ \dots \\ -0.2010 \\ -1.3079 \end{bmatrix} \quad D = \begin{bmatrix} x^{(1)} \\ x^{(2)} \\ \dots \\ x^{(n)} \end{bmatrix}$$

- **Cần lưu ý**

Completeness
(Đầy đủ)

Từng mẫu thu thập nên đầy đủ thông tin các trường thuộc tính cần thiết

Integrity
(Trung thực)

Nguồn thu thập chính thống, đảm bảo mẫu thu được chứa giá trị chính xác trên thực tế.

Homogeneity
(Đồng nhất)

Thu thập dữ liệu từ nhiều nguồn

Rating "1,2,3" & "A,B,C"
Age = "23" & Birthday = "01/01/2023"

Structures
(Cấu trúc)

	C	D	E	F	G
Population	Under15	Over60	Fertil	LifeExp	
13724	40.24	5.68	3.64	54	
14075	46.73	3.95	5.77	55	
23852	40.72	4.54	4.35	64	
90796	22.87	9.32	1.79	75	
29955	28.84	9.17	2.44	75	
247	37.37	6.02	3.46	72	
26541	28.9	6.38	2.38	68	
3395	22.05	18.59	2.07	77	

2.1.1. What is Data Preparation?

- **Định nghĩa:** Chuẩn bị dữ liệu là quá trình **thu thập**, **chuyển đổi** và **lưu trữ** một tập dữ liệu dưới dạng hữu ích cho việc phân tích.
- **Gồm 3 bước:**
 - **Data collection (Thu thập dữ liệu):** **thu thập** dữ liệu liên quan **từ nhiều nguồn** khác nhau.
 - **Data sources (Nguồn dữ liệu):** Website, Khảo sát, Nhật ký thí nghiệm khoa học hoặc nghiên cứu thực địa.
 - Ví dụ: Ghi lại âm thanh và hành vi của chim trong tự nhiên.
 - **Data collection methods (Phương pháp thu thập dữ liệu):** Nghiên cứu quan sát, Thí nghiệm.
 - Ví dụ: Quan sát chim trong tự nhiên là một nghiên cứu quan sát.

- **Data wrangling/munging (Xử lý/Sắp xếp dữ liệu):** chuyển đổi dữ liệu thô sang một **định dạng dễ sử dụng hơn**, bằng cách làm sạch (cleaning), biến đổi (transforming) và tích hợp (integrating) dữ liệu để tạo điều kiện cho việc phân tích và trình bày hiệu quả.


Data wrangling is the process of cleaning data (converting from messy to tidy data), transforming it (making it ready for analysis), and integrating it (connecting it with more than one data source).

- **Data Cleaning (Làm sạch dữ liệu)**
 - **Sửa chữa hoặc loại bỏ** dữ liệu *không đầy đủ, bất thường hoặc không nhất quán*.
 - **Lưu ý quan trọng:** Thông báo bất kỳ điều chỉnh nào được thực hiện đối với dữ liệu **trong quá trình làm sạch!**
 - Việc ghi lại mọi thay đổi là cực kỳ quan trọng để đảm bảo tính minh bạch và khả năng tái lập của quá trình phân tích.
 - **Các vấn đề cần xử lý khi làm sạch dữ liệu:**
 - *Missing data (Dữ liệu bị thiếu)*
 - *Implausible or extreme values (Các giá trị vô lý hoặc cực đoan)*
 - *Incorrectly formatted values (Các giá trị sai định dạng)*
 - *Duplicate records (Các bản ghi trùng lặp)*

dog		dog	Mặc dù "Dog" và "dog" có cùng ý nghĩa với con người, nhưng máy tính sẽ hiểu chúng là hai giá trị hoàn toàn khác nhau . Việc làm sạch ở đây là chuẩn hóa chúng về một định dạng duy nhất .
Dog		dog	
cat		cat	
Cat		cat	

- **Data Transformation (Biến đổi dữ liệu):**
 - Sau khi làm sạch, dữ liệu có thể cần được biến đổi. Điều này có thể là việc trích xuất thông tin từ văn bản để *tạo các cột mới, hoặc thay đổi định dạng của các cột hiện có* (ví dụ: chuyển đổi ngày tháng, nhóm các giá trị lại với nhau).
 - Data transformation is the process used **to convert a clean dataset into the form or structure** needed for analysis and visualization.

- **Tổ chức và định dạng** dữ liệu để phân tích hiệu quả, bao gồm
 - Cấu trúc hóa dữ liệu phi cấu trúc trước đó.
 - Cấu trúc hóa thêm một tập dữ liệu đã có cấu trúc.
- **Data Integration (Tích hợp dữ liệu)**
 - **Kết hợp hai hoặc nhiều bộ dữ liệu** để cung cấp thêm thông tin chi tiết.
 - To maximize the amount of information from which to draw insight.
 - **Lưu ý:** "Khi dữ liệu dễ dàng có được từ một nguồn công khai, lợi thế cạnh tranh của thông tin đó là thấp."
 - Giá trị thực sự thường đến từ việc kết hợp các bộ dữ liệu độc đáo mà không phải ai cũng có.
 - **Các phương pháp tích hợp dữ liệu:**
 - *Stacking data sets* (Chồng/Xếp chồng các tập dữ liệu)
 - *Augmenting a data set* (Mở rộng một tập dữ liệu)
 - *Merging data sets* (Trộn/Hợp nhất các tập dữ liệu)



- **Data management (Quản lý dữ liệu):** lưu trữ dữ liệu để sẵn sàng cho việc phân tích.
 - Sau khi đã được thu thập và xử lý, dữ liệu cần được lưu trữ ở một nơi an toàn, có tổ chức và dễ dàng truy cập để các nhà phân tích có thể sử dụng.

• Dataframes

- A dataframe is a tabular data structure with named columns.
- A tabular dataset that can be stored, viewed, and processed with a variety of software tools.
- We can complete many tasks—that is, instruct the computer to fulfill complex or calculation-heavy functions—with these tools. For example, we can clean structured data

by opening it in a spreadsheet tool and use the spreadsheet's built-in functions to recognize and address issues.

- We **clean, transform, and integrate data** through the structure of a **dataframe**.

2.1.2. Cleaning Data

- **Tầm quan trọng của việc làm sạch dữ liệu**

- Làm sạch dữ liệu đảm bảo tính chính xác và độ tin cậy của dữ liệu cho việc phân tích.
- Ngăn chặn các lỗi và sai lệch có thể dẫn đến kết luận không chính xác.
- Phân tích trên dữ liệu "bẩn" sẽ cho ra kết quả "bẩn" (Garbage In, Garbage Out).

- **Làm sạch dữ liệu với các hàm trong Bảng tính**

- Sử dụng các hàm trong công cụ phần mềm để tinh giản quy trình làm sạch.
- Sắp xếp dữ liệu giúp tổ chức thông tin theo một thứ tự cụ thể để phân tích tốt hơn.
- Lọc dữ liệu giúp tập trung vào các tiêu chí cụ thể hoặc loại bỏ các mục dữ liệu không mong muốn.
- Các công cụ và kỹ thuật cơ bản (thường có trong Excel hoặc Google Sheets) để thực hiện việc làm sạch dữ liệu như **sắp xếp (sort)** và **lọc (filter)**.

2.1.2.1 Dữ liệu bị thiếu (Missing Data)

- **Định nghĩa:** các giá trị trong tập dữ liệu bị thiếu (**absent**) nhưng được cho là/mong đợi phải tồn tại.
- **Nguyên nhân:** lỗi nhập liệu, trục trặc thiết bị, người tham gia không trả lời, v.v.
- **Hậu quả:** có thể dẫn đến kết quả sai lệch và kết luận thống kê không chính xác (biased results and inaccurate statistical conclusions).
- **Ví dụ:** Một bảng dữ liệu có các ô trống ở cột "tuổi" và "thú cưng yêu thích".

first_name	age	gpa	favorite_pet	voted
Selma	18	3.1	Dog	0
Juan		3.2	Cat	1
Rozzlin	19	3.9		0

- **Các cách xử lý dữ liệu bị thiếu - Addressing Missing Data**

- **Remove Observations:** **Xóa** các hàng có dữ liệu bị thiếu.
- **Impute with Internal Data (Suy luận bằng dữ liệu nội bộ):** **Điền** vào các giá trị bị thiếu dựa trên dữ liệu có sẵn trong tập dữ liệu.
- **Impute with External Data (Suy luận bằng dữ liệu bên ngoài):** Sử dụng các **nguồn hoặc tập dữ liệu bên ngoài** để **điền** vào các giá trị bị thiếu.
- **Other Options (Các lựa chọn khác):** Suy luận bằng giá trị trung bình (Mean imputation), suy luận hồi quy (regression imputation), học máy (machine learning).

2.1.2.1.1. Suy luận từ dữ liệu nội bộ để bổ sung vào dữ liệu bị thiếu (Imputation with Internal Data to Address Missing Data)

- **Định nghĩa:** Thay thế các giá trị bị thiếu bằng các ước tính được suy ra từ các điểm dữ liệu tương đương (comparable).
- **Phương pháp:** Sử dụng giá trị trung bình (mean), trung vị (median), hoặc các kỹ thuật nâng cao.
- Sử dụng dữ liệu trong tập dữ liệu để ước tính các giá trị bị thiếu.
- **Ví dụ chi tiết:**
 - Một bảng dữ liệu về các cổ vật với một số giá trị "tuổi" (age) bị thiếu.

object_id	type	material	depth	age	object_id	type	material	depth	age
O1	Pottery	Clay	1	2000	O1	Pottery	Clay	1	2000
O2	Jewelry	Gold	2		O2	Jewelry	Gold	2	2185.72
O3	Tool	Bronze	1.5	3000	O3	Tool	Bronze	1.5	3000
O4	Weapon	Iron	3.5	1500	O4	Weapon	Iron	3.5	1500
O5	Coin	Silver	1.5		O5	Coin	Silver	1.5	2185.72
O6	Pottery	Clay	2.5	2500	O6	Pottery	Clay	2.5	2500
O7	Jewelry	Gold	1		O7	Jewelry	Gold	1	2185.72
O8	Weapon	Bronze	3	2000	O8	Weapon	Bronze	3	2000
O9	Tool	Iron	4		O9	Tool	Iron	4	2185.72
O10	Coin	Silver	1.2	1900	O10	Coin	Silver	1.2	1900
O11	Jewelry	Gold	2.7		O11	Jewelry	Gold	2.7	2185.72
O12	Pottery	Clay	2.2	2400	O12	Pottery	Clay	2.2	2400

- **Phương pháp 1 (Xóa bỏ):** Bỏ qua các hàng bị thiếu và tính tuổi trung bình của các hàng còn lại. (Kết quả: 2185.72)

$$(2000 + 3000 + 1500 + 2500 + 2000 + 1900 + 2400) / 7 = 2185.72$$
- **Phương pháp 2 (Suy luận):** Điền giá trị trung bình (2185.72) vào các ô bị thiếu. Sau đó tính lại giá trị trung bình của toàn bộ cột (kết quả vẫn là 2185.72).

$$(2000 + 2185.72 + 3000 + 1500 + 2185.72 + 2500 + 2185.72 + 2000 + 2185.72 + 1900 + 2185.72 + 2400) / 12 = 2185.72$$

2.1.2.1.2. Suy luận từ dữ liệu bên ngoài để bổ sung vào dữ liệu bị thiếu (Imputation with External Data and Other Methods to Address Missing Data)

- Sử dụng các giá trị từ một tập dữ liệu khác.
- Thay thế trực tiếp các giá trị bị thiếu cho cùng một cá nhân từ một tập dữ liệu khác.
- Yêu cầu sự tin tưởng vào độ tin cậy và sự liên quan của các nguồn dữ liệu bổ sung.

- Ví dụ, nếu bạn có dữ liệu khách hàng bị thiếu ngày sinh, bạn có thể tìm thông tin đó trong một hệ thống quản lý khách hàng khác. Tuy nhiên, bạn phải chắc chắn rằng nguồn dữ liệu bên ngoài là chính xác và đáng tin cậy.
- Yêu cầu **báo cáo các quyết định được đưa ra** trong quá trình suy luận.

2.1.2.1.3. Các lựa chọn xử lý khác

- Thay thế các giá trị bị thiếu bằng các **mã định danh duy nhất** (unique identifiers).
 - For example, missing values for quantitative variables could be filled with “NA” (which is often a special value in software that uniquely denotes a missing value), or with a completely nonsensical (vô nghĩa) value like -999.
 - For categorical variables, missing values could literally be replaced with a value of “Missing” or “Unknown”.
- Thực hiện các phân tích riêng biệt **không bao gồm dữ liệu bị thiếu**.
- Sử dụng các kỹ thuật **suy luận bội** (multiple imputation) dựa trên các mẫu dữ liệu quan sát được. Nó tạo ra nhiều phiên bản của tập dữ liệu đã được điền đầy đủ và kết hợp các kết quả phân tích từ chúng.

2.1.2.2. Các lưu ý khi xử lý dữ liệu bị thiếu

- **Randomness in Data (Tính ngẫu nhiên trong dữ liệu):** Dữ liệu bị thiếu có ngẫu nhiên không hay theo một quy luật nào đó?
- **Documentation for Transparency (Ghi chép để minh bạch):** Luôn ghi lại cách bạn xử lý dữ liệu.
- **Data Integrity (Tính toàn vẹn của dữ liệu):** Đảm bảo các thay đổi không làm hỏng dữ liệu.
- **Ethical Considerations (Các cân nhắc về đạo đức):** Việc xử lý dữ liệu có gây ra sự thiên vị hay bất công không?
- Đây là những nguyên tắc quan trọng cần ghi nhớ trong suốt quá trình chuẩn bị dữ liệu. Đặc biệt, việc hiểu được liệu dữ liệu có bị thiếu một cách ngẫu nhiên hay không sẽ ảnh hưởng lớn đến việc lựa chọn phương pháp xử lý.

2.1.3. Dữ liệu bất thường (Anomalous Data)

- **Các loại giá trị bất thường:** Vô lý (Implausible values), Cực đoan (Extreme values), Sai định dạng (Incorrect data formats), Trùng lặp (Duplicate records).
- **a/ Giá trị vô lý (Implausible Values):**
 - Implausible values are data points that fall outside the realm (phạm vi) of possible values, clearly indicating errors
 - **Ví dụ:** điểm tín dụng là 2,995 hoặc -53 (trong khi thang điểm chuẩn là 300-850).
 - Depending on our judgment, we could **replace these cells with missing values** and proceed with any of the methods previously described in **our discussion of missing data**.
 - We could also return to the source of the data and **correct these values** instead of replacing them with missing values.

Credit Score Range	Credit Score Meaning
720 - 850	Excellent
690 - 719	Good
630 - 689	Fair
300 - 629	Bad

name	credit_score
Juan	800
Alice	2,995
Kai	690
Kahlil	-53

- **b/ Giá trị cực đoan (Extreme Values) và Ngoại lệ (Outliers):** Các giá trị lệch đáng kể so với mức trung bình hoặc phạm vi dự kiến. Chúng có thể là lỗi hoặc là những điểm dữ liệu thực sự đặc biệt.
 - **Các giá trị dữ liệu cực đoan:**
 - Extreme values are data points that are noticeably different from others, potentially affecting the overall analysis in noticeable ways.
 - Sai lệch đáng kể so với giá trị trung bình hoặc khoảng giá trị mong đợi (giá trị rất cao/thấp so với kỳ vọng).
 - **Ví dụ:** trong bảng điểm sinh viên, đa số điểm từ 4 → 9, nhưng có một điểm 0 hoặc 15 (vượt quá thang điểm).
 - **Cách xử lý:** Cần kiểm tra độ chính xác của dữ liệu, biến đổi dữ liệu để giảm tác động, hoặc loại bỏ (filter) nếu dựa trên kiến thức miền (domain knowledge) thấy không hợp lý.
 - **Giá trị ngoại lai:** Có thể chỉ ra lỗi hoặc bất thường, là những điểm dữ liệu khác biệt rõ rệt so với phần lớn tập dữ liệu.
 - Có thể do lỗi nhập liệu, nhưng cũng có thể chứa thông tin bất thường quan trọng (ví dụ phát hiện gian lận giao dịch ngân hàng).
 - → Sử dụng các kỹ thuật thống kê hoặc loại bỏ các giá trị ngoại lai khỏi phân tích.
 - **Nghiên cứu tình huống (Case Study): Dewey Defeats Truman:** Một ví dụ lịch sử nổi tiếng về việc một tờ báo tuyên bố sai người chiến thắng trong cuộc bầu cử tổng thống Mỹ năm 1948 do dựa trên dữ liệu thăm dò bị lỗi (dữ liệu bất thường).
- **c/ Định dạng dữ liệu không chính xác:**
 - Incorrect formats refer to data entries in an unexpected format, requiring correction to match the anticipated (dự kiến/mong đợi) data type.
 - Ví dụ: lưu số dưới dạng văn bản ("seventeen" thay vì 17), lỗi chính tả ("Goldfisg" thay vì "Goldfish") → Deletion is a last resort.
- **d/ Xác định và loại bỏ bản ghi trùng lặp:**
 - Duplicate records are repeated entries (e.g., observations) in a dataset, often identified and resolved using unique identifiers.

- Quy trình 3 bước:

- Xác định các bản ghi có khả năng trùng lặp (ví dụ: hai khách hàng có cùng tên, cùng số điện thoại hoặc email).
- So sánh các trường nhận dạng (identification fields) (ID, email, số điện thoại, mã khách hàng, ...) để kiểm tra xem chúng có thực sự là trùng nhau không.
- Chỉ giữ lại một bản sao, còn lại xóa hoặc hợp nhất để tránh dư thừa.

2.1.4. Transforming Data

2.1.4.1. Biến đổi biến định lượng (Transforming Quantitative Variables)

2.1.4.1.1. Tạo biến phân loại từ biến định lượng (Creating a Categorical Variable from a Quantitative Variable)

- **Biến định lượng - Quantitative Variables:**

- Kiểu số (Numeric)
- Cho phép thực hiện các phép tính toán học cộng, trừ, nhân, chia, trung bình.
- Chia thành 2 loại:
 - **Discrete (rời rạc)**
 - Là những biến nhận **một tập giá trị hữu hạn hoặc vô hạn đếm được**, thường không có giá trị ở giữa.
 - Được biểu diễn dưới dạng số nguyên, số thực
 - Ví dụ: số anh chị em trong gia đình (0, 1, 2, 3...), số sinh viên trong lớp, zip code, nghề nghiệp, tập hợp các từ trong bộ sưu tập tài liệu...
 - Thuộc tính binary là trường hợp đặc biệt của thuộc tính rời rạc.
 - **Continuous (liên tục)**
 - Là những biến có thể nhận **mọi giá trị trên một khoảng**, kể cả giá trị thập phân.
 - Giá trị thuộc tính: **số thực**
 - Trên thực tế, các giá trị thực chỉ có thể được đo lường và biểu diễn bằng số lượng chữ số hữu hạn
 - Ví dụ: tuổi (20.5, 20.75), chiều cao (170.2 cm), GPA (3.25, 3.8).
- **Ý nghĩa:** Phân biệt rời rạc và liên tục giúp ta chọn đúng mô hình và công cụ phân tích (ví dụ hồi quy tuyến tính thường dùng cho biến liên tục, còn phân phối nhị thức dùng cho biến rời rạc).

- **Biến phân loại - Categorical Variables:**

- Thường không phải là số
- Dùng để biểu diễn **nhóm, loại, hạng mục**.
- Không thể thực hiện phép toán số học có nghĩa (ví dụ: “Chó” + “Mèo” không có nghĩa).
- Ý nghĩa: Các biến này được dùng để **phân nhóm, so sánh** chứ không tính toán trực tiếp.

- **Quá trình tạo biến phân loại từ biến định lượng:** The process of **categorization** describes the way in which **a new categorical variable is created from an existing quantitative variable**. This is done by **assigning a category or label to intervals of values** (khoảng giá trị) of the **quantitative variable**. In the age example, it was

- Ages 0–11 years: child
- Ages 12–59 years: adult
- Ages 60+ years: senior

First Name	Age	GPA	Favorite Pet	Voted	Age Group
Selma	18	3.7	Dog	0	Adult
Jerry	19	3.5	Cat	1	Adult
Sanjiv	17	3.1	Dog	1	Adult
Olivia	18	3.9	Other	0	Adult
Hector	18	3.6	Fish	0	Adult

- In this case, we've created a categorical variable, *age_category* (*age_group*), from a quantitative variable, *age*.
- In this case, the **age categories are more useful** to a restaurant than the actual age value.
- One of the most important steps in categorization is ensuring that all possible values of the quantitative variable are each associated with **a single category**. For example, someone who is 11 years old should NOT be considered both a child and an adult.

2.1.4.1.2. Thay đổi thang đo của biến định lượng (Changing the Scale of a Quantitative Variable)

- **Nhân hoặc chia một biến cho một hằng số** để làm cho nó dễ đọc hơn (ví dụ: chia mức lương cho 1.000 để biểu thị bằng "nghìn đô la").
 $\$20,000 / 1,000 = \20 (in thousands)
 $\$800,000 / 1,000 = \800 (in thousands)
- Generally, the process of **scaling** or **transforming** describes the method of creating a new quantitative variable from an existing one by *performing some mathematical operation* on it.
- Scaling usually involves **multiplying or dividing** the original variable by a certain value.
- Transforming, in this restricted sense, refers to applying a more complex function to the original variable, such as **taking the logarithm or square root** of the values

2.1.4.1.3. Kết hợp các biến định lượng (Combining Quantitative Variables)

- Tạo một biến mới từ hai hoặc nhiều biến hiện có.
- **Ví dụ:** $GNI_bình_quân_đầu_người = GNI / dân_số$ ($gdp_per_capita = gdp / population$).
 - we would be combining two variables—*gdp* and *population*—into a new variable, *gdp_per_capita*.

2.1.4.2. Biến đổi biến phân loại (Transforming Categorical Variables)

2.1.4.2.1. Tạo biến định lượng từ biến phân loại (Creating a Quantitative Variable from a Categorical Variable)

- **Đối với Categorical Variables**
 - Represent different types of variables, Examples: pet preference, date, class standing, political party, or zip code
 - Often requires text variables (e.g. Favorite Pet), but in some cases may be numeric (e.g. Voted, or Zip Code)
 - Not appropriate for mathematical operations

- Nhiều thuật toán yêu cầu đầu vào là số, vì vậy chúng ta cần chuyển đổi các biến văn bản thành số. Ví dụ: chuyển "Có" thành 1, "Không" thành 0; hoặc "Chó" -> 1, "Mèo" -> 2, "Cá" -> 3.
- Ví dụ:**
 - Original data

student_id	age	gpa	pet_preference	voted
S1	19	3.5	Dog	Yes
S2	21	3.7	Cat	No
S3	20	3.2	None	Yes
S4	22	3.8	Dog	No
S5	19	3.1	Cat	Yes

- Data after creating Boolean variables from the categorical variable pet_preference


student_id	age	gpa	pet_preference	prefers_dogs	prefers_cats	prefers_none	voted
S1	19	3.5	Dog	1	0	0	Yes
S2	21	3.7	Cat	0	1	0	No
S3	20	3.2	None	0	0	1	Yes
S4	22	3.8	Dog	1	0	0	No
S5	19	3.1	Cat	0	1	0	Yes

- the *pet_preference* categorical variable has been transformed into three new binary variables: *prefers_dogs*, *prefers_cats*, and *prefers_none*.
- This quantitative transformation allows for numerical analysis and modeling that could not be accomplished with the original categorical data. For example, we can sum the values of *prefers_dogs* using the following equation: $1 + 0 + 0 + 1 + 0 = 2$
- Since there are five records, we know that $2/5 = 0.4 = 40\%$ of respondents prefer dogs.
- The process of **creating a quantitative variable from a categorical variable** is often called **encoding** because we are creating numeric codes associated with each category, or value, of the categorical variable.
- Boolean encoding** is a *special case of variable encoding* where we assign a 1 or 0 during encoding.

2.1.4.2.2. Cô đọng các danh mục - Condense the Categories of a Categorical Variable

- Sometimes free response results contain many different answers, some of which may not occur very often.
- Condensing categories:** **Reducing the number of values** in a categorical variable by **merging categories into broader ones**. This simplifies the variable for analysis while reducing its informational detail.
- When Mirabel's dataset involved students' pet preferences, she might have seen responses about dogs, cats, fish, birds, turtles, lizards, and more. Upon further inspection, she might discover that 90% of the responses were either "dog" or "cat". To simplify the rest of the work,

she decides to create a new variable, **pet_preference_condensed**, that contains people's pet preference as "dog," "cat," "none," or "other."



First Name	Age	GPA	Favorite Pet	Voted	Pet_Condense
Selma	18	3.7	Dog	0	Dog
Jerry	19	3.5	Cat	1	Cat
Sanjiv	17	3.1	Dog	1	Dog
Olivia	18	3.9	Other	0	Other
Hector	18	3.6	Fish	0	Other

- Typically, condensing a categorical variable means decreasing the variety of its possible values.
- This process does not need to preserve any of the original variable's values.
- Of all our transformation methods thus far, this is one of the most important methods with which to **create a new variable and not replace the existing variable**. This is because the combining of categories, although it may end up being informative, is a reduction in the information contained in the variable.

2.1.4.2.3. Tách một biến thành nhiều biến (Splitting a Variable into Multiple Variables)

- **Extracting information from the values of a categorical variable** and storing the info in a new variable
- **Example:** Categorical variable Date contains pieces of information – *day, month, year*

Date	Month	Year
3/4/2003	March	2003
11/2/1998	November	1998
3/30/2013	March	2013
5/1/2009	May	2009
9/20/2012	September	2012

2.1.4.3. Reshaping a Data Set (Định hình lại tập dữ liệu)

- **Tidy Data:**
 - Each column represents a distinct variable
 - Each row represents a unique observation
 - Each cell contains one value
- **Wide Format to Long Format (left to right), and Long Format to Wide Format (right to left)**

country	1800	1801	1802	1803	1804	1805	1806	1807	1808	1809	1810
Afghanistan	3.28M	3.28M	3.28M	3.28M	3.28M	3.28M	3.28M	3.28M	3.28M	3.28M	3.28M
Angola	1.57M	1.57M	1.57M	1.57M	1.57M	1.57M	1.57M	1.57M	1.57M	1.57M	1.57M
Albania	400k	402k	404k	405k	407k	409k	411k	413k	414k	416k	418k
Andorra	2650	2650	2650	2650	2650	2650	2650	2650	2650	2650	2650
UAE	40.2k	40.2k	40.2k	40.2k	40.2k	40.2k	40.2k	40.2k	40.2k	40.2k	40.2k
Argentina	534k	520k	506k	492k	479k	466k	453k	441k	429k	417k	420k
Armenia	413k	413k	413k	413k	413k	413k	413k	413k	413k	413k	413k
Antigua and Barbuda	37k	37k	37k	37k	37k	37k	37k	37k	37k	37k	37k
Australia	200k	205k	211k	216k	222k	227k	233k	239k	246k	252k	259k
Austria	3M	3.02M	3.04M	3.05M	3.07M	3.09M	3.11M	3.12M	3.14M	3.16M	3.18M
Azerbaijan	880k	880k	880k	880k	880k	880k	880k	880k	880k	880k	880k
Burundi	899k	899k	899k	899k	899k	899k	899k	899k	899k	899k	899k
Belgium	3.25M	3.26M	3.27M	3.28M	3.29M	3.3M	3.3M	3.31M	3.32M	3.33M	3.34M



country	year	population
Afghanistan	1800	3.28M
Afghanistan	1801	3.28M
Afghanistan	1802	3.28M
Afghanistan	1803	3.28M
Afghanistan	1804	3.28M
Afghanistan	1805	3.28M
Afghanistan	1806	3.28M
Afghanistan	1807	3.28M
Afghanistan	1808	3.28M
Afghanistan	1809	3.28M
Afghanistan	1810	3.28M
Afghanistan	1811	3.28M
Afghanistan	1812	3.28M
Afghanistan	1813	3.28M
Afghanistan	1814	3.28M
Afghanistan	1815	3.28M
Afghanistan	1816	3.28M
Afghanistan	1817	3.28M
Afghanistan	1818	3.28M
Afghanistan	1819	3.28M
Afghanistan	1820	3.29M
Afghanistan	1821	3.3M
Afghanistan	1822	3.31M
Afghanistan	1823	3.32M
Afghanistan	1824	3.34M

- **wide-format dataset:** it contains more columns than we might need → **dataset that is not tidy.**
- To tidy this dataset, we aim to convert it into a **long format** with only three columns: *country*, *year*, and *population*.
- The process of reshaping a dataset usually refers to the transformation of a dataset from wide format to long format, or from long format to wide format.
- *The wide format version* can be better for humans to read (e.g., to see as labels on a graph).
- Although *the long format version* seems less readable to a human, it is a better form for computing systems that can quickly use these variables (columns) for visualization and analysis.
- In either case, the goal is to end with a form that lends itself to visualization and analysis.

2.1.5. Integrating Data/ Combining Datasets

- Đây là một bước **cực kỳ quan trọng** trong quá trình phân tích dữ liệu.
- Khi kết hợp nhiều tập dữ liệu, ta có thể nhìn nhận vấn đề **toàn diện hơn**, thay vì chỉ dựa vào một nguồn dữ liệu đơn lẻ. Sau khi kết hợp, dữ liệu sẽ cho ta cái nhìn **rộng hơn** và **sâu hơn**, giúp nhà phân tích hoặc nhà quản lý ra được **quyết định chính xác hơn**, có cơ sở hơn.
- Thực tế các tập dữ liệu thường đến từ nhiều nguồn khác nhau, ví dụ: Excel, SQL database, CSV, API, file văn bản... Chúng có thể có **định dạng khác nhau**, **cấu trúc khác nhau**, và **chất lượng dữ liệu** (sạch/bẩn, đầy đủ/thiếu) cũng khác. Do đó, việc kết hợp cần xử lý chuẩn hóa dữ liệu, làm sạch và biến đổi cho phù hợp.

2.1.5.1. Xếp chồng (Stacking Datasets)

- Kết hợp các tập dữ liệu theo chiều dọc.
- **Các tập dữ liệu phải có cùng các biến (cột).**
- **Kết quả là một tập dữ liệu có nhiều quan sát (hàng) hơn.**

- Ví dụ: gộp dữ liệu thời tiết từ châu Phi và châu Á.

country	average_rainfall	average_temperature
Kenya	24.8	71.6
Tanzania	42.2	78.8
Uganda	47.2	71.6
Ethiopia	33.4	70.2

country	average_rainfall	average_temperature
China	25.4	57.2
Japan	66.0	60.8
India	42.6	75.2

- Since both datasets have identical variables (*country*, *average_rainfall*, and *average_temperature*), we can stack them. Resulting dataframe after stacking

country	average_rainfall	average_temperature
Kenya	24.8	71.6
Tanzania	42.2	78.8
Uganda	47.2	71.6
Ethiopia	33.4	70.2
China	25.4	57.2
Japan	66.0	60.8
India	42.6	75.2

2.1.5.2. Mở rộng (Augmenting Datasets)

- Kết hợp các tập dữ liệu theo chiều ngang.
- Các tập dữ liệu phải có cùng các quan sát (hàng).
- Kết quả là một tập dữ liệu có nhiều biến (cột) hơn.
- **Ví dụ:** gộp dữ liệu lượng mưa và nhiệt độ theo mùa của Nhật Bản. If both datasets identify all four seasons in alphabetical order, we can augment the two datasets.

season	average_rainfall
Fall	16.5
Winter	16.7
Spring	9.7
Summer	23.1

season	average_temperature
Fall	59.4
Winter	43.2
Spring	58.6
Summer	81.9

- Resulting dataframe after augmenting

season	average_rainfall	average_temperature
Fall	16.5	59.4
Winter	16.7	43.2
Spring	9.7	58.6
Summer	23.1	81.9

2.1.5.3. Trộn/Hợp nhất (Merging Datasets)

- Merging Datasets Combining datasets horizontally and vertically
- May involve different variables
- May involve different observations
- **Observations** matched on a common variable (Để ghép ngang, thường cần có một **biến chung**)
- Adds more variables and observations to the dataset

student_id	club_name
S1	Drama Club
S1	Math Club
S2	Debate Team
S3	Math Club
S3	Science Society
S4	Drama Club
S5	Debate Team
S5	Science Society

student_id	major	gpa
S1	Math	3.8
S2	English	3.5
S3	Science	3.9
S4	Drama	3.2
S5	Politics	3.7

Merged data

student_id	club_name	major	gpa
S1	Drama Club	Math	3.8
S1	Math Club	Math	3.8
S2	Debate Team	English	3.5
S3	Math Club	Science	3.9
S3	Science Society	Science	3.9
S4	Drama Club	Drama	3.2
S5	Debate Team	Politics	3.7
S5	Science Society	Politics	3.7

2.1.6. Lưu ý khi gán giá trị “other”

- Cần cân nhắc tác động đến nhận thức và cách hiểu về **các thuộc tính nhận dạng cá nhân** (giới tính, chủng tộc, tôn giáo, văn hóa, v.v.) khi gom một nhóm người vào mục **“khác” (other)**.
Ví dụ: Nếu khảo sát có các lựa chọn “Nam, Nữ, Khác”, từ “Khác” có thể khiến những người không nằm trong 2 nhóm chính cảm thấy bị gạt ra ngoài hoặc không được công nhận.
- Đảm bảo tính toàn vẹn dữ liệu bằng cách **tránh việc “othering”** (tức là xếp một số cá nhân vào nhóm “khác” mà không quan tâm đúng mức). Thay vào đó, nên thúc đẩy đa dạng và hòa nhập (diversity & inclusiveness) bằng cách cho phép nhiều lựa chọn hoặc cách mô tả chi tiết hơn để phản ánh đúng thực tế.

2.2. Making Sense of Data Through Visualization - Hiểu dữ liệu thông qua sự trực quan hóa

2.2.1. Trực quan hóa với một biến định lượng (Visualizations with One Quantitative Variable)


2.2.1.1. Biểu đồ tần suất (Histograms)

- Hiển thị sự phân phối của *dữ liệu liên tục (continuous data)*
- Cho thấy **tần suất xuất hiện của các giá trị** dữ liệu trong các **khoảng** (intervals/bins)
- **Trục X:** Giá trị của biến định lượng
- **Trục Y:** Tần suất (số lần xuất hiện)
- Có **hình dạng đa dạng** (Đối xứng, Lệch trái, Lệch phải).
 - **Lệch trái (Left-Skewed):**
 - Đuôi dài hơn về bên trái, hầu hết dữ liệu tập trung ở các giá trị cao.
 - Most of the observations are medium/large, with a few smaller observations
 - **Đối xứng (Symmetrical):**
 - Dữ liệu phân bố đều hai bên giá trị trung tâm, giống hình chuông.
 - Observations are evenly distributed on both sides of the center
 - Mean and median are near each other
 - Shapes on either side of a line drawn down the middle of the graph somewhat mirror one another


- **Lệch phải (Right-Skewed):**

- Đuôi dài hơn về bên phải, hầu hết dữ liệu tập trung ở các giá trị thấp.
- Most observations are small, with a few larger observations

- Biểu đồ tần suất là một công cụ cơ bản để "cảm nhận" dữ liệu. Nó chia phạm vi dữ liệu thành các "thùng" (bins) và đếm xem có bao nhiêu điểm dữ liệu rơi vào mỗi thùng.
- Hình dạng của biểu đồ cho chúng ta biết ngay lập tức dữ liệu tập trung ở đâu và có các giá trị bất thường hay không.



- **Applying Histograms to Social Media Analytics**




- **Bimodal and Multimodal Histograms**

- **Biểu đồ hai đỉnh (Bimodal Histogram):**


- Có hai đỉnh riêng biệt, hai mode (peaks/đỉnh) khác nhau.
- Can be symmetric
- Identifying values of the modes can provide insights

- **Biểu đồ đa đỉnh (Multimodal Histogram):** Có nhiều hơn hai đỉnh, nhiều mode (đỉnh).
- Khi một biểu đồ tần suất có nhiều hơn một đỉnh, nó thường là dấu hiệu cho thấy có thể có **hai hoặc nhiều nhóm con tiềm ẩn** trong dữ liệu của bạn.
- **Ví dụ:**
 - Nếu bạn khảo sát **chiều cao** của học sinh tiểu học, thường sẽ có **1 mode** (khoảng 120–130 cm).
 - Nếu khảo sát **chiều cao của cả nam và nữ người lớn**, bạn có thể thấy **2 mode** (nam cao trung bình hơn nữ → 2 đỉnh khác nhau).
 - Nếu khảo sát **thu nhập trong xã hội**, có thể có **3 mode hoặc nhiều hơn** (nhóm thu nhập thấp, trung bình, cao → nhiều đỉnh).



Bimodal Histogram

Two distinct peaks
Two different modes





Multimodal Histogram

More than two peaks
Multiple modes


2.2.1.2. Biểu đồ mật độ (Density Plots)

- Là một biểu diễn **liên tục**, được làm mịn (smoothed, continuous representation)
- xác định các mẫu và xu hướng
- tăng cường sự hấp dẫn thị giác.
- Có thể coi biểu đồ mật độ như một phiên bản "mượt mà" của biểu đồ tần suất.
- Thay vì các cột rời rạc, nó vẽ một **đường cong** liên tục để thể hiện sự phân phối của dữ liệu.
- Ưu điểm của nó là không phụ thuộc vào số lượng "thùng" bạn chọn (một vấn đề của biểu đồ tần suất) và **giúp nhìn ra hình dạng tổng thể của phân phối** dễ dàng hơn.



2.2.1.3. Biểu đồ hộp (Box Plots)


- Là một cách cực kỳ hiệu quả để **tóm tắt sự phân phối của dữ liệu**.
- Biểu đồ hộp hay đôi khi gọi là **biểu đồ hộp và râu (đồ thị hộp ria mèo, box-and-whisker plot)** giúp biểu diễn các đại lượng quan trọng của dãy số như giá trị nhỏ nhất (min), lớn nhất (max), giá trị phân vị (quartile), khoảng tứ phân vị (interquartile range) và sự hiện diện của các giá trị ngoại lệ.



- Sau đây là một số nguyên tắc chung để vẽ một biểu đồ hộp:
 - Vẽ một trục ngang thể hiện giá trị của dữ liệu.
 - Trên trục này, vẽ một hình chữ nhật với cạnh phía trái hộp là phân vị thứ nhất Q1 và cạnh phía phải hộp là phân vị thứ ba Q3.
 - Vẽ một đường thẳng đứng nối cạnh trên và cạnh dưới của hộp tại điểm trung vị m.


- Để vẽ râu bên trái, ta vẽ một đường nằm ngang từ giá trị nhỏ nhất đến điểm giữa cạnh bên trái của hộp.
- Để vẽ râu bên phải, ta vẽ một đường ngang nối từ điểm giữa cạnh phải của hộp đến giá trị lớn nhất của hộp.
- Sau khi vẽ như vậy, ta có biểu đồ hộp chia dữ liệu một cách hình ảnh thành 4 phần.
 - **Chú ý rằng, đường ngang chiều dài hộp là khoảng tứ phân vị IQR, râu bên trái thể hiện phần tư thứ nhất, và râu bên phải thể hiện phần tư cuối cùng của dữ liệu.**
- Biểu đồ hộp thường dùng để biểu diễn một tập giá trị hoặc so sánh giữa các tập giá trị với nhau (một trục có kiểu dữ liệu là *nomial/phân loại*, trục còn lại có kiểu *numeric/số*).
- **Median (Q2 - Trung vị):**
 - Là giá trị đứng ở giữa dữ liệu khi sắp xếp từ nhỏ → lớn.
 - Ví dụ: Điểm kiểm tra của lớp là [4, 5, 6, 8, 9]. Trung vị = 6 (điểm ở giữa).
 - 👉 Nó giúp thấy “điểm điển hình” của dữ liệu, không bị lệch nhiều bởi ngoại lệ.
- **25th Percentile (Q1 - Tứ phân vị thứ nhất):**
 - Là điểm chia sao cho **25% dữ liệu nhỏ hơn nó**.
 - Ví dụ: Trong lớp có 100 học sinh, Q1 là điểm của học sinh đứng thứ 25 nếu xếp theo điểm từ thấp đến cao.
 - 👉 Nó cho thấy “rìa thấp” của dữ liệu.
- **75th Percentile (Q3 - Tứ phân vị thứ ba):**
 - Là điểm chia sao cho **75% dữ liệu nhỏ hơn nó**.
 - Ví dụ: Trong lớp 100 học sinh, Q3 là điểm của học sinh đứng thứ 75.
 - 👉 Nó cho thấy “rìa cao” của dữ liệu.
- **Interquartile Range (IQR - Khoảng tứ phân vị):** Chiều cao của hộp (Q3 - Q1), chứa 50% dữ liệu ở giữa.
 - Ví dụ: Nếu Q1 = 5 và Q3 = 9 thì IQR = 4.
 - 👉 Nó đo mức độ “tán mát” của dữ liệu (giống như khoảng “phần giữa” đồng học sinh nhất).
- **Whiskers ("Râu"):** Các đường kéo dài từ hộp, thể hiện **phạm vi của dữ liệu**, thường là đến giá trị nhỏ nhất và lớn nhất, không phải là ngoại lệ.
- **Potential Outliers (Ngoại lệ tiềm năng):** Các điểm nằm ngoài "râu".
 - Là những giá trị **quá khác biệt** so với phần lớn dữ liệu.
 - Ví dụ: Lớp học đa số điểm từ 5–9, có 1 bạn được 0 điểm hoặc 20 điểm (nếu thang 20). Đây là ngoại lệ.
 - 👉 Ngoại lệ có thể là **lỗi nhập dữ liệu** hoặc **thông tin đặc biệt cần chú ý**.

- **Example**




2.2.1.4. Biểu đồ Violin (Violin Plots)

- Kết hợp các đặc điểm của box plot và density plot
- Cung cấp một cái nhìn chi tiết hơn về sự phân phối dữ liệu.
- **Cấu trúc:**
 - **Phần giữa:** Box plot (có thể thấy median, Q1, Q3)
 - **Độ rộng:** Density plot (phần nào rộng = nhiều dữ liệu ở đó)
- **Có thể thấy:**
 - dữ liệu có một đỉnh hay nhiều đỉnh (unimodal vs bimodal)
 - Độ tập trung của dữ liệu ở các vùng khác nhau
 - Hình dạng tổng thể của phân phối




- **Ví dụ:** Đây là violin plot so sánh **Life Expectancy (Tuổi thọ)** của 6 châu lục. Mỗi "cây violin" thể hiện phân phối tuổi thọ của các quốc gia trong châu lục đó.



2.2.2. Trực quan hóa với một biến phân loại - Visualization with One Categorical Variable

- **Categorical Variables:** Các giá trị đại diện cho một danh mục hoặc nhóm (ví dụ: Thú cưng yêu thích, Đã bỏ phiếu).
- **All** text variables & Some numeric variables are categorical variables
- **Mathematical operations are never used on categorical variables**
 → Chúng được tóm tắt bằng cách đếm (counts) hoặc tính phần trăm (percentages). For example:
 - How many people responded "Dog" for Favorite Pet? "Cat"?
 - What percentage of people indicated that they voted?
- **Biểu đồ cột (Column Charts) và Biểu đồ thanh (Bar Charts):**
 - Hiển thị phân phối tần suất cho một biến phân loại.
 - Shows the number of observations in each category of the variable
 - Biểu đồ thanh chỉ là biểu đồ cột được xoay 90 độ.



• So sánh Biểu đồ thanh và Biểu đồ tần suất (Histogram):

Tiêu chí	BAR CHART	HISTOGRAM
Dùng cho loại dữ liệu	Categorical (phân loại)	Quantitative (định lượng)
Khoảng cách giữa các cột	CÓ (các nhóm là độc lập , không liên tục)	KHÔNG (tính liên tục của dữ liệu)
Thứ tự cột	Tùy ý	Cố định (theo giá trị)
Trục X	Nhãn văn bản phân loại	Trục số liên tục
Trục Y	Count hoặc %	Frequency (tần suất)
Có thể đổi thứ tự?	CÓ	KHÔNG
Ứng dụng	❖ Doanh số theo sản phẩm ❖ Số học sinh theo khoa ❖ Phân bố theo giới tính, tôn giáo ❖ Votes cho các ứng viên	❖ Phân bố điểm thi ❖ Phân bố thu nhập (số cụ thể, không phải nhóm) ❖ Chiều cao, cân nặng của dân số ❖ Thời gian hoàn thành công việc

• Đám mây từ (Word Clouds):

- Tập hợp các từ từ dữ liệu văn bản, hiển thị với các kích thước khác nhau. Các từ xuất hiện thường xuyên hơn sẽ có kích thước lớn hơn.
- Đám mây từ là một cách trực quan, sinh động để tóm tắt nhanh nội dung chính của một khối văn bản.




2.2.3. Trực quan hóa với hai biến (Visualizations with Two Variables)

- **Biểu đồ thanh cho biến định lượng và phân loại:** Chiều cao của mỗi thanh (đại diện cho một danh mục) thể hiện giá trị trung bình của một biến định lượng. Ví dụ: mỗi thanh là một châu lục, chiều cao là tỷ lệ truy cập internet trung bình.

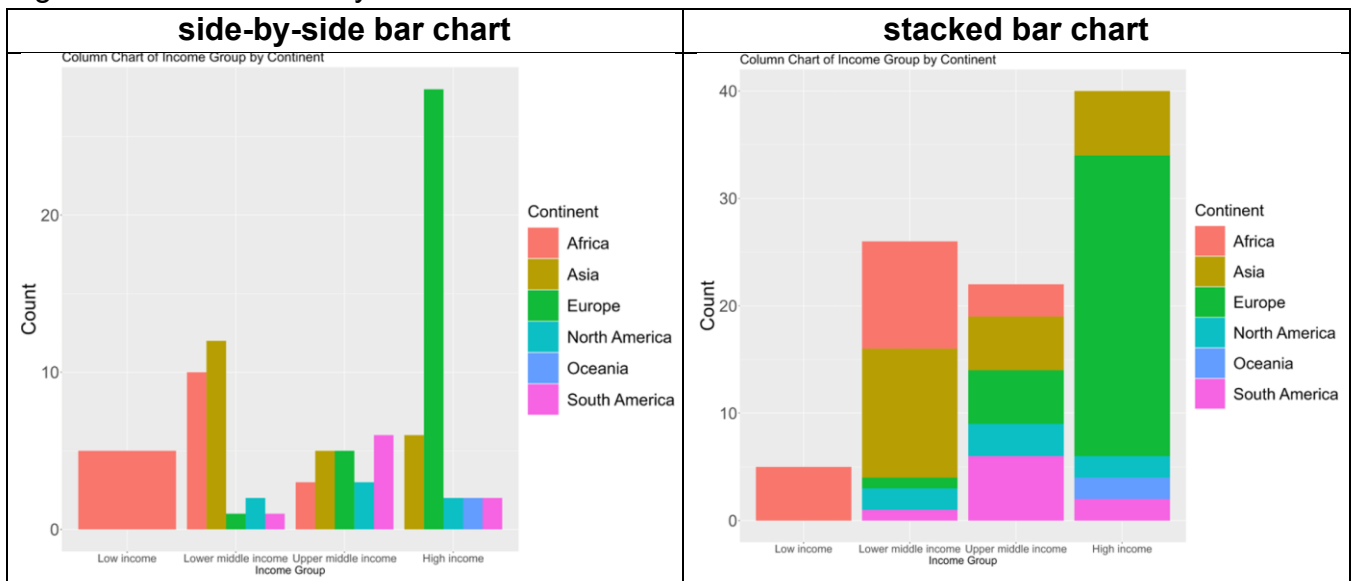
Height of each bar = mean percentage of people with internet access (quantitative variable)

Each bar represents a continent (categorical variable)




- **Biểu đồ thanh cho hai biến phân loại:** Có thể dùng biểu đồ thanh kề nhau (side-by-side) hoặc biểu đồ thanh chồng (stacked) để so sánh.

These plots display the exact same information for **Income Group** and **Continent**, but organized in different ways!




- **Bản đồ cây (Treemaps):** Hiện thị dữ liệu có cấu trúc phân cấp (hierarchical data). Mỗi hình chữ nhật đại diện cho một danh mục (category or subcategory), và diện tích của nó tương ứng với giá trị của dữ liệu.




- **Biểu đồ hộp (Box Plot) với biến phân loại:**

- Visualize a **quantitative variable's distribution** across the values of a **categorical variable**
- Vẽ nhiều biểu đồ hộp cạnh nhau, mỗi biểu đồ cho một nhóm trong biến phân loại. Rất tốt để so sánh sự phân phối của một biến định lượng giữa các nhóm khác nhau.


Boxplot of Global Green Economy Index by Continent



- **Biểu đồ Violin với biến phân loại:** Tương tự như trên, nhưng dùng biểu đồ violin để so sánh chi tiết hơn.



- **Biểu đồ phân tán (Scatterplot):** Hiện thị **mối quan hệ giữa hai biến định lượng**. Mỗi điểm đại diện cho một quan sát.
 - **Explanatory Variable (Biến giải thích/Biến độc lập)**
 - **Định nghĩa:** Biến được cho là **có ảnh hưởng** đến biến khác
 - **Đặc điểm:** Tác động, giải thích sự thay đổi của biến phản hồi
 - **Vị trí:** Trục X (trục ngang)
 - **Explanatory (X) = nguyên nhân / yếu tố ảnh hưởng.**
 - **Tên gọi khác:** Independent variable, predictor variable
 - **Response Variable (Biến phản hồi/Biến phụ thuộc)**
 - Là biến **kết quả** mà chúng ta quan tâm, muốn nghiên cứu
 - **Đặc điểm:** Được cho là **bị ảnh hưởng, chịu tác động từ các biến khác**
 - **Vị trí:** Trục Y (trục dọc)
 - **Response (Y) = kết quả / phản ứng.**
 - **Tên gọi khác:** Dependent variable, outcome variable




- ❖ **Trục X (ngang):** GNI Per Capita (\$) → Tổng thu nhập quốc dân bình quân đầu người.
- ❖ **Trục Y (dọc):** GGEI (Global Green Economy Index) → Chỉ số nền kinh tế xanh toàn cầu.
- ❖ **Đường xu hướng (trend line):**
 - Màu xanh dương, dốc lên
 - Cho thấy **mối quan hệ dương (positive relationship)**
- ❖ Mỗi **chấm đen** đại diện cho một quốc gia. Ví dụ:
 - Chấm ở tọa độ (10000, 0.5) = một quốc gia có GNI \$10,000/người và GGEI = 0.5
 - Chấm ở (60000, 0.75) = quốc gia giàu có (GNI \$60,000) và có chỉ số xanh cao (0.75)

○ **Một số quan sát chính:**

- **Càng giàu (GNI cao) → càng có chỉ số kinh tế xanh cao.** Điều này cho thấy các quốc gia giàu thường có chỉ số kinh tế xanh cao hơn (có điều kiện đầu tư vào công nghệ sạch, năng lượng tái tạo, chính sách môi trường...).
- Tuy nhiên, vẫn có một số **điểm lệch** (outliers):
 - Có quốc gia giàu nhưng GGEI thấp.
 - Hoặc quốc gia chưa giàu nhưng GGEI khá cao.
- **Độ phân tán tăng dần:**
 - Thu nhập thấp: ít biến động trong chỉ số xanh
 - Thu nhập cao: biến động lớn hơn (một số quốc gia giàu vẫn có chỉ số xanh thấp)

○ Biểu đồ này chứng minh rằng **quốc gia càng giàu thì thường càng “xanh”**, nhưng không phải lúc nào cũng đúng 100% vì còn nhiều yếu tố khác ngoài thu nhập.


- **Biểu đồ đường (Line Chart):** Hiển thị dữ liệu dưới dạng một chuỗi các điểm được nối bằng các đường thẳng, thường dùng để thể hiện sự thay đổi của một giá trị theo thời gian.



2.2.4. Trực quan hóa với ba hoặc nhiều biến (Visualizations with Three or More Variables)


- **Visualize Two Quantitative Variables and One Categorical Variable with a Scatterplot:**
Tương tự như sử dụng biểu đồ phân tán với 2 biến, nhưng lần này ta sử dụng thêm màu sắc cho các điểm để đại diện cho một biến phân loại thứ ba.

Scatter Plot of GGEI vs. GNI Per Capita, by Continent




- **Biểu đồ bong bóng (Bubble Charts):** Bắt đầu từ một biểu đồ phân tán (2 biến định lượng trên trục x, y như diễn giải ở phần trước), sau đó sử dụng kích thước của các điểm (bong bóng) để đại diện cho một biến định lượng thứ ba. Có thể thêm màu sắc để thể hiện biến thứ tư (phân loại).


Bubble Chart of GGEI by GNI Per Capita




Scatterplot of GGEI vs. GNI Per Capita, by Continent



- **Bản đồ nhiệt (Heatmaps):** Sử dụng màu sắc để biểu thị giá trị của một biến định lượng cho sự kết hợp của hai biến phân loại.




- *Document-word frequencies*



- **Bản đồ địa lý (Geographic Maps):** Trực quan hóa một biến định lượng liên quan đến các vùng địa lý.

Geographic Map of Europe
Visualizing GGEI by Country



2.2.5. Big Picture Break: Visualizing Data

- **Có rất nhiều cách để trực quan hóa dữ liệu:** Một biến, hai biến, hoặc nhiều biến cùng lúc → biểu đồ cột, đường, phân tán, histogram, heatmap, boxplot, ... Gần như “vô hạn” lựa chọn.
- **Người làm phân tích thường thử nhiều biểu đồ khác nhau để tìm ra cách thể hiện dễ hiểu nhất.**
- **Mục tiêu quan trọng nhất** của trực quan hóa dữ liệu:
 - Rõ ràng (**clear**)
 - Dễ tiếp cận với mọi người (**accessible**)
 - Người xem có thể nắm bắt thông tin nhanh (**quickly digestible**).

2.3. Exploratory Data Analysis - Phân tích dữ liệu khám phá

2.3.1. Đo lường xu hướng tập trung (Central Tendency)

- Trước khi kinh doanh hoặc mua sắm một thứ đắt giá nào đó, ta cần phân tích thị trường, các dữ liệu sẵn có.
- Các vấn đề cần quan tâm phân tích dữ liệu bao gồm: xu hướng trung tâm, độ biến thiên, hình dạng, mối liên hệ, các giá trị ngoại lệ (central tendency, variability, shape, associations, outliers).
- Central tendency characterizes a data set (đặc tả một tập dữ liệu) using the **middle** or “**typical**” value (giá trị “điển hình”).
- **Các thước đo:** Trung bình (Mean), Trung vị (Median), Yếu vị (Mode), Trung bình cắt 90% (90% Trimmed Average). Các giá trị này dùng để tóm tắt, so sánh và dự đoán.
 - **The mean (Trung bình cộng)**, or average, is computed by **adding all values in the data set** and **dividing by the number of observations**.

- **A 90% trimmed average** is the average of **the middle 90% of a variable's values** in a data set.
 - Lấy **90% giá trị ở giữa** sau khi bỏ đi 5% nhỏ nhất và 5% lớn nhất, rồi tính trung bình.
 - **Ví dụ:** Giả sử bạn có một tập dữ liệu về thu nhập hàng tháng (triệu đồng) của 10 người trong một nhóm: 20, 25, 30, 35, 40, 45, 50, 60, 100, 200. Chúng ta sẽ tính **90% trimmed mean** cho tập dữ liệu này.
 - **Bước 1: Sắp xếp dữ liệu:** Dữ liệu được sắp xếp theo thứ tự tăng dần:
20, 25, 30, 35, 40, 45, 50, 60, 100, 200
 - **Bước 2: Xác định số lượng giá trị cần loại bỏ**
 - Với **90% trimmed mean**, chúng ta loại bỏ **5% thấp nhất** và **5% cao nhất** của dữ liệu.
 - Tổng số phần tử: $n = 10$.
 - Số phần tử bị loại ở mỗi đầu: $5\% \times 10 = 0.5$. Vì số phần tử phải là số nguyên, chúng ta làm tròn lên để loại bỏ **1 giá trị** ở đầu thấp nhất và **1 giá trị** ở đầu cao nhất (tổng cộng 2 giá trị).
 - **Bước 3: Loại bỏ giá trị**
 - Giá trị thấp nhất: **20** (loại bỏ).
 - Giá trị cao nhất: **200** (loại bỏ).
 - Tập dữ liệu sau khi loại bỏ: **25, 30, 35, 40, 45, 50, 60, 100**
 - **Bước 4: Tính trung bình của các giá trị còn lại**
 - Các giá trị còn lại: **25, 30, 35, 40, 45, 50, 60, 100**.
 - Tổng: $25 + 30 + 35 + 40 + 45 + 50 + 60 + 100 = 385$.
 - Số phần tử còn lại: $10 - 2 = 8$.
 - **90% trimmed mean** = $385/8 = 48.125$ triệu đồng.
 - **So sánh với trung bình cộng thông thường**
 - Trung bình cộng thông thường của toàn bộ tập dữ liệu:
$$\frac{20+25+30+35+40+45+50+60+100+200}{10} = \frac{605}{10} = 60.5 \text{ triệu đồng.}$$
 - **Nhận xét:** Trung bình cộng thông thường (60.5) bị ảnh hưởng mạnh bởi giá trị ngoại lai (200), trong khi 90% trimmed mean (48.125) phản ánh tốt hơn mức thu nhập trung tâm của nhóm, vì nó loại bỏ các giá trị bất thường (20 và 200).
 - Nếu $0.05 \times n \leq 0.5$, bạn có thể:
 - **Không loại bỏ giá trị nào** và tính trung bình cộng thông thường, nhưng điều này làm mất ý nghĩa của trimmed mean.
 - **Loại bỏ 1 giá trị ở mỗi đầu** để giữ ý nghĩa của trimmed mean, đặc biệt khi có ngoại lai rõ rệt.
 - Với tập dữ liệu nhỏ, cần cân nhắc kỹ xem trimmed mean có thực sự phù hợp hay không, vì việc loại bỏ giá trị có thể làm mất thông tin.

- **The median (trung vị)** is the middle value in a data set (tập dữ liệu đã được sắp xếp theo thứ tự tăng dần).
 - Nếu m là trung vị của một phân bố nào đó thì một nửa phần tử trong phân bố đó có giá trị nhỏ hơn hay bằng m và một nửa còn lại có giá trị bằng hoặc lớn hơn m .
 - **Quy tắc:**
 - Nếu số phần tử n là **lẻ**, trung vị là giá trị ở vị trí $\frac{n+1}{2}$.
 - Nếu số phần tử n là **chẵn**, trung vị là trung bình cộng của hai giá trị ở vị trí $\frac{n}{2}$ và $\frac{n}{2} + 1$.
 - **Ví dụ 1: Tập dữ liệu có số phần tử lẻ**
 - **Tập dữ liệu:** 3, 7, 1, 9, 5 (5 phần tử)
 - **Bước 1: Sắp xếp dữ liệu:** Sắp xếp theo thứ tự tăng dần: **1, 3, 5, 7, 9**
 - **Bước 2: Xác định vị trí trung vị**
 - Số phần tử: $n = 5$ (lẻ).
 - Vị trí trung vị: $\frac{n+1}{2} = \frac{5+1}{2} = 3$.
 - Giá trị tại vị trí thứ 3: **5**.
 - **Kết quả: Trung vị = 5.**
 - **Ví dụ 2: Tập dữ liệu có số phần tử chẵn (không có ngoại lai)**
 - **Tập dữ liệu:** 10, 4, 8, 6, 12, 2 (6 phần tử)
 - **Bước 1: Sắp xếp dữ liệu:** Sắp xếp theo thứ tự tăng dần: **2, 4, 6, 8, 10, 12**
 - **Bước 2: Xác định vị trí trung vị**
 - Số phần tử: $n = 6$ (chẵn).
 - Vị trí trung vị: Hai giá trị ở vị trí $\frac{n}{2} = \frac{6}{2} = 3$ và $\frac{n}{2} + 1 = 4$.
 - Giá trị tại vị trí thứ 3: **6**.
 - Giá trị tại vị trí thứ 4: **8**.
 - Trung vị = Trung bình cộng của hai giá trị này: $\frac{6+8}{2} = \frac{14}{2} = 7$.
 - **Kết quả: Trung vị = 7.**
 - **Một số nhận định:**
 - Trung vị không bị ảnh hưởng bởi ngoại lai.
 - Trung vị hoạt động tốt với các phân bố không đối xứng (skewed data).
- **The mode (mốt)** is the value that occurs the most frequently in the data set.
 - Một tập dữ liệu có thể:
 - **Không có mốt:** Nếu không có giá trị nào xuất hiện nhiều hơn một lần.
 - **Một mốt** (unimodal): Nếu chỉ có một giá trị xuất hiện nhiều lần nhất.
 - **Nhiều mốt** (bimodal hoặc multimodal): Nếu có hai hoặc nhiều giá trị xuất hiện với tần suất cao nhất bằng nhau.
 - **Ví dụ:** Dữ liệu: {2, 4, 4, 6, 6, 6, 8}
 - Giá trị xuất hiện nhiều nhất là **6**.
 - Vậy mode = 6.

- **Khi nào sử dụng môđ?**

- *Dữ liệu phân loại*: Ví dụ, xác định sản phẩm bán chạy nhất, màu sắc phổ biến nhất.
- *Dữ liệu số rời rạc*: Khi cần biết giá trị phổ biến nhất (ví dụ, số lần xuất hiện của một điểm số).
- *Phân bố đa đỉnh (multimodal)*: Môđ giúp xác định các cụm giá trị phổ biến, hữu ích trong phân tích cụm.

- **So sánh giữa giá trị trung bình, trung vị và môđ:**

- Trong 3 tham số trung bình, trung vị và môđ thì trung vị có khả năng **đo lường xu hướng tập trung của dữ liệu mạnh nhất**.

- **Ví dụ:**

- Có mẫu về 8 lần chạy như sau: $x = \{25.1, 21.2, 17.9, 23.0, 24.6, 19.5, 79.9, 79.9\}$
- Cũng có mẫu về 6 lần chạy thu được: $x = \{25.1, 21.2, 17.9, 23.0, 24.6, 19.5\}$
- Các giá trị trung bình, trung vị và môđ so sánh giữa 2 mẫu như sau:

Xu hướng tập trung	6 lần đo	8 lần đo
Trung bình	21.9 giây	36.4 giây
Trung vị	22.1 giây	23.8 giây
Môđ	Không có	79.9 giây

- Nếu quan sát cẩn thận, đối với 6 lần chạy đầu tiên thì thành tích đó chính là thời gian chạy bình thường, còn 2 lần sau có sự khác biệt rất lớn so với 6 lần chạy ban đầu (**2 giá trị này được xem là bất thường của dữ liệu – giá trị ngoại lai, outlier**) thực chất nó không phải thời gian chạy mà là thời gian đi bộ. Nếu người A không bị đau thì thời gian chạy dao động quanh giá trị trung vị.
- Theo bảng trên có thể thấy rằng **2 giá trị ngoại lai không ảnh hưởng nhiều đến trung vị** (từ 22.1 lên 23.8) **nhưng ảnh hưởng rất lớn đến trung bình** (từ 21.9 lên 36.4) **và môđ**.
- Mặc dù giá trị trung vị có khả năng đo lường xu hướng tập trung của dữ liệu mạnh hơn trung bình vì trung vị không bị ảnh hưởng bởi các giá trị ngoại lai *nhưng nhiều người vẫn thích sử dụng giá trị trung bình để đo lường xu hướng tập trung của dữ liệu vì dễ tính hơn không cần phải sắp xếp dữ liệu như trung vị*.
- **Môđ** rất hữu ích đối với dữ liệu có kiểu dữ liệu phân loại (nominal). **Đối với các dữ liệu có kiểu phân loại ta không thể dùng giá trị trung bình hay trung vị vì không thể tính được hoặc không có ý nghĩa mà phải dùng môđ**. Ví dụ, cho dữ liệu mô tả giới tính thuộc kiểu phân loại với giá trị 1 là nam, 0 là nữ thì trung bình hay trung vị là 0.5 không có ý nghĩa gì. Trong khi đó môđ sẽ cho biết tần suất nam hay nữ xuất hiện nhiều nhất.

2.3.2. Đo lường sự biến thiên của dữ liệu (Variability)

- Thước đo mức độ khác biệt của các điểm dữ liệu trong một tập dữ liệu định lượng so với nhau.
- **Các thước đo:** Khoảng biến thiên (Range), Phương sai (Variance), Độ lệch chuẩn (Standard Deviation).

• Range

- Difference between the maximum and minimum values in a dataset
- Provides a simple measure of the spread of values
- **range = maximum value – minimum value**

• Variance

- Cả 2 tham số khoảng biến thiên và khoảng tứ phân vị không quan tâm đến giá trị trung tâm (thường sử dụng giá trị trung bình). **Khi muốn đo lường sự phân tán của dữ liệu so với giá trị trung tâm, người ta sẽ đo lường độ lệch của mỗi quan sát (phần tử) so với giá trị trung tâm của mẫu.**
- **Average squared distance** from each data point to the mean
- Quantifies (định lượng) how much data points differ from the average value

Population	Sample
$\sigma^2 = \frac{\sum (x_i - \mu)^2}{N}$	$s^2 = \frac{\sum (x_i - \bar{x})^2}{n - 1}$
x_i = elements in population μ = population mean N = population size	x_i = elements in sample $\bar{x}$ = sample mean n = sample size

- **Tổng thể (Population):** Là toàn bộ tập hợp các phần tử mà bạn quan tâm. Ví dụ, nếu bạn nghiên cứu chiều cao của tất cả học sinh trong một trường, thì đó là tổng thể.
- **Mẫu (Sample):** Là một tập con được chọn từ tổng thể để nghiên cứu, thường vì không thể thu thập dữ liệu từ toàn bộ tổng thể. Ví dụ, bạn chỉ đo chiều cao của 50 học sinh trong trường.

• Standard Deviation


- Định lượng mức độ biến thiên (variation) hoặc phân tán (dispersion) trong một tập hợp các giá trị
 - **Mức độ phân tán (dispersion)** trong một tập giá trị đề cập đến mức độ mà các giá trị trong tập dữ liệu phân bố hoặc lan tỏa xung quanh một giá trị trung tâm (như trung bình, trung vị, hoặc mốt).
- **Được tính bằng căn bậc hai của phương sai**
- Độ lệch chuẩn nhỏ hơn cho thấy các điểm dữ liệu gần giá trị trung bình hơn (ít biến động hơn)
- Độ lệch chuẩn lớn hơn cho thấy các điểm dữ liệu xa hơn so với trung bình (biến động lớn hơn)

- **Ví dụ:** Giả sử có hai lớp học với điểm thi toán như sau:
 - **Lớp A:** 6, 7, 7, 8, 7 (5 học sinh)
 - **Lớp B:** 2, 4, 7, 10, 12 (5 học sinh)
 - Cả hai lớp có **trung bình** = 7, nhưng mức độ phân tán sẽ khác nhau.
- a. Tính khoảng biến thiên (Range):**
 - Lớp A: Range = $8 - 6 = 2$.
 - Lớp B: Range = $12 - 2 = 10$.
- b. Tính độ lệch chuẩn (Standard Deviation):**
 - **Lớp A:**
 - Trung bình: $\bar{x} = 7$.
 - Các độ lệch: $(6 - 7)^2 = 1$, $(7 - 7)^2 = 0$, $(7 - 7)^2 = 0$, $(8 - 7)^2 = 1$, $(7 - 7)^2 = 0$.
 - Tổng bình phương độ lệch: $1 + 0 + 0 + 1 + 0 = 2$.
 - Phương sai (mẫu): $s^2 = \frac{2}{5-1} = 0.5$.
 - Độ lệch chuẩn: $s = \sqrt{0.5} \approx 0.707$.
 - **Lớp B:**
 - Trung bình: $\bar{x} = 7$.
 - Các độ lệch: $(2 - 7)^2 = 25$, $(4 - 7)^2 = 9$, $(7 - 7)^2 = 0$, $(10 - 7)^2 = 9$, $(12 - 7)^2 = 25$.
 - Tổng bình phương độ lệch: $25 + 9 + 0 + 9 + 25 = 68$.
 - Phương sai (mẫu): $s^2 = \frac{68}{5-1} = 17$.
 - Độ lệch chuẩn: $s = \sqrt{17} \approx 4.123$.
- Nhận xét:**
 - Lớp A có mức độ phân tán thấp (range = 2, độ lệch chuẩn ≈ 0.707), điểm số tập trung quanh trung bình (7).
 - Lớp B có mức độ phân tán cao (range = 10, độ lệch chuẩn ≈ 4.123), điểm số phân bố rộng hơn.

2.3.3. Mối liên kết dữ liệu (Data Associations)


2.3.3.1. Data Associations

- Relationships between pairs of variables take three primary forms:
 - **quantitative-by-quantitative** (định lượng-định lượng)
 - **quantitative-by-categorical** (định lượng-phân loại)
 - **categorical-by-categorical** (phân loại-phân loại)
- **Ví dụ:** Điểm đánh giá của nhà phê bình vs. Điểm của người dùng là một ví dụ về quan hệ định lượng-định lượng, được thể hiện hoàn hảo bằng biểu đồ phân tán.




- **Quantitative-by-Quantitative Relationships**

- **hệ số tương quan (correlation coefficient)**, ký hiệu là r .
 - Luôn nằm trong khoảng từ **-1 đến 1**.
 - Đo lường **độ mạnh** và **hướng** của mối quan hệ tuyến tính giữa hai biến định lượng.
 - $r = 1$: Quan hệ tuyến tính hoàn hảo tích cực (**perfect positive** linear relationship) – khi một biến tăng, biến kia cũng tăng theo đường thẳng.
 - $r = -1$: Quan hệ tuyến tính hoàn hảo tiêu cực (**perfect negative** linear relationship) – khi một biến tăng, biến kia giảm theo đường thẳng.
 - $r = 0$: Không có mối quan hệ tuyến tính (**no correlation**).
- **Ứng dụng**: Hệ số tương quan hữu ích để đánh giá xem hai biến định lượng (như chiều cao và cân nặng) có xu hướng thay đổi cùng hướng hay ngược hướng không, nhưng chỉ áp dụng cho mối quan hệ tuyến tính (ví dụ: nhiệt độ và tiêu thụ điện).



Quantitative-by-Categorical Relationships

State	Mean Price (USD)	Median Price (USD)	Standard Deviation of Price (USD)
Georgia	19,779	18,639	12,732
Illinois	16,752	13,998	12,734
Oregon	16,724	12,980	14,075
Pennsylvania	15,960	11,900	12,121
Texas	19,757	17,990	13,290




Quantitative variable: Price of a car

Categorical variable: State in which the car is sold

- The table and box plot show the **quantitative variable's center and variability** across **categorical variable** values.
- Sử dụng thống kê trung tâm (mean, median) và phân tán (standard deviation, IQR) để so sánh, **phù hợp với dữ liệu số theo nhóm** (ví dụ: thu nhập theo vùng).
- Điều này cho phép so sánh trực quan nhanh chóng về cả xu hướng trung tâm và độ phân tán giữa các nhóm.

- **Categorical-by-Categorical Relationships**

	Automatic	Manual	Other	Total
GA	3979	285	2016	6280
IL	7551	549	1739	9839
OR	12440	1246	515	14201
PA	9119	837	2770	12726
TX	16554	1117	3643	21314
Total	49643	4034	10683	64363



- **First categorical variable:** State in which the car is sold
- **Second categorical variable:** Type of transmission (Loại hộp số) on the sold car
- Sử dụng **counts/proportions** và **biểu đồ cột chồng** để phân tích, phù hợp với **dữ liệu phân loại** (ví dụ: loại xe theo khu vực).

- **Lưu ý:**

- *Two variables can be associated without being correlated (Hai biến có thể được liên kết mà không có mối tương quan):*
 - **Association:** Có một mối quan hệ nào đó giữa hai biến (có thể không tuyến tính).
 - Ví dụ: Tuổi và sở thích âm nhạc. Có mối liên hệ (trẻ thích nhạc trẻ, lớn tuổi thích nhạc xưa), nhưng không phải mối quan hệ tuyến tính.
 - **Correlation:** Chỉ áp dụng cho mối quan hệ tuyến tính giữa hai biến định lượng, mô tả bằng đường thẳng.
 - Ví dụ: Nhiệt độ tăng thì tiền điện điều hòa cũng **tăng** theo gần tuyến tính → có tương quan dương.

- *Two variables can be associated or correlated without having a causal relationship (Hai biến có thể được liên kết hoặc tương quan mà không có mối quan hệ nhân quả):*
 - **Causal relationship:** Thay đổi một biến gây ra thay đổi ở biến kia (ví dụ: mưa gây ngập).
 - Ví dụ: Uống nhiều nước (biến A) làm tăng lượng nước tiểu (biến B).
 - **Correlation does not imply causation!** (Tương quan không có nghĩa là mối quan hệ nhân-quả).
 - Ví dụ, số lượng kem bán ra và số người bị cháy nắng có thể tương quan (cùng tăng vào mùa hè), nhưng không phải kem gây cháy nắng – **cả hai đều phụ thuộc vào yếu tố thời tiết.**

2.3.3.2. Phân vị (Percentiles)

- **Phân vị (Percentiles)** là một thước đo thống kê dùng để chia tập dữ liệu đã được sắp xếp theo thứ tự tăng dần thành 100 phần bằng nhau.
- Mỗi phân vị biểu thị giá trị dưới đó có một tỷ lệ phần trăm nhất định của dữ liệu nằm.
- **Phân vị thứ p (percentile p)** là giá trị dưới đó $p\%$ của dữ liệu nằm. Ví dụ:
 - Phân vị 25 (P25 hay **Q1**) là giá trị dưới đó 25% dữ liệu nằm.
 - Phân vị 50 (P50 hay **Q2**) là giá trị trung vị (median), dưới đó 50% dữ liệu nằm.
 - Phân vị 75 (P75 hay **Q3**) là giá trị dưới đó 75% dữ liệu nằm.
- Tổng cộng có 99 phân vị (P1 đến P99), nhưng các phân vị quan trọng thường được chú ý là P25, P50, và P75.
- Phân vị khác với phần trăm (percentage) ở chỗ nó là một giá trị cụ thể trong dữ liệu, trong khi phần trăm là tỷ lệ.
- **Cách tính phân vị**
 - **Bước 1:** Sắp xếp tập dữ liệu theo thứ tự tăng dần.
 - **Bước 2:** Tính vị trí của phân vị bằng công thức: $\text{Vị trí} = \frac{p}{100} \times (n + 1)$. Trong đó:
 - p là phần trăm tương ứng (ví dụ: 25 cho P25).
 - n là số phần tử trong tập dữ liệu.
 - Nếu vị trí không phải số nguyên, nội suy tuyến tính giữa hai giá trị gần nhất.
 - Công thức nội suy tuyến tính thường được áp dụng khi tính phân vị:
Giá trị nội suy = $L + (U - L) \times f$. Trong đó:
 - L : Giá trị tại vị trí thấp hơn (sàn, lower value).
 - U : Giá trị tại vị trí cao hơn (trần, upper value).
 - f : Hệ số nội suy, bằng phần thập phân của vị trí (vị trí - phần nguyên).
- **Ví dụ 1:**
 - Giả sử bạn có điểm thi của 11 học sinh trong một lớp: **4, 6, 8, 10, 12, 14, 16, 18, 20, 22, 25**
 - **a. Tính Phân vị 25 (P25 - Tứ phân vị thứ nhất, Q1)**
 - Số phần tử $n = 11$.
 - Vị trí P25: $\frac{25}{100} \times (11 + 1) = 0.25 \times 12 = 3$.
 - Vị trí là số nguyên 3, nên giá trị tại vị trí thứ 3 là **8**.
 - **Kết quả:** P25 = **8** (25% học sinh có điểm dưới 8).


- **b. Tính Phân vị 50 (P50 - Trung vị, Q2)**
 - Vị trí P50: $\frac{50}{100} \times (11 + 1) = 0.5 \times 12 = 6$.
 - Vị trí là số nguyên 6, nên giá trị tại vị trí thứ 6 là **14**.
 - **Kết quả:** P50 = **14** (50% học sinh có điểm dưới 14, tức trung vị).
- **c. Tính Phân vị 75 (P75 - Tứ phân vị thứ ba, Q3)**
 - Vị trí P75: $\frac{75}{100} \times (11 + 1) = 0.75 \times 12 = 9$.
 - Vị trí là số nguyên 9, nên giá trị tại vị trí thứ 9 là **20**.
 - **Kết quả:** P75 = **20** (75% học sinh có điểm dưới 20).
- **Ví dụ 2:** Giả sử bạn có tập dữ liệu điểm thi của 12 học sinh: 4, 6, 8, 10, 12, 14, 16, 18, 20, 22, 24, 26.
 - Số phần tử $n = 12$.
 - Vị trí P25: $\frac{25}{100} \times (12 + 1) = 0.25 \times 13 = 3.25$.
 - Vị trí 3.25 không phải số nguyên:
 - Phần nguyên: $[3.25] = 3$ (giá trị $L = 8$).
 - Phần thập phân: $3.25 - 3 = 0.25$ (hệ số nội suy $f = 0.25$).
 - Giá trị tại vị trí trần: $U = 10$ (vị trí 4).
 - Công thức nội suy: $P25 = 8 + (10 - 8) \times 0.25 = 8 + 2 \times 0.25 = 8 + 0.5 = 8.5$
 - **Kết quả:** P25 = **8.5** (25% dữ liệu nằm dưới 8.5).
- **Ứng dụng thực tế**
 - **Giáo dục:** Nếu điểm thi của bạn ở P90 (phân vị 90), nghĩa là bạn cao hơn 90% học sinh khác.
 - **Y học:** Trẻ em ở P10 về cân nặng có thể được bác sĩ theo dõi kỹ hơn, vì chỉ 10% trẻ em có cân nặng thấp hơn.
 - **Kinh doanh:** Một sản phẩm ở P75 về doanh số có thể là sản phẩm bán chạy trong top 25%.

2.3.3.3. Khoảng tứ phân vị (Interquartile Range - IQR)

- Tứ phân vị là đại lượng mô tả sự phân bố và sự phân tán của tập dữ liệu.
- Tứ phân vị có 3 giá trị, đó là tứ phân vị thứ nhất (Q1), thứ nhì (Q2), và thứ ba (Q3). Ba giá trị này chia một tập hợp dữ liệu (đã sắp xếp dữ liệu theo trật từ từ bé đến lớn) thành 4 phần có số lượng quan sát đều nhau.
- Được tính bằng hiệu số giữa **tứ phân vị thứ ba (Q3)** và **tứ phân vị thứ nhất (Q1)**.

$$IQR = Q3 - Q1$$

- **Equivalent to the difference between the 75th percentile and the 25th percentile**



- IQR đo lường sự biến thiên (variability) của 50% dữ liệu ở giữa tập dữ liệu, tức là khoảng chứa phần trung tâm của phân bố.

- Vì nó bỏ qua 25% giá trị thấp nhất và 25% giá trị cao nhất, nó **không bị ảnh hưởng bởi các giá trị ngoại lai**, làm cho nó trở thành một thước đo độ phân tán **vững chắc** hơn so với Khoảng (Range).
- IQR thường được sử dụng trong biểu đồ hộp (box plot) để xác định ranh giới của "hộp" (box) và phát hiện ngoại lai (outliers thường nằm ngoài $Q1 - 1.5 \times IQR$ và $Q3 + 1.5 \times IQR$).
- **Ví dụ:** Giả sử bạn có tập dữ liệu điểm thi của 12 học sinh: **4, 6, 8, 10, 12, 14, 16, 18, 20, 22, 24, 30**.
 - **a. Tính Q1 (P25) và Q3 (P75)**
 - **Sắp xếp dữ liệu:** 4, 6, 8, 10, 12, 14, 16, 18, 20, 22, 24, 30.
 - **Tính P25 (Q1):**
 - Vị trí: $\frac{25}{100} \times (12 + 1) = 0.25 \times 13 = 3.25$.
 - Nội suy: $L = 8$ (vị trí 3), $U = 10$ (vị trí 4), $f = 0.25$.
 - $Q1 = 8 + (10 - 8) \times 0.25 = 8 + 0.5 = 8.5$.
 - **Tính P75 (Q3):**
 - Vị trí: $\frac{75}{100} \times (12 + 1) = 0.75 \times 13 = 9.75$.
 - Nội suy: $L = 22$ (vị trí 9), $U = 24$ (vị trí 10), $f = 0.75$.
 - $Q3 = 22 + (24 - 22) \times 0.75 = 22 + 1.5 = 23.5$.
 - **b. Tính IQR:** $IQR = Q3 - Q1 = 23.5 - 8.5 = 15$.
 - **c. So sánh với Range**
 - Range = Giá trị lớn nhất - Giá trị nhỏ nhất = $30 - 4 = 26$.
 - IQR = 15 (chỉ xem xét 50% dữ liệu giữa).
 - Nếu thêm ngoại lai (ví dụ: 100 thay cho 30):
 - Range = $100 - 4 = 96$ (tăng mạnh).
 - IQR vẫn là $23.5 - 8.5 = 15$ (không đổi), *chứng minh IQR kháng cự với ngoại lai*.
 - "IQR = 15 cho thấy **50% tổng số học sinh có điểm số nằm trong khoảng từ Q1 (8.5) đến Q3 (23.5), với độ rộng khoảng cách là 15 điểm**, và giá trị này không bị ảnh hưởng bởi ngoại lai.

2.3.4. Xác định các giá trị ngoại lệ (Identifying Outliers)

2.3.4.1. Phương pháp Tứ phân vị và phương pháp Trung bình/Độ lệch chuẩn (Outliers: The Quartile and Mean/SD Method)

* Standard Deviation = SD

- **Outliers**
 - **Data points** that significantly **differ from other observations** in a dataset
 - **Mild outliers (Ngoại lệ nhẹ):** Moderate differences (khác biệt vừa phải), có thể chỉ là một giá trị hơi cao hoặc thấp nhưng vẫn hợp lý.
 - **Regular outliers (Ngoại lệ thông thường/cực đoan):** Extreme differences (khác biệt cực lớn), có nhiều khả năng là lỗi nhập liệu hoặc một sự kiện thực sự hiếm hoi cần được điều tra.

- **The Quartile Method - Phương pháp Tứ phân vị**


- Đây là phương pháp dựa trên sự phân bố của dữ liệu và có khả năng chống lại ảnh hưởng của chính các giá trị ngoại lệ.
- **Bước 1: Tính IQR.** Đầu tiên, bạn sắp xếp dữ liệu và tìm Tứ phân vị thứ nhất (Q1 - 25% dữ liệu nhỏ hơn nó) và Tứ phân vị thứ ba (Q3 - 75% dữ liệu nhỏ hơn nó).
- **Bước 2: $IQR = Q3 - Q1$.** Hãy hình dung IQR là "chiếc hộp" trong biểu đồ hộp, chứa 50% dữ liệu ở giữa. Nó cho biết độ phân tán của phần cốt lõi của dữ liệu.
- **Bước 3: Xác định Ngoại lệ nhẹ.** Chúng ta tạo ra một "hàng rào" (fence). Bất kỳ điểm dữ liệu nào nằm ngoài hàng rào này đều được coi là ngoại lệ nhẹ.
 - Hàng rào dưới: $Q1 - 1.5 * IQR$
 - Hàng rào trên: $Q3 + 1.5 * IQR$
- **Bước 4: Xác định Ngoại lệ cực đoan.** Chúng ta tạo ra một "hàng rào" xa hơn.
 - Hàng rào dưới: $Q1 - 3 * IQR$
 - Hàng rào trên: $Q3 + 3 * IQR$

- **The Mean/SD Method - Phương pháp Trung bình/Độ lệch chuẩn**


- **Ý tưởng cốt lõi:** Chúng ta đo khoảng cách từ mỗi điểm dữ liệu đến giá trị trung bình (mean), và đơn vị đo là độ lệch chuẩn (standard deviation - SD).
- **Cách phát hiện ngoại lệ:**
 - **Ngoại lệ nhẹ:** Giá trị nằm ngoài khoảng:
 - Dưới: $Mean - 2 \times SD$
 - Trên: $Mean + 2 \times SD$
 - **Ngoại lệ mạnh:** Giá trị nằm ngoài khoảng:
 - Dưới: $Mean - 3 \times SD$
 - Trên: $Mean + 3 \times SD$

2.3.4.2. Lựa chọn phương pháp tốt nhất (Choosing the Best Method for Detecting Outliers)

Quartile Method	Mean/SD Method
❖ vững chắc (robust). ❖ Nó sử dụng trung vị và các tứ phân vị, những giá trị này không bị ảnh hưởng nhiều bởi một vài giá trị cực đoan. ❖ Do đó, nó ít nhạy cảm với các giá trị ngoại lệ và là lựa chọn <u>ưu tiên cho dữ liệu bị lệch (skewed data).</u>	❖ Đây là phương pháp cơ bản trong thống kê, dễ lập trình hoặc tính tay, không cần sắp xếp dữ liệu như Quartile. ❖ không vững chắc. ❖ Giá trị trung bình và độ lệch chuẩn đều bị "kéo" về phía các giá trị ngoại lệ. ❖ Do đó, nó <u>chỉ hoạt động tốt khi dữ liệu của bạn đối xứng (symmetrical).</u> nơi giá trị trung bình thực sự là trung tâm của dữ liệu.



2.3.4.3. Ethics in Practice: Simpson's Paradox (Nghịch lý Simpson)



- Giới thiệu một hiện tượng thống kê nơi một xu hướng bị đảo ngược khi dữ liệu được chia thành các nhóm con. Đây là một trong những cạm bẫy nguy hiểm nhất trong phân tích dữ liệu.

- **Biểu đồ bên trái (Dữ liệu tổng hợp):** Nếu bạn chỉ nhìn vào tất cả các điểm dữ liệu, bạn sẽ thấy một mối tương quan dương (đường màu tím đi lên). Kết luận có vẻ là: "Những người có mức độ bất ổn tâm lý (Neuroticism) cao hơn có xu hướng kiếm được nhiều tiền hơn".
- **Biểu đồ bên phải (Dữ liệu chia nhóm):** Bây giờ, chúng ta thêm vào biến thứ ba: Trình độ học vấn. Khi chúng ta vẽ đường xu hướng cho từng nhóm học vấn riêng biệt (Thấp, Trung bình, Cao), xu hướng đột ngột đảo ngược. Trong *mỗi* nhóm, những người có mức độ bất ổn tâm lý cao hơn lại có xu hướng kiếm được ít tiền hơn (các đường xu hướng đều đi xuống).
- **Tại sao lại có nghịch lý này?** Biến thứ ba ("**biến ẩn**" - **lurking variable**) là trình độ học vấn. Có thể những người có trình độ học vấn cao hơn có xu hướng vừa có lương cao hơn vừa có điểm bất ổn tâm lý cao hơn một chút. Khi bạn gộp tất cả lại, ảnh hưởng mạnh mẽ của học vấn lên lương đã che lấp và đảo ngược mối quan hệ thực sự giữa bất ổn tâm lý và lương.
- Nếu một nhà phân tích chỉ trình bày biểu đồ bên trái và đưa ra kết luận sai lầm, họ có thể gây ra những quyết định chính sách hoặc kinh doanh tồi tệ. Điều này nhấn mạnh trách nhiệm đạo đức của nhà phân tích là **phải khám phá dữ liệu một cách thấu đáo, chứ không chỉ dừng lại ở bề mặt**.

2.4. Normalization – Chuẩn hóa dữ liệu

- Chuẩn hóa dữ liệu là một bước quan trọng trong nhiều trường hợp, đặc biệt khi xử lý dữ liệu có các thuộc tính với phạm vi giá trị khác nhau.
- **Tại sao cần chuẩn hóa?**
 - Trong dữ liệu, các thuộc tính có thể có phạm vi giá trị rất khác nhau (ví dụ: chiều cao từ 150-200 cm, cân nặng từ 50-100 kg).
 - Khi tính khoảng cách (distance) hoặc độ tương đồng (similarity), các giá trị nhỏ có thể bị "biến mất" hoặc không ảnh hưởng đáng kể so với các giá trị lớn.
 - **Mục tiêu:** Đưa các thuộc tính về cùng thang đo để so sánh được (thường là khoảng [0, 1]).
- Chuẩn hóa giúp dữ liệu có thể so sánh được, đặc biệt trong tính toán khoảng cách hoặc độ tương đồng.

• Các phương pháp chuẩn hóa

- **Chia cho giá trị lớn nhất của mỗi thuộc tính (Min-Max Normalization với max):**

- **Công thức:**
$$\text{new value} = \frac{\text{old value}}{\text{max value in the column}}$$
- **Kết quả:** Đưa tất cả giá trị của cột về khoảng [0, 1], với giá trị lớn nhất bằng 1.
- **Ví dụ:**

Temperature	Humidity	Pressure
30	0.8	90
32	0.5	80
24	0.3	95

Temperature	Humidity	Pressure
0.9375	1	0.9473
1	0.625	0.8421
0.75	0.375	1

- **Ứng dụng:** Phù hợp khi muốn giữ tỷ lệ tương đối và không quan tâm đến giá trị nhỏ nhất.

○ **Chia cho hiệu giữa giá trị lớn nhất và nhỏ nhất sau khi trừ giá trị nhỏ nhất (Min-Max Normalization chuẩn):**

- **Công thức:**
$$\text{new value} = \frac{\text{old value} - \text{min column value}}{\text{max column value} - \text{min column value}}$$
- **Kết quả:** Đưa tất cả giá trị về [0, 1], với giá trị nhỏ nhất bằng 0, lớn nhất bằng 1.
- **Ví dụ:**

Temperature	Humidity	Pressure
0.75	1	0.33
1	0.6	0
0	0	1

- **Ứng dụng:** Thường dùng để so sánh trực tiếp, vì giá trị nhỏ nhất được chuẩn hóa về 0.

○ **Chia cho tổng giá trị mỗi hàng trong ma trận:**

- **Công thức:**
$$\text{new value} = \frac{\text{old value}}{\sum \text{old values in the row}}$$
- **Kết quả:** Chuyển đổi vector thành một phân phối, tổng các giá trị trong hàng bằng 1 (tỷ lệ phần trăm).
- **Ví dụ:**

	Word 1	Word 2	Word 3
Doc 1	28	50	22
Doc 2	12	25	13

	Word 1	Word 2	Word 3
Doc 1	0.28	0.5	0.22
Doc 2	0.24	0.5	0.26

- **Ứng dụng:** Hữu ích để so sánh mức độ tương đồng giữa các tài liệu (ví dụ: số từ chung), vì tập trung vào tỷ lệ thay vì giá trị tuyệt đối.

○ **Trừ giá trị trung bình của mỗi hàng:**

▪ **Công thức:**

$$\text{new value} = (\text{old value} - \text{mean row value}) / (\text{max row value} - \text{min row value})$$

▪ **Kết quả:** Bắt được độ lệch so với hành vi trung bình, loại bỏ xu hướng chung.

▪ **Ví dụ:**

	Movie 1	Movie 2	Movie 3
User 1	1	2	3
User 2	2	3	4

	Movie 1	Movie 2	Movie 3
User 1	-1	0	+1
User 2	-1	0	+1

▪ **Ứng dụng:** So sánh cách người dùng chấm điểm phim (ví dụ: ai có xu hướng chấm cao hơn trung bình).