

CHAPTER 7: DATA MINING TRENDS AND RESEARCH FRONTIERS – UNSTRUCTURED DATA MINING

Mục lục

7.1. Mining Rich Data Types	1
7.1.1. Mining Text Data (Khai phá dữ liệu văn bản)	2
7.1.2. Mining Spatial-Temporal Data	3
7.1.3. Mining Graph and Networks	4
7.2. Data Mining Applications (Các Ứng Dụng Khai Phá Dữ Liệu)	6
7.2.1. Data Mining for Sentiment and Opinion (Khai phá dữ liệu cho Tình cảm và Quan điểm)	6
7.2.2. Truth Discovery and Misinformation Identification	6
7.2.3. Information and Disease Propagation (Lan truyền thông tin và Dịch bệnh)	7
7.2.4. Productivity and Team Science	8
7.3. Data Mining Methodologies And Systems (Các phương pháp và hệ thống khai phá dữ liệu)	9
7.3.1. Structuring Unstructured Data for Knowledge Mining: A Data-Driven Approach	9
7.3.2. Data Augmentation (Tăng cường dữ liệu)	10
7.3.3. From Correlation to Causality (Từ Tương quan đến Nhân quả)	11
7.3.4. Network as a Context	12
7.3.5. Auto-ML: Methods and Systems	12
7.4. Data Mining, People and Society	13
7.4.1. Privacy-Preserving Data Mining (Khai phá dữ liệu bảo vệ quyền riêng tư)	13
7.4.2. Human-Algorithm Interaction (Tương tác giữa người và thuật toán)	14
7.4.3. Mining beyond Maximizing Accuracy (Khai phá vượt ra ngoài việc tối đa hóa độ chính xác): Fairness, Interpretability, and Robustness	14
7.4.4. Data Mining for Social Good (Khai phá dữ liệu vì lợi ích xã hội)	16

7.1. Mining Rich Data Types


- "Rich Data Types" không phải là các bảng dữ liệu số đơn giản. Chúng có cấu trúc phức tạp, chứa nhiều thông tin ngữ nghĩa và mối quan hệ ngầm.
 - **Văn bản:** Dữ liệu phi cấu trúc, ngôn ngữ tự nhiên.
 - **Không gian-thời gian:** Dữ liệu có gắn tọa độ địa lý và dấu thời gian.
 - **Đồ thị và Mạng lưới:** Dữ liệu biểu diễn các mối quan hệ giữa các thực thể.
- Việc khai phá các loại dữ liệu này đòi hỏi các kỹ thuật chuyên biệt thay vì các thuật toán khai phá dữ liệu truyền thống. Ví dụ, với dữ liệu văn bản, chúng ta cần Xử lý ngôn ngữ tự nhiên (NLP); với dữ liệu không gian-thời gian, cần các thuật toán nhận biết về vị trí và thời gian; với đồ thị, cần các thuật toán lý thuyết đồ thị.

7.1.1. Mining Text Data (Khai phá dữ liệu văn bản)

- Over 80% of the data is in **an unstructured format**, e.g., news, image, audio.
- **Goal:** deriving **high-quality information**, such as structures, patterns, and summaries, from **unstructured text data**.
- **Process:** mining **structures** from text $\Rightarrow$ deriving patterns within the structured data (Tìm ra các **mẫu** trong dữ liệu **đã có cấu trúc**) $\Rightarrow$ evaluating and interpreting output
- **Main challenge:** **How to represent text primitives** (các thành phần cơ bản của văn bản) (e.g., words, sentences, and documents) and **how to learn effective representation from unstructured text?**
- Vấn đề cốt lõi là máy tính không hiểu được văn bản như con người. Do đó, thách thức lớn nhất là chuyển văn bản (thứ phi cấu trúc) thành một dạng biểu diễn số (thường là vector) mà máy tính có thể xử lý, trong khi vẫn giữ lại được ngữ nghĩa của nó.
- **Major Tasks (Các tác vụ chính trong khai phá dữ liệu văn bản)**
 - **Trích xuất thông tin (Information Extraction - IE):** Tự động lấy thông tin có cấu trúc (tên người, địa điểm, ngày tháng) từ văn bản.
 - **Xây dựng phân loại (Taxonomy Construction):** Tạo ra các hệ thống phân cấp khái niệm (ví dụ: "Chó" là một loại "Động vật có vú").
 - **Phân cụm văn bản (Text Clustering):** **Nhóm các văn bản tương tự lại với nhau** mà không có nhãn cho trước (ví dụ: nhóm các bài báo về cùng một sự kiện).
 - **Phân loại văn bản (Text Classification):** **Gán văn bản vào các danh mục đã được định nghĩa trước** (ví dụ: phân loại email là "Spam" hay "Không phải Spam").
 - **Tóm tắt văn bản (Text Summarization):** **Tạo ra một phiên bản ngắn gọn** chứa các thông tin quan trọng nhất của văn bản gốc.
- **Techniques (Các kỹ thuật)**
 - **Biểu diễn dựa trên ký hiệu (Symbol-based representation):** Dùng one-hot vectors cho từ và mô hình bag-of-words cho tài liệu. Vấn đề của nó là high-dimensionality và dữ liệu thưa thớt (data sparsity).
 - Đơn giản nhưng thô sơ. Mỗi từ là một chiều riêng biệt, không có mối liên hệ ngữ nghĩa. Ví dụ, trong từ điển 10,000 từ, mỗi từ là một vector 10,000 chiều với một số 1 và 9,999 số 0. Điều này tạo ra không gian rất lớn và thưa thớt.
 - **Biểu diễn phân tán (Distributed representation):** Dùng các vector số thực, đặc, chiều thấp. Kỹ thuật này sử dụng **mạng nơ-ron sâu** và lượng lớn dữ liệu chưa gán nhãn.
 - **Word embedding:** Các từ có nghĩa tương tự sẽ có vector biểu diễn gần nhau trong không gian.
 - Tinh vi và hiệu quả hơn. Các từ được "nhúng" vào một không gian vector có số chiều thấp hơn nhiều (ví dụ 200-300 chiều), và vị trí của chúng trong không gian đó thể hiện ý nghĩa của chúng. Đây là nền tảng của NLP hiện đại.
 - **Mô hình ngôn ngữ tiền huấn luyện (Pre-trained language model):** Sử dụng dữ liệu quy mô lớn để tạo ra các biểu diễn có ngữ cảnh.

- **Các kỹ thuật biểu diễn phân tán cụ thể:**

- **Word2vec:** Nhúng các từ có ngữ cảnh chung vào gần nhau. e.g., "Sweden" can be embedded close to Norway, Finland. Có hai mô hình chính:
 - **CBOW (Continuous Bag-of-Words):** Dự đoán từ hiện tại dựa vào các từ xung quanh.
 - **Skip-gram:** Dự đoán các từ xung quanh dựa vào từ hiện tại.
 - *Skip-gram thường hoạt động tốt hơn với các tập dữ liệu nhỏ và các từ hiếm, trong khi CBOW nhanh hơn và hoạt động tốt với các từ xuất hiện thường xuyên.*



- **GloVe (Global Vectors):** Kết hợp cả phương pháp phân rã ma trận toàn cục và phương pháp cửa sổ ngữ cảnh cục bộ.
- **JoSE:** Học cách nhúng từ trong không gian hyperbolic để mô hình hóa cấu trúc phân cấp.
- **Mô hình ngôn ngữ tiên huấn luyện:** ELMo và BERT.

7.1.2. Mining Spatial-Temporal Data

- **Các thuộc tính chính:**



- **Tự tương quan (Auto-correlation):** Sự phụ thuộc và tương quan ở các vị trí và thời gian gần nhau (ví dụ: tình trạng giao thông ở các ngã tư liền kề).
- **Tính không đồng nhất (Heterogeneity):** Sự phân bố không đồng đều và không ổn định (ví dụ: mật độ dân cư khác nhau giữa các quận).

- **Các loại dữ liệu không gian-thời gian:**

Data type	Definition	Operation	Examples
Event	at a spatial location and a time point (<i>Xảy ra tại một địa điểm và thời điểm cụ thể</i>).	intersections and similarity/difference	intersection of forest fire and a rainfall returns the overlapping area and time
Trajectory	a path of an object over space and time (<i>Đường đi của một đối tượng theo không gian và thời gian</i>).	finding relationships between two trajectories (<i>Tìm kiếm các mối quan hệ giữa hai quỹ đạo</i>)	transportation (e.g., tracing vehicle), epidemiology, ecology
Point reference data	collected using discrete reference points (<i>Dữ liệu thu thập tại các điểm rời rạc</i>).	reconstructing fields and modeling non-stationary random process (<i>tái tạo trường và mô hình hóa quá trình ngẫu nhiên không tĩnh</i>)	using mobile sensors to collect temperature data in a certain region
Raster data	recording observation data at fixed locations and fixed time (<i>Dữ liệu quan sát tại các vị trí cố định và thời gian cố định</i>).	converting a raster to a finer or coarser resolution (<i>Chuyển đổi raster sang độ phân giải mịn hơn hoặc thô hơn</i>)	estimate traffic volume using data from nearby sensors/cameras

7.1.3. Mining Graph and Networks

- Đồ thị/Mạng lưới bao gồm **một tập các nút (nodes)** và **một tập các cạnh (edges)**, dùng để mô hình hóa các hệ thống phức tạp như mạng xã hội.
- **Phân loại:**
 - **Đồ thị có thuộc tính vs. đồ thị trơn (Attributed vs. plain):** Các nút/cạnh có **thông tin bổ sung hay không**.
 - **Đồ thị động vs. tĩnh (Dynamic vs. static):** **Cấu trúc/thuộc tính** của đồ thị **có thay đổi theo thời gian hay không**.
 - **Đồ thị đồng nhất vs. không đồng nhất (Homogeneous vs. heterogeneous):** Các nút/cạnh **có cùng loại hay không**.



- Hầu hết các mạng lưới trong thế giới thực đều là mạng không đồng nhất, có thuộc tính và động.

- **Problems (Các bài toán)**

- **Graph Modeling (Mô hình hóa đồ thị):** to study and simulate (mô phỏng) the generation mechanisms.
 - **Động lực:** Hiểu cách các đồ thị được hình thành, Bảo vệ quyền riêng tư bằng cách ẩn danh hóa mạng xã hội.
 - **Các mô hình đồ thị:**
 - **Mô hình Erdős-Rényi:** Mô hình ngẫu nhiên cổ điển.
 - **Các bộ tạo đồ thị thực tế:** Bắt chước các thuộc tính của đồ thị thực, ví dụ mô hình Barabási-Albert dựa trên "liên kết ưu tiên" (preferential attachment).
 - **Các mô hình sinh sâu (Deep generative models):** Dùng mạng nơ-ron để tạo ra các đồ thị giống thực tế.
 - **Thách thức:** Các mạng không đồng nhất.
- **Heterogeneous Network Mining (Khai phá mạng không đồng nhất):** capturing rich semantics. Nắm bắt được ngữ nghĩa phong phú trong các mạng này.
 - **Khái niệm cốt lõi: meta-path.** Đây là một chuỗi các mối quan hệ. Ví dụ: Author-Paper-Author (Tác giả - Bài báo - Tác giả) biểu diễn mối quan hệ "đồng tác giả".
 - **Ứng dụng của meta-path:**
 - **Tìm kiếm tương tự (Similarity search):** Cải thiện độ chính xác xếp hạng.
 - **Phân loại nút (Node classification):** Suy ra nhãn của các nút.
 - **Phân cụm (Clustering):** Biểu diễn các ngữ nghĩa khác nhau.
 - **Nhúng mạng không đồng nhất:** Xây dựng các vùng lân cận.
 - **Thách thức:** Tự động suy ra cấu trúc và ngữ nghĩa từ dữ liệu đầu vào.
- **Khai phá đồ thị tri thức (Knowledge Graph Mining).**
 - **Định nghĩa Đồ thị tri thức (Knowledge Graph - KG):** Một **đồ thị không đồng nhất, có hướng, liên kết** các khái niệm và thực thể thông qua các ngữ nghĩa mà con người có thể hiểu được (ví dụ: DBPedia, Google KG).
 - **Phương pháp xây dựng KG:** Tốn nhiều công sức, thường dựa vào một bản thể luận (ontology) được định nghĩa trước.
 - **Xây dựng bằng cách trích xuất (Extractive construction):** Trích xuất thông tin, gán nhãn ngữ nghĩa.
 - **Dựa trên mô hình ngôn ngữ (Language model-based).**
 - **Dựa trên học biểu diễn (Representation learning-based):** Dự đoán liên kết, phân giải thực thể.
 - **Thách thức:**
 - Tự động xây dựng và cập nhật KG một cách linh động.
 - Các ứng dụng như AI y tế, AI hội thoại, máy tìm kiếm học thuật.

7.2. Data Mining Applications (Các Ứng Dụng Khai Phá Dữ Liệu)

7.2.1. Data Mining for Sentiment and Opinion (Khai phá dữ liệu cho Tình cảm và Quan điểm)

- **Tình cảm (Sentiment):** Một cái nhìn về thái độ/cảm xúc đối với một tình huống hoặc sự kiện.
- **Quan điểm (Opinion):** Một cái nhìn hoặc nhận định được hình thành về một điều gì đó.
- **Mối quan hệ:** Tình cảm và quan điểm có mối tương quan chặt chẽ.
 - **Lưu ý:** Nhiều quan điểm thể hiện tình cảm, nhưng một số thì không (ví dụ: "Tôi nghĩ cô ấy sẽ chuyển đến Canada sau khi tốt nghiệp").
- **Sự khác biệt tinh tế:** Ví dụ câu về tình cảm ("Tôi thấy khai phá dữ liệu rất thú vị") và câu về quan điểm ("Tôi tin rằng khai phá dữ liệu rất hứa hẹn và hữu ích"). Bạn có thể đồng ý với tình cảm ở câu đầu nhưng không đồng ý với quan điểm ở câu sau.
- Lĩnh vực này còn được gọi là **Opinion Mining** hoặc **Sentiment Analysis**. Nó được ứng dụng rộng rãi trong kinh doanh để theo dõi phản hồi của khách hàng về sản phẩm, trong chính trị để đo lường phản ứng của công chúng, và trong tài chính để dự đoán xu hướng thị trường dựa trên tin tức.
- **Techniques (Các kỹ thuật)**
 - **Mục tiêu:** Hiểu được tình cảm được thể hiện trong văn bản.
 - **Các kỹ thuật được sử dụng:** Xử lý ngôn ngữ tự nhiên (NLP), Học máy và khai phá dữ liệu, Tâm lý học và khoa học xã hội.
 - **Các hướng kỹ thuật được khám phá:**
 - Phân tích ở các cấp độ khác nhau: Tài liệu, câu, khía cạnh (aspect-level).
 - Phân loại tình cảm dựa trên từ điển (lexicons).
 - Hai loại nội dung văn bản: độc lập (stand-alone) và hội thoại trực tuyến (online conversations).
 - Khai phá ý định (Mining intent).
 - Phát hiện spam quan điểm (Opinions spam detection).

7.2.2. Truth Discovery and Misinformation Identification

- **Truth Discovery (Khám phá sự thật)**
 - Đánh giá và chọn ra giá trị đúng thực sự cho một mục dữ liệu khi các nguồn khác nhau cung cấp thông tin mâu thuẫn.
 - **Phân loại:**
 - **Khám phá đơn sự thật (Single-truth discovery):** Chỉ có **một giá trị đúng duy nhất** (ví dụ: ngày sinh của một người).
 - **Khám phá đa sự thật (Multi-truth discovery):** Có thể có **nhiều giá trị đúng** (ví dụ: các tác giả của một cuốn sách).
 - **Thách thức:**
 - Đánh giá **độ tin cậy của nguồn (source trustworthiness)** và **độ tin cậy của thông tin (claim reliability)**. Hai yếu tố này phụ thuộc lẫn nhau: nguồn đáng tin cậy thường cung cấp thông tin đáng tin cậy, và thông tin được nhiều nguồn đáng tin cậy xác nhận có khả năng là sự thật.
 - Lượng dữ liệu được gán nhãn hạn chế (khó biết trước nguồn nào đáng tin).
 - Phát hiện hành vi sao chép các giá trị sai.
 - Đánh giá kết quả dựa trên phân phối dữ liệu và coi những câu trả lời sai lệch đáng kể so với tiêu chuẩn là câu trả lời sai.

- **Identification of Misinformation (Nhận diện thông tin sai lệch)**
 - **Mục tiêu:** Phát hiện thông tin sai, không chính xác, hoặc gây hiểu lầm từ một nguồn dữ liệu.
 - **Các giải pháp tiềm năng:**
 - Tận dụng sự tương hỗ giữa độ tin cậy của nguồn và độ tin cậy của thông tin (ý tưởng tương tự như Truth Discovery).
 - Phân biệt thông tin sai lệch bằng các biện pháp bổ sung: giáo dục về kiến thức thông tin và truyền thông, sử dụng kiến thức thông thường, phát triển tư duy phản biện.
 - Xác định thông tin sai lệch ở giai đoạn cuối dựa trên: mô hình tư duy và niềm tin của cá nhân, sự lặp lại của thông tin sai, độ trễ thời gian và sự mạch lạc giữa thông tin sai và thông tin chính xác.
 - Việc chống lại thông tin sai lệch không chỉ là một bài toán kỹ thuật. Nó cần sự kết hợp giữa các thuật toán (đánh giá nguồn/thông tin) và các yếu tố con người/xã hội (giáo dục, tư duy phản biện). Việc thông tin sai lệch được lặp đi lặp lại có thể khiến mọi người tin đó là sự thật, đây là một thách thức lớn.

7.2.3. Information and Disease Propagation (Lan truyền thông tin và Dịch bệnh)

- **Bài toán nghiên cứu:** Dự đoán và Tối ưu hóa sự lan truyền.
 - **Ứng dụng:**
 - **Mạng xã hội:** Dự đoán tin tức lan truyền (viral), tìm nguồn gốc tin đồn, ngăn chặn thông tin sai lệch.
 - **Dịch tễ học tính toán:** Xác định ngưỡng dịch bệnh để một đại dịch có khả năng xảy ra.
- **Bài toán dự đoán:** Phân loại và hồi quy (dự đoán một thông tin có trở nên **phổ biến** hay không), dự đoán trước/sau khi thông tin được công bố, Dự đoán ở các mức độ chi tiết khác nhau: cá nhân/nhóm thông tin.
- **Bài toán tối ưu hóa (trên mạng xã hội):**
 - **Tối đa hóa ảnh hưởng (Influence maximization):** choose a set of initial nodes to maximize the number of infected nodes (Tìm ra những người có ảnh hưởng nhất để bắt đầu một chiến dịch marketing).
 - **Xác định nguồn (Source localization):** **identify source** of a cascade over network **with partial observations** (Tìm ra "bệnh nhân số 0" của một tin đồn).
 - **Định hình hoạt động (Activity shaping):** Điều hướng hành vi của người dùng.
 - **Tối ưu hóa kết nối đồ thị:** tác động đến cấu trúc liên kết đồ thị để ảnh hưởng đến kết quả lan truyền thông tin
- Bài toán tối đa hóa ảnh hưởng là một bài toán NP-hard, nghĩa là không có thuật toán hiệu quả nào để tìm ra giải pháp tối ưu tuyệt đối cho các mạng lưới lớn. Tuy nhiên, có nhiều thuật toán xấp xỉ hiệu quả.

- **Mô hình sử dụng cho các vấn đề **khuyến tán thông tin**:**
 - **Mô hình dựa trên đặc trưng (Feature based):** Dùng các **mô hình học có giám sát** với các đặc trưng về thời gian, cấu trúc mạng, người dùng, v.v.
 - **Mô hình sinh (Generative model):** Xem sự lan truyền như một chuỗi các sự kiện theo thời gian (Methods: Poisson Process, Survival Analysis, Hawkes Process, Epidemic Model).
 - **Hawkes Process:** Một mô hình điểm ngẫu nhiên, nơi một sự kiện có thể làm tăng xác suất xảy ra các sự kiện khác trong tương lai gần (tương tự như các "aftershock" sau một trận động đất, hoặc các lượt retweet sau một tweet ban đầu).
 - **Mô hình học sâu (Deep learning based):** Không cần giả định về quá trình lan truyền, có thể xử lý dữ liệu đa phương thức với các module khác nhau.
 - **Mô hình dịch tễ học:** SIS, SIR, SEIR và các biến thể.
 - **SIR model:** Chia dân số thành 3 nhóm: Susceptible (Có thể nhiễm), Infected (Đã nhiễm), và Recovered (Đã hồi phục). Đây là một mô hình dịch tễ học cơ bản nhưng rất mạnh mẽ.

7.2.4. Productivity and Team Science

- **Các thành phần của một đội:** (1) *Trưởng nhóm và thành viên*, (2) *Môi trường làm việc*, (3) *Nhiệm vụ mà nhóm làm việc*.
- **Các câu hỏi nghiên cứu:**
 - **Đặc điểm hóa hiệu suất:** Tìm ra các mẫu phân biệt một đội hiệu suất cao và một đội kém hiệu quả.
 - **Dự đoán hiệu suất:** Dự báo hiệu suất của đội trước hoặc ngay sau khi bắt đầu nhiệm vụ.
 - **Tối ưu hóa hiệu suất:** Cải thiện hiệu suất bằng cách điều chỉnh thành phần của đội.
 - **Giải thích hiệu suất:** Diễn giải các kết quả dự đoán và tối ưu hóa một cách trực quan.
- Đây là lĩnh vực áp dụng khoa học dữ liệu vào quản lý nhân sự và tổ chức. Mục tiêu là đưa ra các quyết định dựa trên dữ liệu thay vì chỉ dựa vào trực giác.
- **Các bài toán:**
 - **Team performance characterization (Đặc điểm hóa hiệu suất):**
 - Thành viên có kỹ năng và mối quan hệ xã hội khác nhau.
 - Nhiệm vụ đa dạng phụ thuộc vào các ngữ cảnh.
 - Môi trường lớn, nhiễu, không đầy đủ.
 - Treat as **outcome of collective intelligence** from both **virtual teams and teams with face-to-face interactions**.
 - **Team performance prediction (Dự đoán hiệu suất)**
 - Xác định các đặc trưng quan trọng.
 - Mô hình hóa mối tương quan giữa các đặc trưng và hiệu suất.
 - Mã hóa sự phát triển của đội theo thời gian.
 - Dự đoán tác động của nội dung mà nhóm sản xuất ở mức độ chi tiết hơn.

- **Tối ưu hóa hiệu suất:**
 - Tối ưu hóa thành phần đội (thêm/bớt/thay thế thành viên).
 - Các yếu tố xem xét: Kỹ năng, kết nối mạng lưới.
 - Generalizations: team shrinkage (thu hẹp), team expansion, team conflict resolution (giải quyết xung đột), real-time team optimization, etc.
 - "Tối ưu hóa đội" giống như bài toán của một huấn luyện viên thể thao: chọn ra đội hình tốt nhất từ một nhóm cầu thủ.
- **Giải thích hiệu suất:**
 - Còn ít nghiên cứu về việc giải thích trực quan về hiệu suất của nhóm.
 - Sử dụng "hàm ảnh hưởng" (influence function) để xác định các yếu tố quan trọng.
 - Interpret from multiple levels.
- Hiệu suất của một đội là một khái niệm phức tạp, bị ảnh hưởng bởi nhiều yếu tố tương tác với nhau. Việc mô hình hóa điều này rất khó khăn.

7.3. Data Mining Methodologies And Systems (Các phương pháp và hệ thống khai phá dữ liệu)

7.3.1. Structuring Unstructured Data for Knowledge Mining: A Data-Driven Approach

- **Taxonomy construction and refinement**
 - **Taxonomy là gì:** Tổ chức các khái niệm quan trọng thành các cấu trúc có ngữ nghĩa phong phú (cây phân cấp).
 - Đóng một vai trò thiết yếu trong việc tổ chức dữ liệu văn bản phi cấu trúc khổng lồ thành các cấu trúc tương đối có tổ chức
 - **Các thuộc tính phân loại:** Đa diện (multi-faceted), phụ thuộc vào kho dữ liệu và ứng dụng (corpus- and application-dependent).
 - **Tạo và mở rộng taxonomy:** Dùng các phương pháp học có giám sát yếu, mở rộng tập hợp (set expansion), phân cụm phân cấp dựa trên embedding, Thêm các thuật ngữ mới nổi hoặc xóa các thuật ngữ cũ, lỗi thời.
- **Weakly supervised text classification (Phân loại văn bản khi có rất ít dữ liệu được gán nhãn)**
 - **Ý tưởng #1:**
 - Dùng embedding để tạo ra các "tài liệu giả" (pseudo documents) để huấn luyện mô hình.
 - Huấn luyện mạng nơ-ron dựa trên các "tài liệu giả" và dữ liệu văn bản không được gán nhãn.
 - **Ý tưởng #2:** Tạo ra các từ khóa hoặc cụm từ đặc trưng cho mỗi lớp bằng category-guided embedding.
 - **Ý tưởng #3:** Dùng các mô hình ngôn ngữ tiền huấn luyện để tạo ra các từ khóa đặc trưng cho lớp.
 - Học có giám sát yếu (Weakly supervised learning) là một giải pháp cho vấn đề thiếu dữ liệu có nhãn. Nó tận dụng các tín hiệu "yếu" hơn, ví dụ như chỉ cần một vài từ khóa cho mỗi danh mục, thay vì hàng nghìn tài liệu được gán nhãn đầy đủ.
 - Các kỹ thuật như Snorkel của Stanford là một framework nổi tiếng để xây dựng các ứng dụng học máy có giám sát yếu bằng cách cho phép người dùng viết các "hàm gán nhãn" (labeling functions) thay vì gán nhãn thủ công.

- **Fine-grained information extraction (Trích xuất thông tin chi tiết)**
 - Đây là một bước tiến so với trích xuất thông tin thông thường, cung cấp một sự hiểu biết chi tiết và cụ thể hơn về các thực thể trong văn bản.
 - **Nhận dạng thực thể chi tiết (Fine-grained entity recognition):**
 - Extract the concrete role that an entity plays in a particular context (*Trích xuất vai trò cụ thể của một thực thể trong một bối cảnh cụ thể*)
 - Không chỉ xác định "Paris" là một "Địa điểm", mà còn là một "Thành phố", "Thủ đô".
 - Xác định bối cảnh của một thực thể:
 - Tạo ứng cử viên đề cập thực thể và cụm từ quan hệ
 - Tìm các loại chi tiết thích hợp nhất cho các thực thể cần kiểm tra
 - **Phương pháp:** Giám sát từ xa (distant supervision), dựa trên embedding, giám sát có hướng dẫn bởi taxonomy và mô hình ngôn ngữ tiền huấn luyện.
- **Knowledge graph/information network construction**
 - **Biểu đồ tri thức (Knowledge graphs)**
 - Một **tập hợp các thực thể**
 - Một **tập hợp các cạnh (có thể được dán nhãn)** liên kết giữa các thực thể
 - Xây dựng đồ thị tri thức
 - Sử dụng giám sát từ xa hoặc yếu (distant or weak supervision)
 - Phân loại văn bản có hướng dẫn phân loại
 - Các vấn đề khi xây dựng đồ thị tri thức
 - Một thực thể có thể được liên kết với các thuộc tính/giá trị khác nhau
 - Dễ gây nhầm lẫn **nếu các liên kết khác nhau được hợp nhất thành một biểu đồ tri thức duy nhất**
 - Giải pháp
 - Xây dựng đồ thị tri thức cục bộ (local knowledge graphs)
 - Sử dụng các biểu đồ tri thức cục bộ như vậy trong các điều kiện tương tự


7.3.2. Data Augmentation (Tăng cường dữ liệu)

- **Why do we need data augmentation?** Các mô hình cần nhiều dữ liệu có nhãn để huấn luyện, nhưng dữ liệu này thường khan hiếm.
 - Huấn luyện với dữ liệu ít có thể dẫn đến **overfitting** (mô hình học thuộc lòng dữ liệu huấn luyện và hoạt động kém trên dữ liệu mới).
- **Làm thế nào?**
 - **Phương pháp cơ bản (cho ảnh):** Lật, xoay, cân bằng màu.
 - **Học chính sách tăng cường:** Tự động tìm ra sự kết hợp tốt nhất của các phép biến đổi.
 - **Dựa trên GANs:** Dùng mạng nơ-ron để sinh ra dữ liệu mới. Huấn luyện một mô hình để "sinh ra" dữ liệu mới trông giống như dữ liệu thật.
 - **Huấn luyện đối kháng:** Thêm nhiễu tinh vi để mô hình mạnh mẽ hơn.
- Tăng cường dữ liệu là một kỹ thuật cực kỳ hiệu quả để cải thiện hiệu suất của mô hình mà không cần tốn công thu thập và gán nhãn thêm dữ liệu. Nó giống như việc "dạy" cho mô hình về các biến thể có thể có của dữ liệu, giúp nó tổng quát hóa tốt hơn.

- Đối với dữ liệu văn bản, các kỹ thuật tăng cường có thể bao gồm thay thế từ đồng nghĩa, dịch ngược (dịch sang ngôn ngữ khác rồi dịch lại), hoặc thêm/xóa từ ngẫu nhiên.

7.3.3. From Correlation to Causality (Từ Tương quan đến Nhân quả)

- **Phân tích tương quan (Correlation analysis):** Nghiên cứu mối liên hệ thống kê giữa các biến (ví dụ: doanh số bán kem và số vụ chết đuối đều tăng vào mùa hè. Chúng có tương quan, nhưng không có nghĩa bán kem gây ra chết đuối).
- **Phân tích nhân quả (Causal analysis):** Nghiên cứu mối quan hệ nguyên nhân - kết quả (ví dụ: nhiệt độ tăng là nguyên nhân chung khiến cả hai việc trên xảy ra).
- **Các tác vụ:**
 - **Khám phá nhân quả (Causality discovery):** Tìm ra cấu trúc nhân quả từ dữ liệu, sử dụng thuật toán dựa trên ràng buộc, thuật toán dựa trên điểm số và mô hình nhân quả chức năng (constraint-based algorithms, score-based algorithms and functional causal models).
 - **Suy luận nhân quả (Causality inference):** Ước tính tác động nhân quả, dùng Điều chỉnh hồi quy, phương pháp điểm xu hướng và phương pháp cân bằng hiệp biến (Regression adjustment, propensity score methods and covariate balancing methods).
- Hầu hết học máy truyền thống chỉ dừng lại ở tương quan ("**A và B hay xảy ra cùng nhau**"). Suy luận nhân quả đi xa hơn để trả lời câu hỏi "Liệu A có gây ra B không?".
- Ví dụ kinh điển: Doanh số bán kem và số vụ tấn công của cá mập có tương quan cao. Nhưng nguyên nhân chung là thời tiết nóng, chứ không phải kem gây ra cá mập tấn công.
- **Lợi ích của phân tích nhân quả:**
 - Tăng khả năng diễn giải của các mô hình deep learning hộp đen.
 - Giúp tránh các kết quả không công bằng.
 - Cải thiện sự mạnh mẽ của mô hình.
- Hiểu được nhân quả giúp xây dựng các mô hình công bằng hơn. Ví dụ, một mô hình dự đoán khả năng tái phạm tội có thể tìm thấy tương quan giữa chủng tộc và tỷ lệ tái phạm. Nhưng đây là một tương quan sai lầm (spurious correlation) do các yếu tố nhiễu (confounders) như điều kiện kinh tế-xã hội. Phân tích nhân quả giúp xác định và loại bỏ các thiên vị này.
- **Phân loại các phương pháp khám phá và suy luận nhân quả.**




7.3.4. Network as a Context

- Mỗi nút trong một mạng có thể đại diện cho một thực thể phức tạp (một tập dữ liệu, một mô hình khai phá dữ liệu).
- **Mạng lưới của các chuỗi thời gian (Network of time series).**
 - Mỗi nút là một chuỗi thời gian (ví dụ: dữ liệu chứng khoán của một công ty).
 - Các cạnh biểu diễn mối quan hệ giữa các chuỗi (ví dụ: các công ty trong cùng một ngành).
 - Tận dụng mạng lưới ngữ cảnh này để cải thiện mô hình dự báo cho từng chuỗi thời gian riêng lẻ.
 - Thông tin từ các nút lân cận có thể giúp chúng ta hiểu rõ hơn về một nút cụ thể. Thay vì phân tích từng chuỗi thời gian một cách độc lập, chúng ta **phân tích chúng cùng nhau trong bối cảnh của mạng lưới quan hệ**. Kỹ thuật này tương tự như "học đa nhiệm" (multi-task learning), nơi việc học nhiều tác vụ liên quan cùng một lúc có thể cải thiện hiệu suất trên từng tác vụ riêng lẻ.
- **Mạng lưới của các mạng lưới (Network of networks).**
 - Mỗi nút tự nó là **một mạng lưới khác**.
 - Ưu điểm: Mã hóa rõ ràng cấu trúc phân cấp, cung cấp sự chính quy hóa bổ sung.
 - Đây là một mức độ trừu tượng hóa cao hơn. Ví dụ, một mạng lưới các thành phố, trong đó mỗi thành phố (nút) lại là một mạng lưới giao thông riêng.
 - Khái niệm này có thể được áp dụng để nghiên cứu sự tương tác giữa các hệ thống phức tạp, ví dụ như sự tương tác giữa mạng lưới tài chính và mạng lưới xã hội.
- **Mạng lưới của các mô hình khai phá dữ liệu (Network of data mining models).**
 - Mỗi nút là **một mô hình** học máy.
 - Các mô hình có thể "vay mượn" dữ liệu hoặc kiến thức từ nhau để cùng cải thiện hiệu suất.
 - **Future directions**
 - The contextual network construction (Xây dựng mạng theo ngữ cảnh)
 - Can be applied to more applications, e.g., knowledge graphs, heterogeneous networks (mạng không đồng nhất)
 - Integrate other data mining problems, e.g., adversarial learning, fairness, explainable learning (học đối nghịch, công bằng, học có thể giải thích).

7.3.5. Auto-ML: Methods and Systems

- **Tại sao cần Auto-ML?** Xây dựng mô hình học máy tốn thời gian, đòi hỏi chuyên môn cao, và các chuyên gia lĩnh vực có thể không rành về các mô hình.
- Auto-ML hướng tới việc "dân chủ hóa" AI, cho phép những người không phải là chuyên gia cũng có thể xây dựng và sử dụng các mô hình học máy hiệu quả. Nó tự động hóa các bước tẻ nhạt và tốn thời gian nhất trong một dự án khoa học dữ liệu.
- **Phân loại Auto-ML:**
 - **Kỹ thuật đặc trưng tự động (Automated Feature Engineering / Auto-FE):** Tự động tìm ra các đặc trưng tốt nhất (most representative and informative features) từ dữ liệu thô.
 - **Tinh chỉnh mô hình và siêu tham số tự động (Automated Model and Hyperparameter Tuning / Auto-MHT):** Tự động xây dựng các mô hình máy học và điều chỉnh siêu tham số tốt nhất cho chúng.

- Auto-ML nhằm mục đích tự động hóa quy trình khoa học dữ liệu, giúp nó dễ tiếp cận hơn và hiệu quả hơn. Nó xử lý các bước lặp đi lặp lại và tốn nhiều công sức nhất.
- **Thách thức chính:**
 - Thiếu các bộ dữ liệu chuẩn để đánh giá (The lack of authoritative benchmarks for Auto-FE and Auto-MHT).
 - Hiệu quả tính toán.
 - Cách kết hợp kiến thức hoặc kinh nghiệm của con người vào AutoML để tìm không gian con phù hợp của toàn bộ không gian tìm kiếm
 - Khả năng diễn giải.
 - Phạm vi ứng dụng.
- **Taxonomy of Auto-ML (Phân loại Auto-ML)**



- Tối ưu hóa Bayes (Bayesian Optimization) là một kỹ thuật rất phổ biến để tinh chỉnh siêu tham số vì nó hiệu quả hơn so với việc tìm kiếm ngẫu nhiên hoặc tìm kiếm lưới.


7.4. Data Mining, People and Society

7.4.1. Privacy-Preserving Data Mining (Khai phá dữ liệu bảo vệ quyền riêng tư)

- **Vấn đề:** Rò rỉ quyền riêng tư có thể xảy ra giữa **người dùng và chủ sở hữu dữ liệu** (ví dụ: tái nhận dạng người dùng từ dữ liệu ẩn danh) hoặc giữa **các chủ sở hữu dữ liệu với nhau** (ví dụ: các công ty muốn hợp tác phân tích nhưng không muốn chia sẻ dữ liệu khách hàng).
- **Các giải pháp:**
 - **k-anonymity (P. Samarath et al., 1998):** Một kỹ thuật ẩn danh hóa cơ bản, đảm bảo mỗi bản ghi trong dữ liệu không thể phân biệt được với ít nhất k-1 bản ghi khác.
 - **Differential Privacy (A. Machanavajjhala et al. 2006):** Một định nghĩa toán học chặt chẽ hơn về quyền riêng tư. Nó cho phép thực hiện phân tích trên tập dữ liệu trong khi đảm bảo rằng việc có hay không có dữ liệu của một cá nhân bất kỳ trong tập dữ liệu đó cũng không làm thay đổi đáng kể kết quả.
 - **Federated Learning (Học liên kết):** Một giải pháp cho vấn đề giữa các chủ sở hữu dữ liệu. Các mô hình được **huấn luyện cục bộ** trên dữ liệu của mỗi bên, và chỉ có các cập nhật của mô hình (Chỉ tổng hợp các kết quả, chứ không phải dữ liệu thô) được chia sẻ và tổng hợp lại mà không làm rò rỉ dữ liệu chi tiết. Phân loại: Học liên kết ngang (Horizontal) và dọc (Vertical).
 - Học liên kết là một giải pháp thanh lịch cho phép hợp tác mà không cần tập trung hóa dữ liệu. Điều này rất quan trọng trong các lĩnh vực nhạy cảm như y tế.
 - Tính năng gợi ý từ trên bàn phím Gboard của Google sử dụng Học liên kết để học từ cách bạn gõ mà không cần gửi những gì bạn gõ về máy chủ của Google.

7.4.2. Human-Algorithm Interaction (Tương tác giữa người và thuật toán)

- **Mục tiêu:** Tối ưu hóa sự hợp tác giữa trí tuệ con người và thuật toán, từ đó nâng cao hiệu suất hệ thống và trải nghiệm người dùng. Thay vì xem AI như một công cụ thay thế hoàn toàn con người, cách tiếp cận này xem AI và con người như những đối tác, mỗi bên có những điểm mạnh riêng.
- **Crowdsourcing (Thuê ngoài cộng đồng):** khai thác trí thông minh của con người, Tận dụng trí tuệ của đám đông để giải quyết các vấn đề khó (gán nhãn dữ liệu, đánh giá mô hình, đánh giá khả năng giải thích dự đoán, gỡ lỗi hệ thống AI, v.v.).
- **Human-in-the-loop (Con người trong vòng lặp):** Tận dụng sự can thiệp của con người để cải thiện thuật toán (tạo nhãn chất lượng cao để học có giám sát, nâng cao khả năng giải thích mô hình với kiến thức nền tảng, đánh giá mô hình, v.v.).
- **Machine-in-the-loop (Máy trong vòng lặp):** Thuật toán giúp cải thiện chiến lược truy vấn của con người bằng thuật toán (ví dụ: gợi ý trong viết lách sáng tạo).
- **Human-machine-teaming (Đội nhóm người-máy):** Thúc đẩy sự hợp tác hiệu quả giữa người và thuật toán.



(a) HMT Overview



(b) HMT for Cyber Defense

7.4.3. Mining beyond Maximizing Accuracy (Khai phá vượt ra ngoài việc tối đa hóa độ chính xác): Fairness, Interpretability, and Robustness

- **Công bằng thuật toán (Algorithm fairness):** Đảm bảo rằng các mô hình không đưa ra các quyết định thiên vị đối với các nhóm nhân khẩu học nhất định (dựa trên giới tính, chủng tộc, v.v.).
 - **Các loại Công bằng thuật toán**
 - **Công bằng nhóm (Group fairness):**
 - **Demographic parity (Tính tương đồng nhân khẩu học):** Dự đoán không phụ thuộc vào các thuộc tính nhạy cảm (ví dụ: tỷ lệ được chấp thuận cho vay là như nhau cho mọi chủng tộc).
 - **Equalized odds (Tỷ lệ cược cân bằng):** xác suất có điều kiện của cùng một kết quả dự đoán cho nhãn phải bằng nhau đối với các thuộc tính nhạy cảm khác nhau (Tỷ lệ dương tính thật và dương tính giả là như nhau giữa các nhóm).
 - **Predictive rate parity:** Tỷ lệ dự đoán đúng là như nhau giữa các nhóm.

- **Công bằng cá nhân (Individual fairness):** Những cá nhân tương tự nhau nên được đối xử tương tự.
- **Công bằng phản thực tế (Counterfactual fairness):** Dự đoán sẽ không thay đổi nếu thuộc tính nhạy cảm của một cá nhân thay đổi.
- Các định nghĩa công bằng này đôi khi mâu thuẫn với nhau. Việc đạt được một loại công bằng có thể làm giảm một loại công bằng khác. Đây là một lĩnh vực nghiên cứu rất phức tạp.
- **Các chiến lược để đạt được công bằng:**
 - **Tiền xử lý (Pre-processing):** Thay đổi dữ liệu huấn luyện để loại bỏ thiên vị.
 - **Tối ưu hóa trong quá trình huấn luyện:** Thêm các ràng buộc hoặc hàm phạt vào quá trình học của mô hình để khuyến khích sự công bằng.
 - **Hậu xử lý (Post-processing):** Điều chỉnh kết quả đầu ra của mô hình để đảm bảo công bằng.
- **Khả năng diễn giải (Interpretability):** Mục tiêu là giải thích được các quyết định của các mô hình "hộp đen" (như mạng nơ-ron sâu). Tại sao mô hình lại đưa ra dự đoán này?
 - **Cách làm:** Trực quan hóa thống kê, khám phá các thành phần có thể tự giải thích, xác định các điểm dữ liệu quan trọng.
- **Sự mạnh mẽ (Robustness):** Đảm bảo mô hình hoạt động ổn định và không bị "đánh lừa" bởi các nhiễu nhỏ hoặc các cuộc tấn công đối kháng (adversarial attacks).
 - **Phương pháp phản ứng (Reactive methods):** phát hiện các ví dụ đối nghịch sau khi mô hình được xây dựng.
 - **Phương pháp chủ động (Proactive methods):** làm cho các mô hình khai thác mạnh mẽ hơn trước các cuộc tấn công
- Một mô hình có độ chính xác 99% nhưng lại luôn sai với một nhóm thiểu số nào đó thì không phải là một mô hình tốt. Tương tự, một mô hình mà chúng ta không thể giải thích được quyết định của nó có thể rất nguy hiểm khi áp dụng trong các lĩnh vực quan trọng như y tế hay tài chính. Phần này nhấn mạnh rằng độ chính xác chỉ là một trong nhiều thước đo của một mô hình học máy tốt.
- Lĩnh vực "AI có thể giải thích được" (Explainable AI - XAI) đang phát triển nhanh chóng với các kỹ thuật như LIME và SHAP, giúp làm sáng tỏ cách các mô hình phức tạp đưa ra quyết định.

7.4.4. Data Mining for Social Good (Khai phá dữ liệu vì lợi ích xã hội)

- **Ứng dụng:** Trình bày một bảng các ứng dụng của khai phá dữ liệu trong các lĩnh vực như giáo dục, y tế công cộng, chống thông tin sai lệch, quy hoạch đô thị, an toàn công cộng và giao thông, cùng với các kỹ thuật chính được sử dụng.

Applications	Key Data Mining Techniques
Education	Random Forests Logistic Regressions
Public Health	Long-Short Term Memory (LSTM) Auto-Encoder Deep Clustering
Combating Information Manipulation	SVM with RBF Kernel Function Markov Random Field (MRF) Graph Attention Network (GAT)
Social Care and Urban Planning	Gradient Boosting Decision Trees AdaBoost Transfer Learning
Public Safety	Generalized Linear Model (GLM) Naive Bayes (NB)
Transportation	Demand and Supplier Modeling Multi-agent Reinforcement Learning

- **Thách thức:**
 - **Thiếu dữ liệu (Data scarcity):** Dữ liệu trong các lĩnh vực xã hội thường khó thu thập và có quy mô nhỏ.
 - **Đánh giá:** Các thước đo tiêu chuẩn (như độ chính xác) có thể không phản ánh đúng tác động trong thế giới thực.
 - **Sự tham gia của con người (Human-in-the-loop):** Chưa tận dụng hết kiến thức chuyên môn từ các chuyên gia trong lĩnh vực.
 - **Triển khai bền vững:** Làm thế nào để duy trì và phát triển các giải pháp sau khi dự án kết thúc.
- Tuy nhiên, nó cũng chỉ ra rằng việc áp dụng AI trong các bối cảnh này khó khăn hơn nhiều so với trong môi trường thương mại, đòi hỏi sự hợp tác chặt chẽ với các chuyên gia và một cách tiếp cận bền vững.