

CHAPTER 1: INTRODUCTION TO DATA MINING

Mục lục


1.1. Khám phá Tri thức từ (cơ sở) dữ liệu - Knowledge Discovery in Data(base) (KDD)	1
1.1.1. Khái niệm	1
1.1.2. DIKW model	2
1.1.2. Quá trình Khám phá Tri thức từ Dữ liệu	4
1.2. Quá trình Khai thác Dữ liệu	6
1.2.1. What is data mining?	6
1.2.2. Các chức năng/ nhiệm vụ của KTDL	8
1.2.3. Các tác vụ chính của KTDL	9
1.2.3.1. Predictive Modeling (Mô hình dự đoán)	9
1.2.3.2. Association Analysis (Phân tích kết hợp)	10
1.2.3.3. Cluster Analysis (Phân tích phân cụm)	11
1.2.3.4. Anomaly Detection (Phát hiện bất thường)	13
1.2.4. Một số kỹ thuật chính trong KTDL	13
1.2.5. Đánh giá Tri thức đã khai thác	14
1.2.6. Các quy trình Khai thác Dữ liệu	15

1.1. Khám phá Tri thức từ (cơ sở) dữ liệu - Knowledge Discovery in Data(base) (KDD)

1.1.1. Khái niệm

- Quá trình không tầm thường để **xác định các mẫu tiềm ẩn** **hợp lệ, mới lạ, hữu ích** và **có thể hiểu được** bởi người dùng.
- Quá trình sử dụng CSDL cùng với kỹ thuật lựa chọn, tiền xử lý, lấy mẫu và chuyển đổi; áp dụng các phương pháp (thuật toán) KTDL để **liệt kê các mẫu từ CSDL** đó; và **đánh giá các sản phẩm** từ quá trình KTDL này và *xác định tập hợp con các mẫu* đã được liệt kê thể hiện **tri thức** hữu ích
- Ví dụ mẫu tiềm ẩn:
 - Người đàn ông mua quần tây thường sẽ mua thêm áo sơ mi
 - Những người có mức tín dụng tốt thì thường ít bị tai nạn
 - Người đàn ông trên 37 tuổi, thu nhập 50K-75\$ thường chi khoảng 25-50% cho việc đặt mua hàng qua catalog


1.1.2. DIKIW model



- Một hệ thống phân cấp thể hiện quá trình **chuyển đổi từ dữ liệu thô thành trí tuệ**.
 - Data (Dữ liệu):** Các **sự kiện**, **con số rời rạc**, **chưa được xử lý và chưa có ngữ cảnh** (được minh họa bằng các chấm tròn ngẫu nhiên).
 - Information (Thông tin):** Khi dữ liệu được **tổ chức, cấu trúc và gán ngữ cảnh**, nó trở thành thông tin (các chấm được phân loại theo màu sắc).
 - Knowledge (Tri thức):** Là sự hiểu biết về các mẫu và **mối liên hệ** trong thông tin (các điểm thông tin được kết nối thành một mạng lưới).
 - Insight (Sự thấu hiểu):** Là khả năng **nhận ra các mẫu hoặc mối quan hệ quan trọng, có ý nghĩa** trong khối tri thức đó (một vài kết nối quan trọng được làm nổi bật).
 - Wisdom (Sự khôn ngoan/Trí tuệ):** Là cấp độ cao nhất, thể hiện khả năng áp dụng tri thức và sự thấu hiểu để đưa ra các quyết định đúng đắn.
- Phần bên trái nghiêng về việc **ghi nhận những gì đã xảy ra**. Ví dụ: “Doanh thu tháng 9 là 100 triệu” → đó là thông tin về **quá khứ**, nó chỉ mô tả, không dự đoán.
- Phần bên phải thiên về **dự báo và định hướng hành động cho tương lai**. Ví dụ: “Nếu quảng cáo nhấn vào Valentine thì doanh thu sẽ tăng” → đây là insight hướng tới **tương lai**.
- “Triển khai chiến dịch marketing vào tháng 2” → wisdom biến tri thức thành hành động để đạt kết quả trong **tương lai**.
- Decision Risk (Rủi ro ra quyết định) thể hiện bởi** thanh màu từ đỏ (trái) sang xanh (phải):
 - Ở tầng **Data, Information**: ra quyết định dựa trên dữ liệu thô, chưa phân tích → **rủi ro cao** (màu đỏ).
 - Lên **Knowledge**: đã có quy luật, xu hướng → rủi ro giảm.
 - Tới **Insight và Wisdom**: hiểu sâu, áp dụng vào hành động có cơ sở → **rủi ro thấp** (màu xanh).
- Ví dụ về DIKIW:** Một cửa hàng bán trang sức online
 - Data (Dữ liệu thô):** Hàng ngày hệ thống ghi lại: Thời gian mua hàng, Mã sản phẩm, Giá bán, Khách hàng (ID, khu vực), Số lượng mua 🖱️ Đây chỉ là “các con số” chưa nói lên điều gì.

- **Information (Thông tin):** Từ dữ liệu trên, ta tạo báo cáo: Doanh thu theo ngày/tháng, Sản phẩm nào bán chạy nhất, Khách hàng chủ yếu đến từ TP.HCM... 🖱️ Thông tin này dễ đọc, dễ phân tích hơn dữ liệu thô.
- **Knowledge (Tri thức):** **Phân tích sâu, tìm ra quy luật:** Nhấn kim cương bán chạy vào dịp Valentine và 8/3, Khách hàng nữ 25–35 tuổi mua nhiều trang sức vàng hơn nhóm khác. 🖱️ Đây là hiểu biết có thể **giải thích được xu hướng**.
- **Insight (Hiểu biết sâu):** Nhìn ra **cơ hội mới** từ tri thức: Nếu chạy quảng cáo nhấn kim cương 2 tuần trước Valentine thì doanh thu tăng mạnh; Nếu giới thiệu sản phẩm vàng mini giá rẻ hơn, có thể thu hút sinh viên... 🖱️ Đây là “ngộ ra ý tưởng mới”, vượt trên tri thức thuần túy.
- **Wisdom (Trí tuệ):** **Ra quyết định** hành động thực tế: Lập chiến dịch marketing Valentine tập trung vào nhấn; Tạo bộ sưu tập vàng mini cho khách hàng trẻ... 🖱️ Đây chính là **áp dụng tri thức + insight vào thực tế** để mang lại hiệu quả kinh doanh.
- **Phân tích:**
 - **DIK và data mining:** Data mining tập trung vào việc *xử lý dữ liệu thô (Data) để tạo ra thông tin (Information) và kiến thức (Knowledge)* thông qua các kỹ thuật như **phát hiện mẫu, phân loại, hoặc clustering**. Đây là **một phần cốt lõi của quy trình KDD** (Knowledge Discovery in Databases), nơi data mining đóng vai trò chính trong việc chuyển đổi từ Data sang Knowledge.
 - **IW và data science:** Data science bao quát hơn, *bao gồm không chỉ data mining mà còn các kỹ thuật như machine learning, thống kê nâng cao, và phân tích* để tạo ra Intelligence (insights hành động được, như dự đoán hoặc tối ưu hóa) và Wisdom (quyết định chiến lược dựa trên bối cảnh). **Data science thường xử lý toàn bộ chuỗi DIKIW, từ dữ liệu thô đến trí tuệ thực tiễn.**
 - Data mining là một phần của data science, nên DIK là nền tảng chung cho cả hai. Tuy nhiên, **data science mở rộng sang IW bằng cách áp dụng kiến thức vào các bài toán thực tế**, như xây dựng mô hình dự đoán (Intelligence) hoặc ra quyết định chiến lược (Wisdom).

1.1.2. Quá trình Khám phá Tri thức từ Dữ liệu



- **KDD Process từ góc nhìn quản trị dữ liệu doanh nghiệp**


- **7 bước của Quá trình Khám phá tri thức:**

- **Data cleaning:** **Làm sạch** dữ liệu nhiễu, thiếu, ...
- **Data integration:** **tích hợp dữ liệu từ nhiều nguồn** (dữ liệu chồng lấn, dư thừa, định dạng khác nhau,...)
- **Data selection:** **chọn lọc** dữ liệu phù hợp (effectiveness và efficiency), loại bỏ thuộc tính (dư thừa, không ý nghĩa), ...
- **Data transformation:** **chuyển đổi** dữ liệu cùng định dạng, miền giá trị
- **Data mining:** **rút trích** các mô hình, các mẫu chứa tri thức.
- **Pattern Evaluation:** đánh giá tính hợp lệ, tính mới, tính hữu dụng, ... của các mẫu
- **Pattern Presentation:** biểu diễn, trực quan hóa các mẫu tri thức

- **5 thành phần chính của Quá trình Khám phá tri thức:**

- **Data sources:** Dữ liệu ban đầu
 - Internal data source hoặc External data source
 - Nhiều định dạng khác nhau, các DBMS khác nhau
- **Data Warehouse:** Kho dữ liệu tích hợp dữ liệu từ nhiều nguồn khác nhau
- **Task-relevant Data:** Bộ dữ liệu sẵn sàng cho khai phá – **Dữ liệu sau khi tiền xử lý** (pre-processing: cleaning, integration, selection, transformation)
- **Pattern:** Các **mẫu (kết quả)** khám phá được
- **Knowledge:** Các **mẫu (kết quả)** đã được đánh giá, xử lý để biểu diễn dưới dạng tri thức có thể hiểu biết được và diễn giải rõ ràng được bởi người dùng, phục vụ việc ra quyết định.

- **KDD Process – Machine Learning & Statistics view**




- **Data Pre-processing (Tiền xử lý dữ liệu):** Đây là bước làm sạch và chuẩn bị dữ liệu. Các kỹ thuật gồm:
 - *Data integration*: tích hợp dữ liệu từ nhiều nguồn.
 - *Normalization*: **chuẩn hóa** (ví dụ: chuyển tất cả giá trị tiền tệ về cùng đơn vị).
 - *Feature selection*: chọn đặc trưng quan trọng, bỏ bớt cột dư thừa.
 - *Dimension reduction*: **giảm chiều dữ liệu** (ví dụ PCA) để dễ khai phá.

👉 Kết quả: dữ liệu “sạch” và “chuẩn” để đưa sang khai phá.
- **Data Mining (Khai phá dữ liệu):** Đây là **trái tim của KDD**, áp dụng thuật toán để phát hiện mẫu (pattern):
 - *Pattern discovery*: phát hiện **mẫu ẩn** trong dữ liệu.
 - *Association & correlation*: **tìm mối liên hệ** (ví dụ: khách mua nhẵn thì hay mua dây chuyền).
 - *Classification*: **phân loại** (ví dụ: phân loại khách hàng tiềm năng vs. không tiềm năng).
 - *Clustering*: **gom nhóm** (ví dụ: nhóm khách mua cao cấp vs. khách mua bình dân).
 - *Outlier analysis*: **phát hiện bất thường** (ví dụ: giao dịch gian lận).

👉 Kết quả: có được các **pattern, mô hình, quy luật**.
- **Post-Processing (Hậu xử lý):** Sau khi có kết quả mining, cần **đánh giá và diễn giải**:
 - *Pattern evaluation*: đánh giá độ chính xác, độ tin cậy.
 - *Pattern selection*: chọn ra mẫu quan trọng, bỏ nhiều.
 - *Pattern interpretation*: diễn giải kết quả sao cho dễ hiểu với con người.
 - *Pattern visualization*: trực quan hóa bằng biểu đồ, dashboard.

👉 Kết quả: **Information và Knowledge** hữu ích.

- **CRISP-DM (Cross-Industry Standard Process for Data Mining)** - Quy trình chuẩn liên ngành cho Khai phá dữ liệu.




- **Obtain and explore data (Thu thập và khám phá dữ liệu):** Hiểu bài toán, **thu thập dữ liệu ban đầu và tìm hiểu sơ bộ** về dữ liệu.
- **Data preprocessing (Tiền xử lý dữ liệu):** **Làm sạch, định dạng và chuẩn bị** dữ liệu cho các mô hình.
- **Data Mining (Khai phá dữ liệu):** Lựa chọn và áp dụng các kỹ thuật **mô hình hóa**.
- **Postprocessing (Hậu xử lý/Đánh giá):** Đánh giá mô hình xem có đáp ứng được mục tiêu không.
- **Knowledge applied from mining is utilized (Áp dụng tri thức):** Triển khai mô hình vào thực tế để sử dụng.

1.2. Quá trình Khai thác Dữ liệu

1.2.1. What is data mining?

- **Cách hiểu đơn giản:**
 - Data mining = tìm ra được **“diamond”** trong data
 - Ví dụ:
 - Bộ DL về gen → diamond = dữ liệu về người bị UT
 - Bộ DL về điểm KTDL → Diamond = dữ liệu về SV có điểm cao nhất của môn học...
- Data mining is the use of **efficient techniques** for the **analysis** of **very large collections** of data and the **extraction** of **useful** and possibly **unexpected patterns** in data.
- **Khai thác dữ liệu ~ Khám phá tri thức**
- Tập hợp các công nghệ, quy trình và phương pháp phân tích được kết hợp với nhau để **khám phá những hiểu biết về dữ liệu** có thể được sử dụng để **hỗ trợ đưa ra quyết định tốt hơn**.
- Kết hợp số liệu thống kê, trí tuệ nhân tạo và máy học để **tìm ra các mẫu, mối quan hệ và sự bất thường** trong các tập dữ liệu lớn.
- Tìm các **mối quan hệ và mẫu** trong dữ liệu hiện tại, sau đó **áp dụng chúng cho dữ liệu mới để dự đoán xu hướng trong tương lai** hoặc **phát hiện sự bất thường**, chẳng hạn như gian lận.
- “Data mining is the **analysis** of (often large) observational data sets to **find unsuspected relationships** and to **summarize** the data in novel ways that are both **understandable and useful** to the data analyst” (Hand, Mannila, Smyth)
- “Data mining is the **discovery of models** for data” (Rajaraman, Ullman). We can have the following types of models

- Models that **explain** the data (e.g., a single function)
- Models that **predict** the future data instances.
- Models that **summarize** the data
- Models the **extract** the most prominent **features** of the data.
- **Why do we need data mining?**
 - Really, really huge amounts of raw data!!
 - Need to analyze the data to **extract knowledge**
- **Nguồn gốc của Khai phá dữ liệu**
 - Bắt nguồn từ các ý tưởng của *Machine Learning/AI*, *Pattern Recognition* (nhận dạng mẫu), *Statistics* (thống kê) và các hệ cơ sở dữ liệu, được hỗ trợ bởi *Database Technology*, *Parallel Computing*, *Distributed Computing* → dùng kỹ thuật hiện đại để vượt qua giới hạn của phân tích truyền thống khi dữ liệu ngày càng đồ sộ và phức tạp.



- Các kỹ thuật truyền thống (ví dụ thống kê cổ điển) có thể không phù hợp do dữ liệu hiện nay có đặc điểm:
 - **Large-scale**: quy mô lớn (Big Data)
 - **High-dimensional**: nhiều chiều (nhiều thuộc tính, biến số)
 - **Heterogeneous**: dị thể (nhiều loại dữ liệu khác nhau: số, văn bản, hình ảnh, tín hiệu...)
 - **Complex**: phức tạp, nhiều quan hệ chồng chéo
 - **Distributed**: phân tán (dữ liệu nằm ở nhiều hệ thống, nhiều nơi)
- Là một **thành phần quan trọng** của lĩnh vực **khoa học dữ liệu** (Data Science), mang tính **khám phá tri thức từ dữ liệu** (data-driven discovery). Đây chính là cầu nối giữa “dữ liệu” và “tri thức hữu ích để ra quyết định”.
- **Phân biệt Data Analysis & Data Mining**
 - **Analysis (Phân tích dữ liệu)**
 - **Định nghĩa**: quá trình **kiểm tra dữ liệu** để rút ra thông tin hữu ích, mẫu, xu hướng, hỗ trợ ra quyết định.
 - **Mục tiêu**: trả lời các câu hỏi “Cái gì đã xảy ra?”, “Xu hướng hiện tại là gì?”.
 - **Cách làm**: thường dùng **thống kê, biểu đồ, báo cáo BI** (Business Intelligence).
 - **Ví dụ**:
 - Doanh thu tháng 9 là 100 triệu.
 - Doanh thu tháng 9 tăng 15% so với tháng 8.
 - 👉 Phân tích thường tập trung vào **hiện tại và quá khứ**, có tính mô tả (descriptive).


- **Mining (Khai phá dữ liệu – Data Mining)**
 - **Định nghĩa:** quá trình tìm ra **mẫu ẩn, mối quan hệ, insight chưa rõ ràng** từ dữ liệu lớn.
 - **Mục tiêu:** phát hiện cái “**chưa nhìn thấy** ngay”, từ đó **dự đoán hoặc gợi ý** hành động.
 - **Cách làm:** dùng **thuật toán máy học, thống kê tiên tiến, AI** (clustering, classification, association rule, anomaly detection).
 - **Ví dụ:**
 - Khách mua nhẫn kim cương thường mua thêm dây chuyền vàng.
 - Gom khách hàng thành 3 nhóm: cao cấp, trung cấp, bình dân.
 - Dự đoán khách nào có khả năng rời bỏ dịch vụ.
- 👉 Mining thường tập trung vào **khám phá, dự đoán, insight mới**, vượt xa mô tả đơn thuần.

1.2.2. Các chức năng/ nhiệm vụ của KTDL

- **Generalization – Khái quát dữ liệu**
 - **Data characterization (Đặc trưng hóa dữ liệu):** tóm tắt các đặc điểm chung của một lớp dữ liệu đối tượng. Đầu ra có thể được thể hiện dưới nhiều hình thức (data cube, ...).
 - **Data discrimination (Phân biệt dữ liệu):** so sánh các đặc điểm chung giữa các đối tượng dữ liệu của lớp mục tiêu với các đối tượng từ một hoặc một tập hợp các lớp tương phản.
- **Association and Correlation Analysis – Phân tích tương quan và luật kết hợp:** Phân tích tập hợp các items thường xuất hiện cùng nhau trong tập dữ liệu
 - Các mẫu phổ biến hoặc tập phổ biến: Những mặt hàng nào thường được mua cùng nhau?
 - Các liên kết, quan hệ tương quan, nhân quả
 - Luật kết hợp điển hình: Tã → Bia [0,5%, 75%] (support, confidence)
- **Classification and Prediction – Phân lớp và Dự báo**
 - Xây dựng các mô hình (hàm) mô tả dựa trên phân tích tập dữ liệu huấn luyện.
 - Phân biệt các lớp hoặc khái niệm để phân lớp một đối tượng mới.
 - Các bài toán dự đoán những giá trị chưa biết hoặc bị thiếu.
- **Cluster Analysis – Gom cụm**
 - **Unsupervised learning** (học không giám sát), nhãn lớp không xác định.
 - Phân chia các phần tử dữ liệu thành các cụm (cluster) theo một tiêu chí nào đó.
 - **Nguyên tắc:** **Tối đa hóa mức độ tương đồng (similarity) giữa các phần tử trong cụm và tối thiểu hóa mức độ tương đồng giữa phần tử khác cụm**
- **Outlier Analysis – Phân tích mẫu cá biệt, bất thường**
 - Mẫu cá biệt, bất thường: đối tượng dữ liệu **không tuân theo các quy luật chung** của các đối tượng dữ liệu **trong cùng một không gian**
 - Là đối tượng nghiên cứu trong việc phát hiện gian lận, phân tích các sự kiện hiếm gặp, điều tra tội phạm,...
 - Phương pháp: clustering, regression,...
- **Trend and evolution analysis – Phân tích xu thế phát triển**
 - Phân tích xu thế, chuỗi thời gian (time-series). VD: hồi quy, dự đoán giá trị, ...
 - Tìm mẫu tuần tự (Sequential pattern mining). VD: mua máy ảnh, sau đó sẽ mua thẻ nhớ

- Phân tích dự báo (Periodicity analysis)
- Phân tích dựa trên sự tương đồng (Similarity-based analysis)
- **Structure and Network Analysis – Phân tích cấu trúc và mạng**
 - Khai thác đồ thị (Graph mining). VD: Tìm các đồ thị con phổ biến, cây (XML), ...
 - Information network analysis. VD: Mạng xã hội: tác nhân (đối tượng, nút) và mối quan hệ (cạnh)
 - Web mining. VD: Web community discovery, opinion mining, ...

1.2.3. Các tác vụ chính của KTDL




1.2.3.1. Predictive Modeling (Mô hình dự đoán)

- Ý nghĩa: **Xây dựng mô hình để dự đoán giá trị** của một biến mục tiêu (target variable) dựa trên một hàm của các biến giải thích/biến độc lập (explanatory variables).
- **Task này có 2 loại:**
 - **Classification (phân loại)** → dùng cho các biến mục tiêu **rời rạc** (discrete target variables).
 - Cho một tập dữ liệu huấn luyện (training set) gồm nhiều bản ghi (record). Mỗi bản ghi có nhiều thuộc tính (attributes). Một trong các thuộc tính là **class** (nhãn, loại, category) → Bài toán classification là **tìm ra một mô hình (model) biểu diễn quan hệ giữa các thuộc tính đầu vào và thuộc tính class**.
 - **Mục tiêu:** Khi gặp một bản ghi mới (chưa thấy trước đó), mô hình phải dự đoán chính xác nó thuộc class nào.
 - **Classification = tạo một mô hình có thể dự đoán một đặc tính (class/label) của dữ liệu dựa trên các đặc tính khác.**

- Ví dụ:
 - Chẩn đoán bệnh
 - Thuộc tính: kết quả xét nghiệm, huyết áp, tuổi...
 - Class: "Bệnh A", "Bệnh B", hoặc "Khỏe mạnh".
 - Mục tiêu: dự đoán bệnh của bệnh nhân mới.
 - Phân loại hoa Iris (ví dụ kinh điển)
 - Thuộc tính: chiều dài cánh hoa, chiều rộng cánh hoa...
 - Class: "Setosa", "Versicolor", "Virginica".
 - Mục tiêu: dự đoán loài hoa.

Model for predicting credit worthiness



- Regression (hồi quy) → dùng cho các biến mục tiêu liên tục (continuous target variables).
 - Regression là dự đoán một giá trị số liên tục dựa trên các biến đầu vào.
 - Nói cách khác: bạn muốn biết “nó có giá trị bao nhiêu?”, chứ không phải nó thuộc nhóm nào.
 - Ví dụ: Dự đoán doanh số bán hàng của sản phẩm mới dựa vào chi phí quảng cáo. (Chi phí quảng cáo ↑ → Doanh số ↑ theo một quan hệ nào đó); Dự đoán vận tốc gió dựa trên nhiệt độ, độ ẩm, áp suất không khí.
 - Có thể dùng mô hình tuyến tính (linear) hoặc phi tuyến (nonlinear) để mô tả mối quan hệ.
 - Regression được nghiên cứu nhiều trong thống kê và mạng nơ-ron (machine learning).
- Mục tiêu: Giảm sai số giữa giá trị dự đoán và giá trị thật.
- Ứng dụng: Marketing (dự đoán khách hàng phản hồi), môi trường (dự đoán biến động khí hậu), y tế (chẩn đoán bệnh từ kết quả xét nghiệm).

1.2.3.2. Association Analysis (Phân tích kết hợp)

- Ý nghĩa: Khám phá các mẫu (patterns) cho thấy mối quan hệ mạnh giữa các thuộc tính.
- Biểu diễn: Dạng luật kéo theo (implication rules), ví dụ: {Diapers} → {Milk}: khách mua bỉm thường mua thêm sữa.

○ Example Application

- Supermarket shelf management.
 - **Goal:** To **identify items that are bought together by sufficiently many customers.**
 - Approach: Process the point-of-sale data collected with barcode scanners to find dependencies among items.
- **A classic rule**
 - If a customer buys diaper and milk, then he is very likely to buy beer.
 - So, don't be surprised if you find six-packs stacked next to diapers!
 - → **supermarket will set beer near milk.**

<i>TID</i>	<i>Items</i>
1	Bread, Coke, Milk
2	Beer, Bread
3	Beer, Coke, Diaper, Milk
4	Beer, Bread, Diaper, Milk
5	Coke, Diaper, Milk

Itemsets Discovered:

{Milk, Coke}
{Diaper, Milk}


Rules Discovered:

{Milk} --> {Coke}
{Diaper, Milk} --> {Beer}


- Do kích thước không gian tìm kiếm tăng theo cấp số nhân, mục tiêu của tác vụ này là trích xuất "interesting patterns" một cách hiệu quả.
- **Ứng dụng:**
 - Market Basket Analysis (phân tích giỏ hàng siêu thị).
 - Nhóm gene có chức năng liên quan.
 - Phân tích hành vi người dùng trên web.
 - Quan hệ trong hệ sinh thái.

1.2.3.3. Cluster Analysis (Phân tích phân cụm)


- **Ý nghĩa:** Gom nhóm các đối tượng sao cho **cùng nhóm thì giống nhau (có liên quan)** hơn so với đối tượng ở nhóm khác.
- **Similarity Measures?**
 - Euclidean Distance if attributes are continuous (small distance → similar).
 - Other Problem-specific Measures.



- **Ví dụ:** Document Clustering (nhóm bài báo theo chủ đề).
 - Tập tin có nhiều bài báo, mỗi bài biểu diễn bằng word-frequency (tần suất từ).
 - Các bài về kinh tế rơi vào một cụm, các bài về y tế rơi vào cụm khác.



- Clustering (phân cụm) mã nguồn trong việc chấm điểm/lọc bài tập lập trình tự động.




- **Input:** các file mã nguồn SV nộp lên (.cpp, .py, .java, ...).
- Mã nguồn được chuyển sang **dạng biểu diễn trung gian** (CSV chứa thông tin về cấu trúc, quan hệ giữa các phần tử trong code).
- **Trích xuất đặc trưng (Feature Extraction):** Dùng các đồ thị như:
 - **EOG (Execution Order Graph)** – mô tả thứ tự thực thi.
 - **CFG (Control Flow Graph)** – mô tả luồng điều khiển trong chương trình.
 - **DFG (Data Flow Graph)** – mô tả luồng dữ liệu.
 Từ các biểu diễn này → sinh ra **Feature Set** (bộ đặc trưng).
- Các feature của từng bài được đưa vào thuật toán phân cụm (**KMeans**). **Kết quả:** nhóm lại các bài có cấu trúc/mẫu giải pháp tương tự nhau.
- **Output:** Các **cụm mã nguồn** (clusters).
 - Ví dụ: nhóm 1 có các bài giải tương tự nhau bằng Python và C++; nhóm 2 là Java; nhóm 3 là các biến thể khác.
 - Mục đích: giúp phát hiện **giải pháp giống nhau, đạo văn**, hoặc **phân loại các cách giải**.
- Đây là một ứng dụng của **unsupervised learning (học không giám sát)** trong giáo dục. Không cần nhãn sẵn (ví dụ: "đúng/sai"), mà chỉ cần nhóm các lời giải giống nhau.

- **Ứng dụng:**
 - Phân nhóm khách hàng theo hành vi.
 - Phân tích khí hậu (vùng đại dương có ảnh hưởng lớn đến môi trường).
 - Giảm dữ liệu (data compression).

1.2.3.4. Anomaly Detection (Phát hiện bất thường)

- **Ý nghĩa:** Xác định những điểm dữ liệu bất thường (anomalies/outliers) **khác biệt rõ rệt so với phần lớn dữ liệu.**
- **Mục tiêu:** Phát hiện thật sự những bất thường, **tránh gắn nhầm dữ liệu** bình thường thành bất thường. **Yêu cầu:** **Tỷ lệ phát hiện cao, tỷ lệ cảnh báo sai thấp.**
- **Ví dụ:** Credit Card Fraud Detection (phát hiện gian lận thẻ tín dụng): Khi có một giao dịch mới, so sánh với hồ sơ đã có của người dùng. Nếu các đặc điểm của giao dịch khác biệt nhiều so với hồ sơ đã tạo thì gắn cờ "ngghi gian lận".
- **Ứng dụng:**
 - Phát hiện gian lận (tài chính, bảo hiểm).
 - An ninh mạng (xâm nhập).
 - Y tế (dịch bệnh lạ).
 - Thiên tai (hạn hán, lũ lụt, bão...).

1.2.4. Một số kỹ thuật chính trong KTDL




- **Predictive tasks (Nhiệm vụ dự đoán)**
 - The objective (Mục tiêu) of these tasks is to **predict the value of a particular attribute based on the values of other attributes.**
 - The attribute to be predicted is commonly known as the **target** or **dependent variable**, while the attributes used for making the prediction are known as the **explanatory** or **independent** variables.

- Ví dụ:
 - Dự đoán **điểm thi** của sinh viên dựa trên số giờ học, số buổi đi học, mức độ làm bài tập.
 - Dự đoán **giá nhà** dựa vào diện tích, vị trí, số phòng.
 - Dự đoán **khả năng khách hàng sẽ mua hàng** dựa vào lịch sử giao dịch.

- **Descriptive tasks (Nhiệm vụ mô tả)**

- The objective is to **derive (rút ra) patterns** (*correlations/mối tương quan, trends, clusters, trajectories/quỹ đạo/tiến trình, and anomalies/bất thường*) that **summarize the underlying (cơ bản) relationships** in data → không cần biến mục tiêu.
- Descriptive data mining tasks are often **exploratory** (mang tính **khám phá**) in nature and frequently require **postprocessing** techniques to **validate** and **explain** the results.




1.2.5. Đánh giá Tri thức đã khai thác

- Khai thác dữ liệu có thể tạo ra hàng ngàn mẫu: **Không phải tất cả chúng đều tốt** (interesting pattern). Một số có thể chỉ phù hợp với không gian kích thước nhất định (thời gian, địa điểm,...)
- **Interesting pattern:** dễ hiểu đối với con người, hợp lệ trên dữ liệu mới hoặc thử nghiệm với một mức độ chắc chắn.
- **Đánh giá Tri thức đã khai thác (Evaluation of mined knowledge)**
 - **Khách quan:** dựa trên số liệu thống kê và cấu trúc của các mẫu.
 - **VD:** độ phổ biến (support), độ tin cậy (confidence), độ chính xác (accuracy),
 - **Chủ quan:** dựa trên niềm tin của người dùng vào dữ liệu
 - **VD:** tính bất ngờ, tính mới,...

1.2.6. Các quy trình Khai thác Dữ liệu

Quy trình **SEMMA** của SAS Institute:

- **Sample**: Lấy mẫu (đủ lớn, đủ nhỏ)
- **Explore**: Khám phá ban đầu, khảo sát dữ liệu
- **Modify**: Sửa đổi dữ liệu
- **Model**: Lựa chọn, mô hình hóa
- **Assess**: Đánh giá độ tin cậy, tính hữu ích. Có thể triển khai áp dụng thực tế (nếu tốt) hoặc lặp lại quá trình (nếu chưa tốt)



Quy trình **CRISP** chuẩn công nghiệp:

- **Business Understanding**: Tìm hiểu nghiệp vụ để xác định những tri thức cần đạt được
- **Data Understanding**: Khảo sát dữ liệu
- **Data Preparation**: Data pre-processing
- **Modeling**
- **Evaluation**: Đánh giá effectiveness, efficiency, scalability, ...
- **Deployment**

