

Quiz 1 - Dữ liệu và tiền xử lý

1. Cho biết các vấn đề nào sau đây **liên quan đến chất lượng dữ liệu**?

→ Tồn tại nhiều dữ liệu

→ Dữ liệu thiếu sót

→ Xuất hiện trùng lặp dữ liệu

2. Trong mặt phẳng tọa độ Oxy, cho 2 điểm $A(x_1, y_1)$, $B(x_2, y_2)$. Hãy cho biết khoảng cách **Euclidean** giữa 2 điểm này được tính bằng công thức nào?

→ $d = \sqrt{\text{sqr}(x_2 - x_1) + \text{sqr}(y_2 - y_1)}$ trong đó sqr là hàm bình phương, $\sqrt{}$ là hàm lấy căn bậc 2.

Euclidean Equation:

Euclidean Distance Formula

The Euclidean distance between two points $A(x_1, y_1)$ and $B(x_2, y_2)$ in a 2D space is:

$$d = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$$

For **n-dimensional space** (e.g., 3D, 4D, etc.), the general formula is:

$$d = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2 + (z_2 - z_1)^2 + \dots + (n_2 - n_1)^2}$$

3. Cho biết loại thuộc tính dữ liệu nào sau đây là thuộc tính rời rạc (discrete attribute)?

kiểu thuộc tính **Continuous** (Nhiệt độ, Cân nặng, Chiều cao)

→ Mã vùng (Vì mã vùng theo dãy số nguyên)

4. Trong mặt phẳng tọa độ Oxy, cho hai điểm A(0,1), B(4, 4). Hãy cho biết nếu sử dụng độ đo khoảng cách Euclidean thì khoảng cách giữa 2 điểm có giá trị là bao nhiêu?

→ dùng công thức $= 5 = \sqrt{(4 - 0)^2 + (4 - 1)^2}$

Question 1

Correct

Mark 1.00 out of 1.00

Flag question

Cho biết vấn đề liên quan đến chất lượng dữ liệu trong hàng đánh dấu B của bảng dữ liệu sau:

	Tid	Refund	Marital Status	Taxable Income	Cheat
	1	Yes	Single	125K	No
	2	No	Married	100K	No
	3	No	Single	70K	No
	4	Yes	Married	120K	No
A	5	No	Divorced	10000K	Yes
B	6	No	NULL	60K	No
	7	Yes	Divorced	220K	NULL
	8	No	Single	85K	Yes
C	9	No	Married	90K	No
	9	No	Single	90K	No

Select one:

- ☐ a. Dữ liệu khả năng bị sai
- ☐ b. Dữ liệu không có vấn đề
- ☐ c. Dữ liệu bị trùng lặp
- ☒ d. Dữ liệu bị thiếu hoặc không đầy đủ ✓

Cho biết vấn đề liên quan đến chất lượng dữ liệu trong hàng đánh dấu A của bảng dữ liệu sau:

	Tid	Refund	Marital Status	Taxable Income	Cheat
	1	Yes	Single	125K	No
	2	No	Married	100K	No
	3	No	Single	70K	No
	4	Yes	Married	120K	No
A	5	No	Divorced	10000K	Yes
B	6	No	NULL	60K	No
	7	Yes	Divorced	220K	NULL
	8	No	Single	85K	Yes
C	9	No	Married	90K	No
	9	No	Single	90K	No

Select one:

- ☒ a. Dữ liệu khả năng bị sai ✓
- ☐ b. Dữ liệu bị trùng lặp
- ☐ c. Dữ liệu không có vấn đề
- ☐ d. Dữ liệu bị thiếu hoặc không đầy đủ


Cho biết vấn đề liên quan đến chất lượng dữ liệu trong hai dòng đánh dấu C của bảng dữ liệu sau:

	Tid	Refund	Marital Status	Taxable Income	Cheat
	1	Yes	Single	125K	No
	2	No	Married	100K	No
	3	No	Single	70K	No
	4	Yes	Married	120K	No
A	5	No	Divorced	10000K	Yes
B	6	No	NULL	60K	No
	7	Yes	Divorced	220K	NULL
	8	No	Single	85K	Yes
C	9	No	Married	90K	No
	9	No	Single	90K	No

Select one:

- ☒ a. Dữ liệu bị trùng lặp ✓
- ☐ b. Dữ liệu bị thiếu hoặc không đầy đủ
- ☐ c. Dữ liệu không có vấn đề
- ☐ d. Dữ liệu khả năng bị sai

Quiz 2 - Bài toán phân lớp (Classification) và cây quyết định (Decision Tree)



Classification (Phân loại) trong **Data Mining (khai thác dữ liệu)** là một kỹ thuật dự đoán nhãn (label) của một đối tượng dựa trên các đặc trưng (features) của nó.

- Một trang web thương mại điện tử muốn bổ sung chức năng dự đoán việc click lên các mục quảng cáo của khách viếng thăm. Đây là dạng bài toán:

→ Classification (phân loại “potential cus” và “non-potential” khách hàng)

6. Bài toán **phát hiện giao dịch gian lận** của thẻ tín dụng là dạng bài toán?

→ Classification

7. Cây quyết định là giải pháp cho bài toán khai thác dữ liệu nào?

→ Phân lớp

8. **Ứng dụng lọc thư rác** sẽ áp dụng bài toán khai thác dữ liệu nào dưới đây?

→ Classification

9. Cây quyết định được xây dựng **dựa trên giải thuật?**

→ Giải thuật tham lam (Greedy)

Explain: “KHÔNG XÉT HẾT” tất cả các case → chỉ tìm cây “TỐT NHẤT”

Bản chất tham lam => Lấy nhiều nhất.

10. Trong cây quyết định **node** nào **chứa giá trị** của thuộc tính dự đoán?

→ Node lá

11. Trong cây quyết định **node** nào đại diện cho **thuộc tính dùng để kiểm tra? (kiểm tra điều kiện)**

→ Node trung gian

12. Mệnh đề nào dưới đây mô tả đúng cho **độ chính xác** của một giải thuật phân lớp?

→ Được tính dựa trên các độ đo và qua thực nghiệm

Explain: Các độ đo quan trọng:

- ✓ **Accuracy (Độ chính xác):** Tỷ lệ dự đoán đúng trên tổng số mẫu.
- ✓ **Precision (Độ chính xác theo lớp):** Tỷ lệ mẫu được dự đoán đúng trong số các mẫu được gán vào lớp đó.
- ✓ **Recall (Độ bao phủ):** Tỷ lệ mẫu thực sự thuộc một lớp được mô hình phát hiện đúng.
- ✓ **F1-score:** Trung bình điều hòa của Precision và Recall.

Quiz 3 - Classification Problem

13. Bayesian classifier là gì?

→ Là giải thuật học máy để tìm sự phân lớp tối ưu cho một tập dữ liệu mẫu dựa trên lý thuyết xác suất

14. Case-based learning là gì?

→ Là một hướng tiếp cận để thiết kế giải thuật học máy lấy ý tưởng từ việc con người gặp tình huống mới thì sẽ diễn giải tình huống mới bằng cách tham chiếu đến các tình huống đã xảy ra trước đó.

15. Cho Confusion Matrix như sau - Cho số lượng trường hợp bộ phân lớp cho kết quả sai?

→ 15 (do có 5 + 10 trường hợp predict sai)

n = 165	Predicted: No	Predicted: Yes	
Actual: No	Tn =50	FP=10	60
Actual: Yes	Fn=5	Tp=100	105
	55	110	

16. Mệnh đề nào đúng về độ **đo F-score** cho mô hình phân lớp

→ F-Score càng lớn thì bộ phân lớp càng tốt

17. Giải thuật nào sau đây **không** thuộc nhóm giải thuật phân lớp?

→ K - Means (cái này của Clustering)

Explain thêm: Classification có SVM, KNN, Decision Tree, Neural Network


18. Mệnh đề nào đúng khi dùng **SVM trên dữ liệu không phân tách tuyến tính được?**

→ Dùng Kernel Trick

→ Chuyển đổi dữ liệu lên không gian mới nhiều chiều hơn

(ví dụ: đồ thị dưới dùng e^x , và thay biến x vào hàm bằng $ax + b \rightarrow$ có nhiều chiều hơn trong toán)

- What if decision boundary is not linear?



Example - data non linear

19. Mô tả nào sau đây đúng cho khái niệm "overfitting"?

→ Khi mô hình học quá phức tạp dẫn đến thực thi chính xác trên tập dữ liệu huấn luyện nhưng nhiều dự đoán sai trên tập dữ liệu kiểm tra

20. Mô tả nào sau đây đúng cho khái niệm "underfitting"?

→ Khi mô hình học quá đơn giản dẫn đến khi thực thi trên tập dữ liệu huấn luyện và tập dữ liệu kiểm tra đều có nhiều dự đoán sai.

21. Trong giải thuật KNN, mệnh đề nào đúng cho tham số K

→ Tham số K càng bé thì ảnh hưởng bởi điểm dữ liệu nhiều càng cao

Quiz 4 - Clustering (phân cụm)

1. Các lần chạy K-means có khả năng cho kết quả khác nhau là đúng hay sai?

→ Đúng

2. Các ý nào sau đây đúng với K-Means:

- K-Means cực kỳ nhạy cảm với việc khởi tạo tâm cụm (central point)
- Việc khởi tạo tâm cụm không tốt sẽ dẫn đến việc hội tụ kém
- Việc khởi tạo tâm cụm không tốt sẽ dẫn đến kết quả gom cụm kém

3. Chỉ ra mệnh đề sai về K-Means

- Giải thuật gom cụm K-means tương tự giải thuật KNN (K- nearest neighbor)


Explain - nếu mệnh đề đúng:

- K-means là một phương pháp lượng tử hóa vector (vector quantization)
- K-Means phân chia **n đối tượng** dữ liệu thành k cụm

4. Giải pháp nào sau đây cho phép **tính độ tương tự giữa hai clusters** trong gom cụm phân cấp (hierarchical clustering)

- Average-Link
- MAX / Complete-Link
- MIN / Single-Link

5. Giải thuật gom cụm nào phù hợp với tập dữ liệu mô tả trong hình?




→ DBSCAN

6. Cho dữ liệu gồm 6 điểm trong không gian 2 chiều và khoảng cách giữa các điểm thể hiện ở các bảng sau:

Cho biết kết quả nào khi gom cụm dùng phương pháp gom cụm phân cấp với độ đo **AVERAGE-Link**:

Hierarchical Clustering: Comparison




point	x coordinate	y coordinate
p1	0.4005	0.5306
p2	0.2148	0.3854
p3	0.3457	0.3156
p4	0.2652	0.1875
p5	0.0789	0.4139
p6	0.4548	0.3022

Table : X-Y coordinates of six points.






	p1	p2	p3	p4	p5	p6
p1	0.0000	0.2357	0.2218	0.3688	0.3421	0.2347
p2	0.2357	0.0000	0.1483	0.2042	0.1388	0.2540
p3	0.2218	0.1483	0.0000	0.1513	0.2843	0.1100
p4	0.3688	0.2042	0.1513	0.0000	0.2932	0.2216
p5	0.3421	0.1388	0.2843	0.2932	0.0000	0.3921
p6	0.2347	0.2540	0.1100	0.2216	0.3921	0.0000

Table : Distance Matrix for Six Points




7. Giống bảng data câu số 6.

Cho biết kết quả nào khi gom cụm dùng phương pháp gom cụm phân cấp với độ đo **MAX**



Ward's Method



8. Số lượng thuộc tính (features) tối thiểu để gom cụm được là bao nhiêu?


→ 1

9. Trường hợp nào sau đây K-Means không cho kết quả tốt

→ Dữ liệu có ngoại biên (outlier)

→ Dữ liệu có mật độ phân bố thay đổi

→ Dữ liệu phân bố theo dạng hình không lồi (non-convex)



10. Trong giải thuật K Means, K mang nghĩa?

→ Số cụm

11. Giải thuật K-Means yêu cầu điều gì?

→ Trung tâm cụm khởi tạo trước (centroid)

→ Độ đo khoảng cách định nghĩa trước

→ Số cụm cho trước

12. Các lần chạy K-means có khả năng cho kết quả khác nhau là đúng hay sai?

→ Đúng

13. Hai lần chạy K-means trên cùng một tập dữ liệu có đảm bảo hai kết quả đồng nhất không?

→ Không

14. Điều kiện dừng của giải thuật K-Means có thể là:

→ Nếu giá trị hàm mục tiêu có giá trị dưới ngưỡng cho trước

→ Việc phân cụm không thay đổi

→ Các trung tâm cụm không thay đổi

→ Sau một số lần lặp định trước

15. Những trường hợp nào dưới đây K-Means thất bại:

→ Dữ liệu có nhiều nhiễu

→ Dữ liệu có phân bố mật độ thay đổi

→ Dữ liệu phân bố dạng không lồi (non-convex shapes)

16. Giải thuật K-Means chạy trên tập dữ liệu gồm 7 điểm với $k=3$. Sau lần lặp đầu tiên, các cụm phân bố như sau:

C1: {(2,2), (4,4), (6,6)}

C2: {(0,4), (4,0)}

C3: {(5,5), (9,9)}

Cho biết tâm cụm sau lần lặp tiếp theo.

Finding centroid for data points in cluster C1 = $((2+4+6)/3, (2+4+6)/3) = (4, 4)$

Finding centroid for data points in cluster C2 = $((0+4)/2, (4+0)/2) = (2, 2)$

Finding centroid for data points in cluster C3 = $((5+9)/2, (5+9)/2) = (7, 7)$

Hence, C1: (4,4), C2: (2,2), C3: (7,7)

17. Thao tác nào sau đây có khả năng cải thiện kết quả gom cụm K-Means:

→ Chạy nhiều lần với các khởi tạo tâm cụm khác nhau

→ Điều chỉnh số lần lặp

→ Tìm ra số cụm tối ưu

18. Số cụm thu được bởi giải thuật K-Means áp dụng trên tập dữ liệu có n điểm

→ k

19. K-Means thuộc giải thuật học máy

→ Không có giám sát (unsupervised learning)

Mẫu dữ liệu

Áp dụng giải thuật apriori trên tập dữ liệu gồm 5 loại mục {A, B, C, D, E}.

Giả sử thu được các 2-itemsets phổ biến là {A, B}, {A, C}, {A, D}, {B, C}, {B, E}, {C, E}.

Hỏi trong các itemsets sau, itemset nào sẽ là ứng viên 3-itemsets cần xem xét ở vòng lặp tiếp theo?

→ {B, C, E}, {A, B, C}, {A, B, D}, {A, B, C} , {A, C,D}

Cho trước ngưỡng hỗ trợ $\text{minSup} = 60\%$ và ngưỡng tin cậy $\text{minConf} = 80\%$ để tìm tập phổ biến và luật kết hợp trên cho dataset sau:

T_id	Itemlist
T1	{A, B, D, F}
T2	{A, B, C, D, E}
T3	{A, B, C, E}
T4	{A, B, D}

Cho biết các 1-itemsets nào là phổ biến?

→ A, B, D

60% CỦA 4 TRANSACTIONS = 2.4 = MINUPS → ≥ 2.4 THÌ CHỌN

Cho biết kích cỡ itemsets lớn nhất có thể tìm được là bao nhiêu (DỰA VÀO BẢNG TRÊN)

→ 3

Giải thuật Apriori dựa trên thuộc tính nào của độ hỗ trợ (support)?

→ Thuộc tính Anti-monotone

Giải thuật khai thác mẫu phổ biến?

→ ECLAT

→ FP-Growth

→ Apriori

c. Tất cả đều sai

Một tập mục (itemset) được gọi là phổ biến nếu:

→ Độ hỗ trợ lớn hơn hoặc bằng ngưỡng cho trước

Frequent Itemset

- An itemset I whose support is greater than or equal to a $minsup$ threshold, $s(I) \geq minsup$

Kỹ thuật PCA (Principal Component Analysis) dùng để

→ Thu giảm số chiều dữ liệu

DBSCAN cho phép tìm mật độ phân bố của các điểm dữ liệu trong tập dữ liệu?

→ False

Cho biết các vấn đề nào sau đây liên quan đến chất lượng dữ liệu?

→ a. Tồn tại nhiễu dữ liệu

→ b. Dữ liệu thiếu sót

→ c. Xuất hiện trùng lặp dữ liệu

Cho biết vấn đề liên quan đến chất lượng dữ liệu trong dòng đánh dấu A của bảng dữ liệu sau:

	Tid	Refund	Marital Status	Taxable Income	Cheat
	1	Yes	Single	125K	No
	2	No	Married	100K	No
	3	No	Single	70K	No
	4	Yes	Married	120K	No
A	5	No	Divorced	10000K	Yes
B	6	No	NULL	60K	No
	7	Yes	Divorced	220K	NULL
	8	No	Single	85K	Yes
C	9	No	Married	90K	No
	9	No	Single	90K	No

Select one:

- ☐ a. Dữ liệu bị trùng lặp
- ☐ b. Dữ liệu không có vấn đề
- ☒ c. Dữ liệu khả năng bị sai ✓
- ☐ d. Dữ liệu bị thiếu hoặc không đầy đủ

Cho biết vấn đề liên quan đến chất lượng dữ liệu trong hai dòng đánh dấu C của bảng dữ liệu sau:

	Tid	Refund	Marital Status	Taxable Income	Cheat
	1	Yes	Single	125K	No
	2	No	Married	100K	No
	3	No	Single	70K	No
	4	Yes	Married	120K	No
A	5	No	Divorced	10000K	Yes
B	6	No	NULL	60K	No
	7	Yes	Divorced	220K	NULL
	8	No	Single	85K	Yes
C	9	No	Married	90K	No
	9	No	Single	90K	No

Select one:

- ☐ a. Dữ liệu không có vấn đề
- ☐ b. Dữ liệu khả năng bị sai
- ☐ c. Dữ liệu bị thiếu hoặc không đầy đủ
- ☒ d. Dữ liệu bị trùng lặp ✓

Bài toán khai thác dữ liệu nào dưới đây thực hiện để nhận dạng cho dữ liệu mới dựa trên những dữ liệu đã biết trước?

→ Classification

Bài toán tìm cấu trúc ẩn chứa bên trong tập dữ liệu không được gán nhãn được gọi là

→ Học không giám sát (unsupervised learning)

Thao tác nào sau đây giúp thu giảm số điểm dữ liệu trong tập dữ liệu?

→ Lấy mẫu

Một ứng dụng quản lý file văn bản, muốn cung cấp chức năng tìm kiếm và tổ chức các file văn bản theo các nhóm, căn cứ vào nội dung bên trong file. Đây là dạng bài toán:

→ Clustering

Thao tác nào sau đây giúp thu giảm số thuộc tính trong tập dữ liệu?’

→ Thu giảm số chiều