

## **Chương 3: PHÁT HIỆN ĐẶC TRƯNG VÀ ĐỐI SÁNH ẢNH - FEATURE DETECTION & IMAGE MATCHING (PHẦN 02)**

### **Nội dung**

|                                                                                                              |    |
|--------------------------------------------------------------------------------------------------------------|----|
| 1. Đối sánh hình ảnh (Image Matching).....                                                                   | 1  |
| 2. Đối sánh ảnh (Photo Matching) .....                                                                       | 2  |
| 3. Các phương pháp cải thiện hiệu suất của các thuật toán phát hiện đặc trưng và đối sánh ảnh, hình ảnh..... | 4  |
| 4. Sử dụng các kỹ thuật học sâu cho bài toán Photo Matching.....                                             | 4  |
| 4.1. Sử dụng Mạng Nơ-ron Tích Chập (CNN) .....                                                               | 4  |
| 4.2. Siamese Network .....                                                                                   | 6  |
| 4.3. Triplet Network .....                                                                                   | 7  |
| 4.4. Transformers cho Photo Matchings .....                                                                  | 7  |
| 4.5. Self-Supervised Learning (SSL) .....                                                                    | 8  |
| 4.6. Generative Adversarial Networks (GAN).....                                                              | 9  |
| 4.7. Hybrid Models.....                                                                                      | 9  |
| 5. Triển khai bài toán Photo Matching sử dụng Mạng Nơ-ron Tích Chập (CNN) với PyTorch. ....                  | 11 |

### **1. Đối sánh hình ảnh (Image Matching)**

- Việc **lựa chọn phương pháp** đối sánh hình ảnh phụ thuộc vào nhiều yếu tố, bao gồm:
  - **Tính chất của dữ liệu:** Độ phức tạp của hình ảnh, mức độ nhiễu, biến đổi hình học.
  - **Yêu cầu về độ chính xác và tốc độ:** Mức độ chính xác cần đạt được và thời gian thực thi.
  - **Kiến thức trước về đối tượng:** Có hay không có thông tin về hình dạng, kết cấu của đối tượng.
- **Phân loại phương pháp**
  - **Đối sánh dựa trên đặc trưng cục bộ (Local Feature-based Matching)**
  - **Đối sánh dựa trên mô hình (Model-based Matching)**
- **Độ chính xác** của quá trình đối sánh ảnh phụ thuộc vào nhiều yếu tố, từ chất lượng hình ảnh đến thuật toán được sử dụng. Một số yếu tố chính ảnh hưởng đến độ chính xác này:
  - **Chất lượng hình ảnh:** độ phân giải, độ nhiễu, ánh sáng, biến dạng
  - **Thuật toán đối sánh:**
    - **Loại thuật toán.**
      - Mỗi thuật toán có những ưu nhược điểm khác nhau. Ví dụ,
        - SIFT rất chính xác nhưng chậm, dùng toán học phức tạp (đạo hàm Gaussian) nên rất bền vững nhưng nặng máy.
        - trong khi ORB dùng so sánh nhị phân (binary test) → nhanh hơn nhưng có thể kém chính xác hơn trong một số trường hợp.

- **Các tham số của thuật toán.** Việc thiết lập các tham số của thuật toán một cách phù hợp rất quan trọng. Ví dụ, số lượng điểm đặc trưng, ngưỡng tương đồng, v.v.
  - Ví dụ "ngưỡng tương đồng" (threshold). Đặt cao quá thì không tìm thấy cặp nào, thấp quá thì nhận nhầm cặp sai.
- **Phương pháp loại bỏ điểm ngoại lai. Rất quan trọng.**
  - **Ngoại lai (outlier)** là những đối sánh sai, tức là: Hai điểm được ghép với nhau nhưng thực tế không đại diện cho cùng một đặc trưng trong hai ảnh
  - Các điểm ngoại lai (outliers) có thể làm giảm độ chính xác của quá trình đối sánh.
  - Khi ghép ảnh, sẽ có những điểm máy tính nối sai (ví dụ: điểm trên mây nối với điểm dưới đất).
  - Việc sử dụng các phương pháp loại bỏ điểm ngoại lai như RANSAC là rất cần thiết. RANSAC (Random Sample Consensus) là thuật toán xác suất giúp lọc bỏ các cặp nối sai này để giữ lại mô hình đúng nhất.
- **Đặc trưng được sử dụng:** loại đặc trưng, mô tả đặc trưng
- **Môi trường làm việc:** tốc độ tính toán, bộ nhớ, hệ điều hành
- **Các yếu tố khác:** tiền xử lý hình ảnh, phương pháp đánh giá

## 2. Đối sánh ảnh (Photo Matching)

- **Hiệu suất của các thuật toán** phát hiện đặc trưng và đối sánh ảnh là yếu tố quan trọng quyết định chất lượng của nhiều ứng dụng thị giác máy tính.
- Để cải thiện hiệu suất, chúng ta có thể áp dụng một số phương pháp sau:
  - **Tối ưu hóa thuật toán:**
    - **Lựa chọn thuật toán phù hợp**
    - **Điều chỉnh các tham số** của thuật toán như số lượng điểm đặc trưng, ngưỡng tương đồng, v.v.
    - **Sử dụng các kỹ thuật tối ưu hóa** như RANSAC để loại bỏ các điểm ngoại lai, cải thiện độ chính xác của kết quả.
      - **RANSAC:** Đây là bước "vệ sinh" kết quả, loại bỏ nhiễu sai lệch về hình học.
  - **Cải thiện chất lượng hình ảnh:**
    - **Tiền xử lý hình ảnh:** Áp dụng các kỹ thuật tiền xử lý như **khử nhiễu, tăng cường cạnh, cân bằng histogram** để cải thiện chất lượng hình ảnh, giúp cho quá trình phát hiện đặc trưng và đối sánh chính xác hơn.
    - **Cân bằng ánh sáng:** Điều chỉnh **độ sáng và tương phản** của hình ảnh để giảm thiểu ảnh hưởng của điều kiện ánh sáng khác nhau.
    - **Chỉnh sửa hình học:** **Sửa các biến dạng hình học** như **xoay, phóng to, thu nhỏ** để đảm bảo các hình ảnh có cùng hệ quy chiếu.

○ **Sử dụng các kỹ thuật học sâu:** Đây là xu hướng hiện đại:

▪ **Mạng thần kinh tích chập (CNN):**

- Thay vì để con người thiết kế đặc trưng (như SIFT), ta để mạng AI tự học đặc trưng. Các lớp sâu của CNN chứa thông tin ngữ nghĩa rất tốt.
- Sử dụng CNN để học các đặc trưng sâu của hình ảnh, giúp cải thiện độ chính xác và khả năng tổng quát hóa của mô hình.

▪ **Siamese networks (Mạng Xiêm):** Sử dụng hai mạng thần kinh giống nhau để tạo ra các biểu diễn đặc trưng cho hai hình ảnh và so sánh chúng.

- *Cấu trúc:* Hai mạng CNN y hệt nhau (chung trọng số).
- *Cách chạy:* Đưa ảnh A vào nhánh 1, ảnh B vào nhánh 2.
- *Đầu ra:* Mạng tính toán khoảng cách giữa vector đặc trưng của A và B. Nếu gần nhau → cùng 1 người/vật.

▪ **Triplet networks:**

- Tìm kiếm các bộ ba hình ảnh (anchor, positive, negative) để học cách phân biệt các hình ảnh tương tự và không tương tự.
- Học sao cho Anchor gần Positive và xa Negative. Đây là cốt lõi của FaceNet (nhận diện mặt).

○ **Tối ưu hóa phần cứng:**

▪ **Sử dụng GPU:**

- Tận dụng khả năng tính toán song song của GPU để tăng tốc độ tính toán.
- Xử lý ảnh là thao tác trên ma trận. GPU sinh ra để tính toán ma trận song song, nhanh hơn CPU hàng chục/trăm lần.

▪ **Lựa chọn ngôn ngữ lập trình và thư viện phù hợp:** Sử dụng các ngôn ngữ lập trình và thư viện được tối ưu hóa cho xử lý ảnh, như OpenCV, PyTorch, TensorFlow.

○ **Các kỹ thuật khác:**

▪ **Kết hợp nhiều thuật toán:** Sử dụng kết quả của nhiều thuật toán khác nhau để tăng độ tin cậy của kết quả.

▪ **Xây dựng cơ sở dữ liệu đặc trưng:** Lưu trữ các đặc trưng đã tính toán để tăng tốc độ so sánh trong các ứng dụng thực tế.

▪ **Sử dụng các kỹ thuật giảm chiều (PCA, Autoencoder):**

- Giảm kích thước của các vector đặc trưng để giảm thời gian tính toán và tăng tốc độ so sánh.
- Vector đặc trưng có thể có 4096 chiều (rất nặng). Giảm xuống còn 128 chiều giúp so sánh nhanh hơn mà vẫn giữ được thông tin chính.

### 3. Các phương pháp cải thiện hiệu suất của các thuật toán phát hiện đặc trưng và đối sánh ảnh, hình ảnh

- Ví dụ cụ thể:
  - Trong lĩnh vực nhận dạng khuôn mặt:
    - Sử dụng **mạng thần kinh sâu** để trích xuất các đặc trưng sâu của khuôn mặt, sau đó so sánh các đặc trưng này để xác định danh tính.
    - Dùng Deep Learning (CNN) trích xuất đặc trưng vì khuôn mặt biến đổi phức tạp (cười, khóc, già đi). SIFT/SURF truyền thống không làm tốt việc này.
  - Trong lĩnh vực ghép ảnh: Sử dụng SIFT hoặc SURF để phát hiện các điểm đặc trưng, sau đó sử dụng RANSAC để loại bỏ các điểm ngoại lai và tính toán ma trận biến đổi hình học để ghép các hình ảnh lại với nhau.
  - Trong lĩnh vực theo dõi vật thể:
    - Sử dụng KLT (Kanade-Lucas-Tomasi) tracker để theo dõi các điểm đặc trưng theo thời gian, sau đó sử dụng các thuật toán lọc để ước tính quỹ đạo của vật thể.
    - Nó theo dõi sự di chuyển của các điểm góc qua các khung hình video liên tiếp.
- **Lựa chọn phương pháp cụ thể phụ thuộc vào nhiều yếu tố, bao gồm:**
  - **Tính chất của dữ liệu:** Độ phức tạp của hình ảnh, mức độ nhiễu, biến đổi hình học.
  - **Yêu cầu về độ chính xác và tốc độ:** Mức độ chính xác cần đạt được và thời gian thực thi.
  - **Môi trường làm việc:** Tài nguyên tính toán, phần cứng.

- Feature Matching using Brute Force in OpenCV → <https://www.geeksforgeeks.org/feature-matching-using-brute-force-in-opencv/>
- Python OpenCV – FlannBasedMatcher() Function → <https://www.geeksforgeeks.org/python-opencv-flannbasedmatcher-function/>

### 4. Sử dụng các kỹ thuật học sâu cho bài toán Photo Matching

#### 4.1. Sử dụng Mạng Nơ-ron Tích Chập (CNN)

- **Mạng Nơ-ron Tích Chập (Convolutional Neural Network – CNN)** là mô hình học sâu phổ biến trong xử lý ảnh, có khả năng **tự động trích xuất đặc trưng phân cấp** từ ảnh đầu vào.
- CNN là mô hình phổ biến trong xử lý ảnh, được sử dụng để **biểu diễn mỗi ảnh dưới dạng một vector đặc trưng**, có thể trích xuất đặc trưng của ảnh đầu vào và so sánh độ tương đồng giữa các đặc trưng này.
  - **Mô hình CNN truyền thống:**
    - CNN được **huấn luyện trên tập dữ liệu ảnh lớn** để học các đặc trưng thị giác như:
      - Cạnh, góc (low-level features)
      - Hình dạng, hoa văn (mid-level features)
      - Cấu trúc và ngữ nghĩa (high-level features)
    - Sau khi huấn luyện, mỗi ảnh đầu vào được ánh xạ thành một **vector đặc trưng (feature embedding)**.
    - Độ tương đồng giữa hai ảnh được tính bằng các độ đo khoảng cách phổ biến như: **Euclidean Distance, Cosine Similarity**

→ Hai ảnh được xem là giống nhau nếu **khoảng cách giữa các vector đặc trưng đủ nhỏ** hoặc **độ tương đồng đủ lớn**.

- **Pre-trained CNN:**

- Thay vì huấn luyện từ đầu, các mô hình như **ResNet, VGG, MobileNet** có thể được dùng để trích xuất đặc trưng ảnh.
- **Cách làm phổ biến:**
  - Chọn một mô hình CNN pre-trained.
  - **Loại bỏ lớp phân loại cuối cùng (Fully Connected + Softmax).**
  - Sử dụng **lớp ngay trước lớp phân loại** làm đầu ra đặc trưng.
  - **Mỗi ảnh được biểu diễn bằng một vector đặc trưng cố định chiều.**
  - So sánh các vector này bằng Euclidean hoặc Cosine Similarity.
- **Ý nghĩa:**
  - Các mô hình này đã học được **đặc trưng thị giác tổng quát** từ hàng triệu ảnh do các tổ chức lớn như Google, Meta (Facebook) huấn luyện.
  - Có thể áp dụng trực tiếp cho nhiều bài toán Photo Matching mà không cần huấn luyện lại toàn bộ mạng.

- **Bản chất của cách tiếp cận CNN trong Photo Matching**

- CNN đóng vai trò như một **bộ trích xuất đặc trưng toàn cục (global feature extractor)**.
- Hai ảnh **không được xử lý đồng thời**, mà được xử lý **độc lập** qua cùng một mạng.
- **Việc so sánh diễn ra sau khi trích xuất đặc trưng**, không nằm trong quá trình học của mô hình.

- **Ưu điểm:** Hiệu quả cao trong các bài toán không yêu cầu học quan hệ phức tạp giữa hai ảnh.

- Phù hợp với:
  - Tìm kiếm ảnh tương tự (Image Retrieval)
  - So khớp ảnh ở mức tổng quát
- Tận dụng tốt tri thức từ các mô hình pre-trained.

- **Nhược điểm:**

- **Chỉ so sánh đặc trưng thuần túy**
- **Không tận dụng được các mối quan hệ phức tạp giữa hai ảnh.**
  - Vùng nào trong ảnh này tương ứng với vùng nào trong ảnh kia
  - Biến đổi hình học cục bộ
- Hiệu quả hạn chế trong các bài toán yêu cầu:
  - Độ chính xác rất cao
  - Nhận diện chi tiết hoặc tương quan cục bộ

- Trong bài toán Photo Matching, CNN truyền thống và CNN pre-trained chủ yếu đóng vai trò **trích xuất đặc trưng ảnh**, trong khi việc so khớp được thực hiện bằng các độ đo khoảng cách đơn giản. Cách tiếp cận này **phù hợp với các bài toán so sánh ảnh ở mức tổng quát nhưng còn hạn chế trong việc khai thác các mối quan hệ phức tạp giữa hai ảnh.**

## 4.2. Siamese Network

- Gồm **hai mạng (nhánh) CNN có chung trọng số** để trích xuất đặc trưng của hai ảnh đầu vào. Việc chia sẻ trọng số giúp đảm bảo rằng cả hai ảnh được ánh xạ vào **cùng một không gian đặc trưng**.
- Mỗi nhánh nhận một ảnh đầu vào, được ánh xạ thành một **vector đặc trưng (embedding)**. Đầu ra của hai nhánh sẽ được so sánh bằng một khoảng cách (thường là Euclidean) **để đánh giá độ giống nhau**.
  - Nếu hai ảnh **giống nhau**, khoảng cách giữa các embedding sẽ **nhỏ**.
  - Nếu hai ảnh **khác nhau**, khoảng cách sẽ **lớn**.
- CNN truyền thống cần hàng nghìn ảnh để học. **Siamese chỉ cần học "sự giống nhau" nên hiệu quả với dữ liệu ít**.
- **Cơ chế học (Loss Function)**
  - Siamese Network không học phân loại trực tiếp mà học **hàm đo độ tương đồng**.
  - Thường sử dụng các hàm mất mát như: **Contrastive Loss** (Trong các biến thể nâng cao: Triplet Loss)
  - Thông qua quá trình huấn luyện với các cặp ảnh:
    - **Cặp dương (positive pairs):** hai ảnh của cùng một đối tượng
    - **Cặp âm (negative pairs):** hai ảnh của các đối tượng khác nhau
  - *Mạng học cách kéo gần embedding của cặp dương và đẩy xa embedding của cặp âm trong không gian đặc trưng.*
- **Ưu điểm:**
  - Hiệu quả khi dữ liệu huấn luyện hạn chế.
  - Học được mối quan hệ giữa hai ảnh, không chỉ dựa vào đặc trưng đơn lẻ.
  - Có thể áp dụng cho đối tượng mới chưa từng xuất hiện trong tập huấn luyện.
- **Nhược điểm:**
  - Đòi hỏi dữ liệu phải có cặp ảnh dương (giống nhau) và âm (khác nhau) để huấn luyện tốt.
  - Việc tạo và cân bằng các cặp ảnh có thể: Tốn công, Ảnh hưởng mạnh đến chất lượng mô hình
  - Hiệu suất phụ thuộc nhiều vào chiến lược chọn cặp (pair sampling).
- **Ứng dụng:** Nhận dạng khuôn mặt, tìm kiếm ảnh tương đồng, Nhận dạng chữ viết tay, chữ ký; So khớp ảnh trong hệ thống xác thực sinh trắc học.
- Siamese Network cho phép mô hình học trực tiếp **không gian đặc trưng dựa trên độ tương đồng**, thay vì học phân loại. Nhờ đó, phương pháp này đặc biệt phù hợp cho các bài toán Photo Matching khi **số lượng dữ liệu huấn luyện hạn chế nhưng yêu cầu độ chính xác cao**.

### 4.3. Triplet Network

- Mô hình Triplet Network mở rộng Siamese Network bằng cách sử dụng ba ảnh đầu vào thay vì so sánh từng cặp ảnh độc lập:
  - **Anchor (A)**: Ảnh gốc
  - **Positive (P)**: Ảnh có liên quan đến Anchor (thuộc cùng đối tượng hoặc cùng lớp với Anchor)
  - **Negative (N)**: Ảnh không liên quan (thuộc đối tượng hoặc lớp khác Anchor)
- Ba ảnh này được đưa qua **ba nhánh CNN có chung trọng số**, đảm bảo rằng tất cả ảnh được ánh xạ vào **cùng một không gian embedding**.
- Mô hình học sao cho khoảng cách giữa (A, P) nhỏ hơn khoảng cách giữa (A, N).
  - **Loss function**:  $\text{Distance}(A, P) + \text{margin} < \text{Distance}(A, N)$ .
    - *Distance* thường là Euclidean Distance
    - *margin* là một ngưỡng an toàn, đảm bảo khoảng cách giữa (A, N) đủ lớn so với (A, P)
  - Mạng sẽ cố gắng kéo A và P lại gần nhau, và đẩy N ra xa.
- **Ưu điểm**:
  - Hiệu quả cao trong các bài toán so khớp ảnh lớn.
  - Học được **quan hệ tương đối** giữa các ảnh, không chỉ quan hệ cặp đôi.
  - Không gian embedding có tính phân tách tốt, dễ mở rộng cho dữ liệu mới.
- **Nhược điểm**:
  - Cần một lượng lớn dữ liệu có nhãn để chọn cặp ảnh phù hợp.
  - Việc lựa chọn bộ ba ảnh (triplet sampling) là thách thức:
    - Triplet “dễ” học nhanh nhưng ít hiệu quả
    - Triplet “khó” (hard triplets) cải thiện mô hình nhưng dễ gây mất ổn định khi huấn luyện
  - Chi phí huấn luyện cao hơn so với Siamese Network.
- Triplet Network tối ưu trực tiếp không gian embedding dựa trên quan hệ tương đối giữa ba ảnh, **giúp mô hình học được sự phân tách rõ ràng giữa các đối tượng**. Phương pháp này đặc biệt hiệu quả trong các bài toán Photo Matching quy mô lớn nhưng đòi hỏi dữ liệu và chiến lược huấn luyện phù hợp.

### 4.4. Transformers cho Photo Matching

- Các mô hình transformer như **Vision Transformer (ViT)**, **Swin Transformer** có thể được áp dụng để trích xuất đặc trưng ảnh, sau đó sử dụng khoảng cách đặc trưng để so khớp ảnh, dựa trên cơ chế **self-attention**, thay vì tích chập cục bộ như CNN.
- CNN chỉ nhìn cục bộ (cửa sổ trượt 3x3), còn Transformer nhìn toàn cục (global attention) -> Hiểu mối quan hệ xa trong ảnh tốt hơn.
- Vốn là thuật toán xử lý ngôn ngữ (ChatGPT dùng Transformer), nay áp dụng sang ảnh.

- **Nguyên lý hoạt động**
  - Ảnh đầu vào được chia thành các **patch** (khối nhỏ).
  - **Mỗi patch được ánh xạ thành một vector và đưa vào kiến trúc Transformer.**
  - Cơ chế **self-attention** cho phép mô hình:
    - Học mối quan hệ giữa các vùng ảnh **ở phạm vi toàn cục**
    - Không bị giới hạn bởi vùng receptive field cục bộ như CNN
  - Đầu ra của mô hình là một **biểu diễn đặc trưng toàn cục (global embedding)** của ảnh.
- **Ưu điểm:** Hiệu quả với ảnh có sự khác biệt lớn về hình dạng, nội dung; học được mối quan hệ không gian rộng hơn so với CNN.
- **Nhược điểm:** Đòi hỏi tài nguyên lớn để huấn luyện.
- Việc áp dụng Transformer cho Photo Matching cho phép mô hình khai thác hiệu quả các mối quan hệ không gian toàn cục trong ảnh, vượt qua hạn chế về receptive field của CNN. Tuy nhiên, hiệu quả cao này đi kèm với chi phí tính toán và yêu cầu dữ liệu lớn.

#### 4.5. Self-Supervised Learning (SSL)

- Là hướng tiếp cận học sâu cho phép mô hình **tự học đặc trưng từ dữ liệu không gán nhãn**, thông qua việc thiết kế các nhiệm vụ huấn luyện nội tại (pretext tasks).
- Trong lĩnh vực **Photo Matching**, SSL đóng vai trò quan trọng trong việc **học biểu diễn ảnh tổng quát khi dữ liệu có nhãn hạn chế hoặc khó thu thập.**
- Kỹ thuật này giúp mô hình học được đặc trưng ảnh mà **không cần nhiều dữ liệu có nhãn.**
- Các phương pháp phổ biến: **SimCLR** (Contrastive Learning), **BYOL** (Bootstrap Your Own Latent), **MoCo** (Momentum Contrast)
- Các mô hình này huấn luyện bằng cách so khớp một ảnh với phiên bản biến đổi của chính nó (augmentation), giúp tăng khả năng nhận diện ảnh.
- **Nguyên lý chung**
  - Thay vì sử dụng nhãn thủ công, SSL khai thác **cấu trúc sẵn có trong dữ liệu ảnh.**
  - Mô hình được huấn luyện để:
    - So khớp một ảnh với **các phiên bản biến đổi (augmentations)** của chính nó
    - Phân biệt ảnh này với các ảnh khác trong tập dữ liệu
  - Qua đó, mô hình học được các đặc trưng:
    - Ổn định với biến đổi hình học, ánh sáng
    - Phân biệt tốt giữa các ảnh khác nhau
- **Các mô hình SSL thường được dùng để:**
  - **Tiền huấn luyện (pretraining)** bộ trích xuất đặc trưng ảnh
  - Sau đó áp dụng cho: So khớp ảnh, Tìm kiếm ảnh tương đồng, Nhận dạng đối tượng
  - Biểu diễn đặc trưng học được từ SSL thường: Có khả năng tổng quát hóa cao, hoạt động tốt ngay cả khi chỉ tinh chỉnh (fine-tuning) với ít dữ liệu gán nhãn
- **Ưu điểm:** Không cần nhiều dữ liệu gán nhãn; tổng quát hóa tốt hơn khi áp dụng cho nhiều loại ảnh.
- **Nhược điểm:** Yêu cầu nhiều tài nguyên tính toán để huấn luyện, yêu cầu thiết kế chiến lược augmentation phù hợp để đạt hiệu quả cao.

- Self-Supervised Learning cho phép mô hình học biểu diễn ảnh hiệu quả mà không phụ thuộc vào dữ liệu gán nhãn, trở thành nền tảng quan trọng cho các hệ thống Photo Matching hiện đại, đặc biệt trong bối cảnh dữ liệu nhãn khan hiếm.

#### 4.6. Generative Adversarial Networks (GAN)

- Một hướng tiếp cận học sâu dựa trên cơ chế đối kháng giữa hai mạng nơ-ron: **Generator** và **Discriminator**.
- Mặc dù GAN không được thiết kế trực tiếp cho bài toán *Photo Matching*, chúng vẫn có thể được khai thác trong một số kịch bản đặc thù liên quan đến **so sánh ảnh, phát hiện ảnh giả mạo và phân tích phong cách ảnh**.
- GAN có thể được dùng để **tạo ra ảnh giả mạo hoặc kiểm tra mức độ tương đồng** của ảnh.
- **Nguyên lý hoạt động**
  - **Generator (G)**: Học cách **sinh ra ảnh giả** sao cho giống ảnh thật nhất có thể.
  - **Discriminator (D)**: Học cách **phân biệt ảnh thật và ảnh do Generator tạo ra**.
  - Hai mạng được huấn luyện đồng thời trong một quá trình đối kháng:
    - Generator cố gắng đánh lừa Discriminator
    - Discriminator cố gắng phân loại chính xác
- Thông qua quá trình này, Discriminator học được các **đặc trưng tinh vi** để phân biệt ảnh thật và ảnh giả, từ đó có thể được tái sử dụng cho các bài toán so sánh ảnh.
- Ví dụ: **StyleGAN** (có thể kiểm tra xem hai ảnh có cùng phong cách không), **Pix2Pix**, **CycleGAN** (có thể dùng để chuyển đổi phong cách ảnh rồi so khớp).
- **Ưu điểm**: Hiệu quả với bài toán phát hiện ảnh giả mạo.
- **Nhược điểm**:
  - Ít phù hợp với bài toán so khớp ảnh thông thường,
  - Huấn luyện GAN phức tạp, dễ mất ổn định.
  - Chi phí tính toán cao, khó triển khai trong hệ thống thực tế.
- GAN chủ yếu đóng vai trò hỗ trợ trong các bài toán Photo Matching, đặc biệt là phát hiện ảnh giả mạo và so sánh phong cách ảnh. Tuy nhiên, do không trực tiếp học hàm đo độ tương đồng, **GAN ít được sử dụng cho các bài toán so khớp ảnh thông thường**.

#### 4.7. Hybrid Models

- Trong thực tế, **không có một mô hình đơn lẻ nào đáp ứng tối ưu cho mọi bài toán Photo Matching**. Do đó, các hệ thống hiện đại thường áp dụng **Hybrid Models** – tức là **kết hợp nhiều kiến trúc và kỹ thuật học sâu khác nhau** nhằm tận dụng ưu điểm của từng phương pháp và khắc phục hạn chế riêng lẻ.
- Có thể **kết hợp nhiều phương pháp trên** để tăng độ chính xác:
  - **CNN + Attention Mechanism** (học mối quan hệ không gian tốt hơn)
    - CNN mạnh trong việc trích xuất đặc trưng cục bộ.

- Attention Mechanism cho phép mô hình:
  - Tập trung vào các vùng quan trọng trong ảnh
  - Học mối quan hệ không gian rộng hơn giữa các vùng ảnh
- Sự kết hợp này giúp:
  - Cải thiện khả năng nhận diện các đối tượng có cấu trúc phức tạp
  - Tăng độ chính xác khi so khớp ảnh trong điều kiện biến đổi mạnh
- **Ví dụ:** CNN backbone + Spatial Attention / Self-Attention module.
- **Siamese Network + Transformer** (so khớp ảnh hiệu quả hơn)
  - Siamese Network học **độ tương đồng giữa các ảnh**.
  - Transformer giúp:
    - Mô hình hóa mối quan hệ toàn cục giữa các vùng ảnh
    - Khai thác tương tác phức tạp giữa hai ảnh đầu vào
  - Kết hợp này đặc biệt hiệu quả cho:
    - Photo Matching yêu cầu độ chính xác cao
    - Các bài toán so khớp ảnh ở quy mô lớn
- **Self-Supervised + Triplet Loss** (tăng hiệu quả với dữ liệu không có nhãn)
  - SSL được dùng để: Tiềm huấn luyện bộ trích xuất đặc trưng từ dữ liệu không gán nhãn
  - Triplet Loss được dùng để: Tinh chỉnh không gian embedding dựa trên quan hệ tương đối giữa các ảnh
  - Cách tiếp cận này:
    - Giảm phụ thuộc vào dữ liệu gán nhãn
    - Nâng cao khả năng phân tách của không gian đặc trưng
  - **Phù hợp với:** các bài toán có dữ liệu lớn nhưng nhãn hạn chế.
- **Ưu điểm**
  - Khai thác đồng thời:
    - Đặc trưng cục bộ và toàn cục
    - Quan hệ cặp và quan hệ tương đối
  - Nâng cao độ chính xác và khả năng tổng quát hóa.
  - Linh hoạt, dễ điều chỉnh theo yêu cầu bài toán cụ thể.
- **Hạn chế**
  - Kiến trúc phức tạp, khó thiết kế và tinh chỉnh.
  - Chi phí tính toán và thời gian huấn luyện cao.
  - Yêu cầu kinh nghiệm để lựa chọn cấu hình phù hợp.

## 5. Triển khai bài toán Photo Matching sử dụng Mạng Nơ-ron Tích Chập (CNN) với PyTorch.

- **Ý tưởng:**
  - Sử dụng CNN để trích xuất đặc trưng ảnh.
  - So sánh đặc trưng giữa hai ảnh bằng khoảng cách **Cosine Similarity** hoặc **Euclidean Distance**.
  - Huấn luyện mô hình bằng cách sử dụng một tập dữ liệu có cặp ảnh giống nhau và khác nhau.
  - Bài toán *Photo Matching* được triển khai dựa trên giả định rằng **hai ảnh giống nhau sẽ có biểu diễn đặc trưng gần nhau trong không gian embedding**, trong khi các ảnh khác nhau sẽ nằm xa nhau.
- **Giải pháp:**
  - Sử dụng CNN để trích xuất đặc trưng ảnh.
  - Dùng mạng Siamese để học mối quan hệ giữa hai ảnh.
  - Huấn luyện bằng Contrastive Loss để tối ưu hóa khả năng so khớp ảnh.
- **Triển khai:**
  1. Cài đặt các thư viện torch, torchvision
  2. Import các thư viện cần thiết
    - torch.nn, torch.optim
    - torchvision.transforms
    - Các thư viện hỗ trợ xử lý ảnh...
  3. Chuẩn bị Dataset, sử dụng Siamese Dataset, tức là mỗi lần huấn luyện, chúng ta lấy một cặp ảnh (positive nếu giống nhau, negative nếu khác nhau).
    - **Positive pair**: hai ảnh giống nhau
    - **Negative pair**: hai ảnh khác nhau
    - Mỗi mẫu dữ liệu gồm: Ảnh 1, Ảnh 2, Nhãn (0 hoặc 1) thể hiện mức độ giống nhau
    - Dataset này giúp mô hình không học phân loại mà học **độ tương đồng giữa hai ảnh**
  4. Xây dựng mạng CNN. Mạng CNN được sử dụng để trích xuất đặc trưng ảnh.
    - Lớp phân loại cuối cùng được loại bỏ.
    - Đầu ra là **vector đặc trưng (embedding)** có số chiều cố định.
  5. Xây dựng Mạng Photo Matching. **Mạng Siamese** được sử dụng để tính khoảng cách giữa hai đặc trưng và dự đoán ảnh có giống nhau không.
  6. Hàm Mất Mát và Optimizer. Hàm **Contrastive Loss**, giúp mô hình học cách đưa các ảnh giống nhau lại gần và đẩy ảnh khác nhau ra xa (Giảm khoảng cách với cặp ảnh giống nhau; Tăng khoảng cách với cặp ảnh khác nhau)
  7. Huấn luyện mô hình
    - **Trong mỗi epoch:**
      - Lấy các cặp ảnh từ Siamese Dataset
      - Tính loss
      - Lan truyền ngược (backpropagation)
      - Cập nhật trọng số
    - Theo dõi: Giá trị loss. độ hội tụ của mô hình

## 8. Đánh giá kết quả

- Đánh giá mô hình trên tập kiểm tra:
  - Accuracy
  - Precision / Recall (nếu cần)
- Phân tích:
  - Khoảng cách trung bình giữa các cặp ảnh giống nhau
  - Khoảng cách giữa các cặp ảnh khác nhau
- Kiểm tra khả năng tổng quát hóa của mô hình.

**Danh mục tài liệu sử dụng:**

- **Tài liệu học phần:** TS. Nguyễn Thị Khánh Tiên, *Chương 3: Phát hiện đặc trưng và đối sánh ảnh (Part 2)*, Slide Học phần Xử lý ảnh & Thị giác máy tính, Viện Công Nghệ Thông Tin, Điện & Điện Tử, Trường Đại Học Giao Thông Vận Tải Tp.HCM.
- **Tham khảo:** Các công cụ AI hỗ trợ.