


Chương 4: Phân đoạn ảnh - Image Segmentation

Nội dung


1. Các bài toán và ứng dụng của Computer Vision	2
2. Giới thiệu về phân đoạn ảnh	2
3. Các loại tác vụ phân đoạn ảnh	4
4. Đánh giá hiệu suất phân đoạn ảnh	4
4.1. Các chỉ số đánh giá phổ biến	5
4.2. Thách thức trong đánh giá	7
4.3. Các phương pháp đánh giá	8
5. Phương pháp phân đoạn ảnh	8
5.1. Phân ngưỡng (Thresholding)	9
5.2. Phân vùng (Region based segmentation)	10
5.3. Phân vùng dựa trên biên/cạnh (Edge segmentation)	12
5.4. Clustering-based Segmentation	13
6. Mô hình Phân đoạn Ngữ nghĩa (Semantic Segmentation)	15
7. SegNet, U-Net	18
8. DeepLab, PSPNet	20

1. Các bài toán và ứng dụng của Computer Vision





2. Giới thiệu về phân đoạn ảnh

- Phân đoạn ảnh là một kỹ thuật quan trọng trong xử lý ảnh và thị giác máy tính, nhằm chia một hình ảnh thành các vùng đồng nhất về màu sắc, kết cấu hoặc các đặc trưng khác.
- Mỗi vùng này thường tương ứng với một đối tượng hoặc một phần của đối tượng trong hình ảnh.
- Mục tiêu:** Thay vì chỉ phát hiện đối tượng (Object Detection), phân đoạn giúp máy tính hiểu rõ từng pixel thuộc về đối tượng nào, từ đó hiểu sâu hơn về nội dung và mối quan hệ giữa các đối tượng trong ảnh.
- Lĩnh vực này cũng được biết đến bởi lịch sử nghiên cứu, phát triển lâu dài, với các công trình đầu tiên ra mắt vào đầu năm 1970-1972.




- **Tại sao phân đoạn ảnh lại quan trọng?**

- *Hiểu rõ hơn về nội dung hình ảnh:* Phân đoạn giúp máy tính hiểu được các đối tượng có trong hình, mối quan hệ giữa chúng, từ đó thực hiện các tác vụ phức tạp hơn như **nhận dạng đối tượng, theo dõi chuyển động**.
- *Truy xuất thông tin hiệu quả:* Khi hình ảnh được chia thành các vùng, việc **tìm kiếm, trích xuất thông tin từ hình ảnh trở nên dễ dàng** hơn.
- *Ứng dụng rộng rãi:* Phân đoạn ảnh có nhiều ứng dụng thực tế như:
 - *Y tế:* Phân tích hình ảnh y tế để phát hiện bệnh tật.
 - *Tự lái xe:* Nhận biết các đối tượng trên đường để điều khiển xe.
 - *Giám sát an ninh:* Phát hiện các hoạt động bất thường trong hình ảnh.
 - *Biên tập ảnh:* Tách nền, thay đổi màu sắc các vùng trong ảnh.
 - *Thương mại điện tử:* Thử đồ ảo.
 - ...



3. Các loại tác vụ phân đoạn ảnh

- Phân đoạn ảnh có thể được chia thành ba nhóm tác vụ dựa trên số lượng và loại thông tin mà chúng truyền tải:
 - **Phân đoạn ngữ nghĩa (Semantic Segmentation):**
 - Gán nhãn cho **mỗi pixel trong hình ảnh với một lớp ngữ nghĩa** (ví dụ: người, xe, cây).
 - Không phân biệt các đối tượng riêng lẻ cùng loại
 - Ví dụ: Nếu có 3 người trong ảnh, cả 3 đều được gán nhãn "người" nhưng không phân biệt người 1, 2, 3.
 - **Phân đoạn trường hợp (Instance Segmentation):**
 - **Phân biệt các đối tượng cùng loại**
 - Ví dụ: 3 người sẽ được gán nhãn "người 1", "người 2", "người 3" riêng biệt
 - Quan trọng trong các ứng dụng cần đếm số lượng đối tượng
 - Ví dụ: nhiều người trong một hình ảnh – tìm số lượng người trong ảnh.
 - **Phân đoạn Panoptic:** Kết hợp cả phân đoạn ngữ nghĩa và phân đoạn trường hợp. Đây là bài toán khó nhất và toàn diện nhất.



4. Đánh giá hiệu suất phân đoạn ảnh


- Việc đánh giá hiệu suất của các thuật toán phân đoạn ảnh là một bước quan trọng để so sánh và lựa chọn thuật toán phù hợp cho từng bài toán cụ thể.
- Có nhiều chỉ số và phương pháp đánh giá khác nhau, nhưng mục tiêu chung là đo lường mức độ trùng khớp giữa kết quả phân đoạn của thuật toán với nhãn ground truth (nhãn đánh dấu thủ công).

4.1. Các chỉ số đánh giá phổ biến

- **Intersection over Union (IoU) hoặc Jaccard Index:**

- Đo lường **tỷ lệ phần giao** giữa vùng dự đoán và vùng ground truth¹ so với phần hợp của chúng.
 - **Phần giao:** Là chỗ mà cả máy và thực tế đều đồng ý là "đúng vật thể".
 - **Phần hợp:** Là tổng diện tích của cả hai vùng cộng lại (trừ đi phần trùng lặp để không tính 2 lần).
- **Giá trị IoU càng cao, độ chính xác của phân đoạn càng tốt.**
 - Đây là chỉ số khắt khe nhất. Vì IoU tính cả phần giao và phần hợp, nên con số của nó thường thấp hơn cảm nhận trực quan của mắt người.
 - **< 0.5 (Tệ/Bad):** Vùng dự đoán bị lệch quá nhiều, hoặc chỉ trúng một phần nhỏ vật thể. Trong các cuộc thi (như COCO), IoU < 0.5 thường bị coi là **False Positive** (dự đoán sai).
 - **0.5 - 0.7 (Chấp nhận được/Acceptable):** Mức sàn chung. Máy nhận diện đúng vị trí, nhưng đường viền chưa sát, còn bị lem hoặc thiếu.
 - **0.7 - 0.9 (Tốt/Good):** Kết quả rất khả quan. Đường viền bám khá sát vật thể. Hầu hết các mô hình SOTA (State-of-the-art) hiện nay phần đầu đạt mức này.
 - **> 0.9 (Xuất sắc/Excellent):** Gần như hoàn hảo, khó phân biệt với nhãn dán bằng tay của con người.

$$IoU = \frac{\text{Area of Intersection}}{\text{Ground Truth Area} + \text{Predicted Box Area} - \text{Area of Intersection}}$$




¹ **Ground Truth** (thường dịch là **Nhãn thực tế**) là khái niệm chỉ **đáp án đúng tuyệt đối** mà chúng ta mong muốn mô hình máy tính đạt được. **VD: Input:** Ảnh một quả táo; **Ground Truth:** Một cái nhãn (text hoặc số) nói rằng: Class = "Apple" hoặc ID = 1.

- **Sự thật thú vị:** Độ chính xác của mô hình AI không bao giờ vượt quá độ chính xác của Ground Truth. Nếu Ground Truth sai (người gán nhãn ẩu), mô hình sẽ học cái sai đó (Garbage In, Garbage Out).
- **Tại sao gọi là "Ground" (Mặt đất)?** Thuật ngữ này mượn từ ngành địa chất/khí tượng. Vệ tinh chụp ảnh từ trên trời nói "Chỗ này có mỏ vàng". Đó là **dự đoán** từ xa → Nhà địa chất phải đi đến tận nơi, đào đất lên kiểm tra xem có vàng thật không. Đó là bằng chứng từ mặt đất (**Ground Truth**).

- **Pixel Accuracy:** Tỷ lệ **số lượng pixel được phân loại đúng** trên **tổng số pixel**.
 - Để xem có bao nhiêu điểm ảnh máy đoán đúng (đúng cả nền và vật thể).
 - **Ví dụ:** Bạn có bức ảnh bầu trời (95% diện tích) và một chiếc máy bay nhỏ xíu (5% diện tích).
 - Nếu mô hình AI "lười biếng", nó đoán **toàn bộ bức ảnh là bầu trời** (bỏ qua máy bay).
 - Kết quả: Nó đoán đúng 95% số pixel (phần bầu trời). **Pixel Accuracy = 95%**.
 - → Chỉ số rất cao nhưng mô hình hoàn toàn vô dụng vì không tìm thấy máy bay. Đây gọi là vấn đề **mất cân bằng dữ liệu (Class Imbalance)**.
 - **< 80% (Rất Tệ):** Mô hình hỏng hoàn toàn. Ngay cả nền (background) nó cũng đoán sai.
 - **80% - 90% (Thường/Average):** Nghe có vẻ cao, nhưng trong bài toán segmentation, mức này thường đồng nghĩa với việc các vật thể nhỏ bị bỏ qua hoàn toàn.
 - **> 95% (Tạm ổn/Decent):** Bắt đầu có giá trị sử dụng.
 - **> 98-99% (Tốt):** Mức cần thiết cho các ứng dụng thực tế (như xe tự lái), nhưng vẫn phải kiểm tra lại bằng IoU để chắc chắn không bỏ sót vật nhỏ.
- **Mean IoU (mIoU):** **Giá trị trung bình của IoU trên tất cả các lớp.**
 - Để khắc phục điểm yếu của Pixel Accuracy và đánh giá công bằng hơn cho mọi đối tượng.
 - **Ví dụ:** Bài toán phân đoạn cảnh đường phố gồm 3 lớp: Đường đi, Ô tô, và Người đi bộ.
 - Tính IoU cho **Đường đi** (vùng rất to): Được 0.9.
 - Tính IoU cho **Ô tô**: Được 0.8.
 - Tính IoU cho **Người đi bộ** (vùng rất nhỏ): Máy đoán sai nhiều, chỉ được 0.4.
 - $mIoU = (0.9 + 0.8 + 0.4) / 3 = 0.7$
 - **Ý nghĩa:** **mIoU trừng phạt nặng nếu mô hình đoán sai các vật thể nhỏ** (như người đi bộ), buộc mô hình phải học tốt tất cả các lớp.
- **Dice Coefficient (F1-Score):** **Tương tự như IoU** nhưng có cách tính hơi khác, thường được sử dụng trong các bài toán y tế (như tách khối u, mạch máu).

$$Dice = \frac{2 \times \text{Diện tích phần giao}}{\text{Diện tích vùng dự đoán} + \text{Diện tích vùng thực tế}} =$$



- **Sự khác biệt với IoU:** Dice nhân đôi phần giao (Intersection). Điều này có nghĩa là nó **nhấn mạnh vào việc tìm đúng (khớp) đối tượng** hơn là việc bị lem ra ngoài một chút.
 - **< 0.6 (Tệ):** Độ khớp kém.
 - **0.6 - 0.8 (Khá/Good):** Phổ biến trong các bài báo y tế. Các vùng tổn thương đã được phát hiện đúng vị trí, dù hình dáng chưa khớp 100%.
 - **> 0.8 (Rất tốt/Very Good):** Tiêu chuẩn vàng cho các mô hình y tế chất lượng cao.
 - **> 0.9 (Tuyệt vời):** Rất hiếm gặp ở các ca khó (như khối u nhỏ).

● Boundary F1-score:

- Các chỉ số trên (IoU, Dice) đều dựa trên **diện tích** (vùng bên trong). Nhưng đôi khi, diện tích đúng nhưng **đường viền** lại nham nhở, răng cưa. BF-score sinh ra để kiểm tra độ "mượt" và chính xác của đường viền.
- Đánh giá độ chính xác của đường biên phân đoạn.
- Nó kiểm tra xem đường viền (contour) của vùng dự đoán có nằm sát với đường viền thực tế hay không (trong một khoảng cách cho phép).
- **VD:** Trong bài toán **xe tự lái**: Việc phân đoạn làn đường cần độ chính xác cực cao ở phần mép đường (boundary) để xe không lao xuống ruộng. Dù diện tích mặt đường tô đúng 99% nhưng mép đường bị lệch 10cm cũng có thể gây tai nạn. Lúc này, Boundary F1-score quan trọng hơn IoU.
 - **< 0.5 (Tệ):** Đường viền nham nhở, răng cưa hoặc bị lệch xa so với thực tế.
 - **0.6 - 0.8 (Ổn):** Đường viền bám theo hình dáng vật thể nhưng chưa mượt.
 - **> 0.8 (Tốt):** Đường cắt sắc nét, mượt mà (giống như dùng Pen Tool trong Photoshop). Rất quan trọng trong bài toán **Portrait Mode** (chụp ảnh xóa phông) hay **Matting** (tách nền xanh).



Tuy nhiên, cần nhớ một "quy tắc vàng": Giá trị thế nào là Tốt phụ thuộc hoàn toàn vào độ khó của bài toán.

- **Phân đoạn một quả táo trên nền trắng: IoU 0.9 là bình thường.**
- **Phân đoạn khối u nhỏ xíu, mờ nhạt trong ảnh X-quang: IoU 0.7 đã là một kỳ tích.**

Khi báo cáo kết quả đồ án hay nghiên cứu, đừng chỉ đưa ra một con số trơ trọi. Hãy so sánh nó với các phương pháp khác (Baseline) hoặc các bài báo đi trước (SOTA). Ví dụ: "Mặc dù IoU chỉ đạt 0.65, nhưng đây là mức cải thiện lớn so với mô hình cũ (chỉ đạt 0.55) trên tập dữ liệu khó này."

4.2. Thách thức trong đánh giá

- **Đánh giá chủ quan.** Việc đánh giá trực quan có thể bị ảnh hưởng bởi yếu tố chủ quan của người đánh giá.
- **Sự đa dạng của dữ liệu.** Các thuật toán **có thể hoạt động tốt trên một loại hình ảnh nhưng lại kém hiệu quả trên loại hình ảnh khác.**
- **Độ phức tạp của bài toán.** Các bài toán phân đoạn phức tạp như phân đoạn trường hợp, phân đoạn panoptic **đòi hỏi các tiêu chí đánh giá phức tạp hơn.**


4.3. Các phương pháp đánh giá

- **So sánh trực quan.** **Quan sát trực quan** kết quả phân đoạn để **đánh giá** chất lượng một cách **chủ quan**.
- **Đánh giá định lượng.** **Tính toán các chỉ số đánh giá** trên một tập dữ liệu lớn.
- **Đánh giá so sánh.** **So sánh kết quả của các thuật toán khác nhau trên cùng một tập dữ liệu.**
- **Đánh giá trên các tập dữ liệu tiêu chuẩn.** Sử dụng các tập dữ liệu tiêu chuẩn như Pascal VOC, COCO để đánh giá và so sánh các thuật toán.


5. Phương pháp phân đoạn ảnh

- **Phương pháp truyền thống:**
 - **Phân ngưỡng:** Chia hình ảnh thành hai vùng dựa trên một ngưỡng cường độ,
 - **Phân vùng dựa trên vùng:** Tìm các vùng đồng nhất dựa trên các đặc trưng như màu sắc, kết cấu,...
 - **Phân vùng dựa trên biên:** Tìm các đường biên giữa các vùng khác nhau.

Các phương pháp phân đoạn truyền thống chủ yếu dựa trên các nguyên lý toán học và thống kê, không sử dụng mạng nơ-ron sâu. Mặc dù có độ phức tạp thấp và dễ triển khai, các phương pháp này thường gặp hạn chế khi xử lý ảnh phức tạp hoặc bị nhiễu.




- **Phương pháp dựa trên học sâu:**
 - Transformer
 - Mạng nơ-ron tích chập: Các mạng như U-Net, DeepLabv3+... **to learn hierarchical features** from large datasets to predict pixel-level labels.



5.1. Phân ngưỡng (Thresholding)

- Một trong những phương pháp phân đoạn hình ảnh đơn giản nhất
- ***Ngưỡng được đặt để chia pixel thành hai lớp.*** Các pixel có giá trị lớn hơn giá trị ngưỡng được đặt thành 1 trong khi các pixel có giá trị nhỏ hơn giá trị ngưỡng được đặt thành 0.
- Do đó, hình ảnh được chuyển đổi thành bản đồ nhị phân, dẫn đến **quá trình thường được gọi là nhị phân hóa.**



- **Các phương pháp phân ngưỡng phổ biến:**

- **Phân ngưỡng toàn cục:** Sử dụng một ngưỡng duy nhất cho toàn bộ hình ảnh.
 - **Ngưỡng cố định:** Chọn ngưỡng dựa trên kinh nghiệm hoặc kiến thức về hình ảnh.
 - **Ngưỡng tự động:** Sử dụng các thuật toán để tính toán ngưỡng tự động, ví dụ:
 - **Otsu's method:** Tìm ngưỡng tối ưu hóa sự phân tách giữa các vùng foreground và background.
 - **Phương pháp dựa trên histogram:** Phân tích histogram của hình ảnh để tìm ngưỡng thích hợp.
- **Phân ngưỡng cục bộ:** Sử dụng các ngưỡng khác nhau cho các vùng khác nhau của hình ảnh.
 - **Adaptive thresholding:** Tính toán ngưỡng dựa trên thông tin cục bộ của mỗi pixel.

- **Ưu điểm:**


- Đơn giản, dễ thực hiện.
- Hiệu quả cao với các hình ảnh có độ tương phản cao giữa đối tượng và nền.

- **Nhược điểm:**

- Khó chọn ngưỡng phù hợp với các hình ảnh phức tạp, có nhiều mức xám.
- Không hiệu quả với các hình ảnh có nhiễu hoặc có độ tương phản thấp.

5.2. Phân vùng (Region based segmentation)

- Một kỹ thuật phân đoạn ảnh dựa trên sự tương đồng giữa các pixel lân cận thay vì chỉ xét từng pixel độc lập.
- Nó chia ảnh thành các vùng đồng nhất dựa trên các đặc trưng như cường độ màu sắc, độ dốc, hoặc kết cấu.
- Phương pháp phân vùng tiếp cận bài toán theo hướng “từ trong ra ngoài”, tức là bắt đầu từ việc hình thành các vùng đồng nhất trước, sau đó ranh giới giữa các vùng sẽ được xác định một cách gián tiếp. Nhờ đó, kết quả phân đoạn thường tạo ra các vùng liền mạch và có ý nghĩa trực quan hơn.



- **Ưu điểm:**

- Kết quả phân đoạn thường mịn và ít bị nhiễu.
- Có thể xử lý các ảnh có độ phức tạp cao.

- **Hạn chế:**

- Phụ thuộc vào việc chọn các hạt nhân ban đầu hoặc các tiêu chí chia tách/hợp nhất.
- Có thể bị ảnh hưởng bởi nhiễu trong ảnh.

- **Các phương pháp phân vùng phổ biến:**

- **Region Growing:**

- Khởi đầu từ một **pixel hạt nhân (seed pixel)**.
 - Lần lượt kiểm tra các pixel lân cận của hạt nhân.
 - **Nếu một pixel lân cận thỏa mãn một số tiêu chí** (ví dụ: độ chênh lệch cường độ nhỏ hơn một ngưỡng), **nó được gán vào vùng đang phát triển**.
 - Quá trình này tiếp tục cho đến khi không còn pixel nào thỏa mãn tiêu chí.
 - *Ưu điểm là thuật toán dễ hiểu, dễ triển khai và thường tạo ra các vùng phân đoạn mượt mà, ít bị đứt gãy.*
 - *Nhược điểm lớn của phương pháp này là kết quả phụ thuộc nhiều vào việc lựa chọn seed ban đầu cũng như tiêu chí đánh giá sự tương đồng. Trong trường hợp ảnh bị nhiễu hoặc seed được chọn không phù hợp, vùng có thể bị lan sai hoặc bị trộn lẫn với vùng khác.*

- **Split and Merge:**

- Ban đầu, **toàn bộ ảnh được xem như một vùng duy nhất**. Thuật toán sẽ kiểm tra mức độ đồng nhất của vùng này dựa trên một tiêu chí nhất định, chẳng hạn như phương sai cường độ sáng.
 - Nếu vùng không đồng nhất, nó sẽ được chia nhỏ thành các vùng con, thường theo dạng chia bốn (quadtree). Quá trình chia tiếp tục lặp lại cho đến khi tất cả các vùng con đều đạt được tính đồng nhất theo tiêu chí đặt ra.
 - Sau bước chia, thuật toán tiến hành giai đoạn hợp nhất (merge). *Nếu hai vùng lân cận có độ tương đồng cao, chúng được hợp nhất.*
 - Quá trình này lặp lại cho đến khi không còn thay đổi.
 - *Phương pháp này có khả năng kiểm soát tốt kích thước và tính đồng nhất của các vùng. Tuy nhiên, nhược điểm của phương pháp này là độ phức tạp tính toán cao và việc lựa chọn tiêu chí chia – hợp nhất ảnh hưởng mạnh đến chất lượng phân đoạn cuối cùng.*

- **Watershed Segmentation:**

- Trong cách tiếp cận này, cường độ sáng của pixel được xem như độ cao của địa hình, trong đó các vùng tối tương ứng với thung lũng và các vùng sáng tương ứng với đỉnh núi.
 - Xử lý ảnh để tạo ra một hàm gradient → **Tìm các điểm cực tiểu** trong hàm gradient, gọi là các điểm bắt đầu. Mỗi điểm bắt đầu được coi là một nguồn nước.
 - Thuật toán giả lập quá trình **“đổ nước” vào các điểm cực tiểu của bề mặt địa hình**. Khi mực nước dâng lên, nước từ các thung lũng khác nhau sẽ lan rộng ra xung quanh, tạo thành các vùng.
 - Các vùng gặp nhau tại các điểm đỉnh (watershed lines).
 - Khi nước từ hai vùng khác nhau gặp nhau, một đường ranh giới sẽ được hình thành để ngăn không cho các vùng này hòa vào nhau. Các đường ranh giới đó chính là kết quả phân đoạn ảnh.
 - *Ưu điểm là xác định ranh giới vùng rất rõ ràng và phù hợp với các bài toán cần phân đoạn chi tiết.*

- Tuy nhiên, phương pháp này **đặc biệt nhạy cảm với nhiễu và thường dẫn đến hiện tượng phân đoạn quá mức (over-segmentation), trong đó ảnh bị chia thành quá nhiều vùng nhỏ.** Do đó, trong thực tế, Watershed thường được kết hợp với các bước tiền xử lý như làm mượt ảnh hoặc sử dụng marker để kiểm soát số lượng vùng phân đoạn.

5.3. Phân vùng dựa trên biên/cạnh (Edge segmentation)

- Một kỹ thuật phân đoạn ảnh **tập trung vào việc phát hiện các cạnh (edge)** trong hình ảnh.
- Các cạnh thường đánh dấu sự thay đổi đột ngột về cường độ pixel, màu sắc hoặc kết cấu, và chúng thường tương ứng với các biên giới của các đối tượng trong hình ảnh.
- **Nguyên tắc:** Object/Vật thể được xác định nếu những vùng xác định có đường biên khép kín.
- **Ưu điểm:**
 - Đơn giản và hiệu quả.
 - Dễ dàng triển khai.
 - Phù hợp với các ảnh có các cạnh rõ ràng.
- **Hạn chế:**
 - Khó xử lý các ảnh có nhiễu nhiều hoặc các cạnh không liên tục.
 - Khó phân đoạn các vùng có kết cấu đồng nhất.
 - Không thể phân đoạn các vùng có biên mờ.



- **Các bước thực hiện:**

1. Tiền xử lý:

- **Loại bỏ nhiễu:** Sử dụng các bộ lọc như Gaussian để làm mịn hình ảnh và giảm nhiễu. Máy tính rất nhạy thơ, nó sẽ tưởng mấy hạt sạn này là các cạnh quan trọng.
- **Tăng cường cạnh:** Sử dụng các toán tử vi phân để làm nổi bật các cạnh.

2. Phát hiện cạnh:

- Sử dụng các toán tử vi phân như **Sobel, Canny, Laplacian** để tìm các điểm có sự thay đổi đột ngột về cường độ pixel.
- Máy tính dò từng điểm ảnh, chỗ nào màu đang tối vụt chuyển sang sáng (hoặc ngược lại) → Đó là cạnh.
- Sau bước này, ta thường thu được một bức ảnh đen trắng với các đường viền. **Tuy nhiên**, các đường này thường **bị đứt đoạn, rời rạc**, lấm tấm chứ không liền mạch (do ánh sáng không đều hoặc vật thể bị che khuất).

3. Kết nối các cạnh:

- Các cạnh được kết nối lại với nhau để tạo thành các đường viền bao quanh các đối tượng.
- Từ các nét đứt rời rạc ở bước 2, ta phải nối chúng lại thành một vòng khép kín.
- *Một số phương pháp:*
 - + **Hough transform/HoG:** Sử dụng để phát hiện các đường thẳng và đường cong trong hình ảnh. *Dùng khi ta đoán vật thể có hình dáng hình học rõ ràng (đường thẳng, hình tròn). Nó sẽ tự động "điền vào chỗ trống" để tạo ra hình hoàn chỉnh.*
 - + **Graph-based methods:** Xây dựng một đồ thị trong đó **các nút là các điểm ảnh và các cạnh là các kết nối giữa các điểm ảnh**. Sử dụng các thuật toán tìm kiếm đường đi ngắn nhất để kết nối các cạnh.
- Cần nhìn vào **"nguyên tắc" của bức hình** để chọn được cách để **kết nối các cạnh miễn sao cho khép kín thì mới phân vùng được**.
 - + Khi một đường biên bị đứt quãng (do nhiễu hoặc độ tương phản thấp), ta phải chọn cách nối dựa trên "nguyên tắc tự nhiên" của hình ảnh:
 - ❖ **Nguyên tắc:** Các cạnh của một vật thể thường có xu hướng **trơn tru và tiếp diễn**.
 - ❖ **Ví dụ:** Nếu bạn đang dò theo cạnh của cái bàn và đường viền bị mất một đoạn 2mm.
 - ❖ **Cách sai:** Nối điểm đó queo gắt 90 độ sang điểm nhiều bên cạnh.
 - ❖ **Cách đúng (theo nguyên tắc):** Nối thẳng tiếp theo hướng cũ, hoặc cong nhẹ theo quỹ đạo cũ để tìm điểm tiếp theo.
 - ❖ **Thuật toán nối cạnh (Edge Linking) phải đủ thông minh để dự đoán hướng đi tiếp theo của đường biên dựa trên đoạn trước đó (Local Processing).**
 - + Tùy vào cái mà bạn đang muốn tìm (tập dữ liệu) mà chọn cách nối cạnh:
 - ❖ **Nếu bài toán là nhận diện biển báo giao thông:** Nguyên tắc của hình là "Hình học cứng" (vuông, tròn, tam giác) → Bạn nên dùng **Hough Transform** vì nó cực giỏi trong việc ép các nét đứt thành đường thẳng hoặc tròn hoàn hảo.
 - ❖ **Nếu bài toán là nhận diện tế bào y tế (hình dạng méo mó tự nhiên):** Nguyên tắc của hình là "Cong mềm mại bất quy tắc" → Bạn không thể dùng Hough. Bạn phải dùng **Graph-based** (đồ thị) hoặc **Snake algorithm** (đường bao di chuyển) để đường biên tự uốn lượn bám theo mép tế bào sao cho năng lượng đường cong là nhỏ nhất.
- *Cần lựa chọn phương pháp cho phù hợp với tập dữ liệu cũng như yêu cầu nghiệp vụ. Không phải bài toán nào cũng cần đạt KQ tốt nhất, khiến cho tài nguyên máy tính không đáp ứng đủ.*

4. Phân vùng: Các vùng bên trong các đường viền được xác định là các vùng phân đoạn.

- Sau khi đã có cái vòng tròn khép kín (contour), máy tính chỉ việc tuyên bố: "Tất cả những gì nằm trong vòng tròn này là Đối tượng A".

5.4. Clustering-based Segmentation

- **Phân cụm (Clustering)** là một loại thuật toán học máy **không giám sát** (dữ liệu không có nhãn), được sử dụng phổ biến trong phân vùng ảnh.
- Một trong những thuật toán Clustering thường được **ứng dụng cho tác vụ phân vùng ảnh là KMeans Clustering**.
- Loại phân cụm này có thể được sử dụng để tạo các phân đoạn trong **một hình ảnh có màu**.

- Quy trình thực hiện:

- 1) Chuyển đổi ảnh thành không gian đặc trưng:

- Mỗi pixel trong ảnh được coi như một điểm dữ liệu trong không gian đặc trưng.
- Không gian đặc trưng phổ biến: RGB, HSV, Lab,...

- 2) Khởi tạo các tâm cụm (centroids): Chọn ngẫu nhiên K điểm trong không gian đặc trưng làm tâm cụm ban đầu.

- 3) Gán nhãn cho các điểm dữ liệu:


- Tính khoảng cách từ mỗi điểm dữ liệu đến các tâm cụm.
- Gán mỗi điểm dữ liệu vào cụm có tâm gần nhất.

- 4) Cập nhật các tâm cụm: Tính trung bình của tất cả tọa độ các điểm dữ liệu trong mỗi cụm để cập nhật tọa độ tâm cụm mới.

- 5) Lặp lại bước 3 và 4: Tiếp tục quá trình gán nhãn và cập nhật tâm cụm cho đến khi các tâm cụm không thay đổi đáng kể hoặc đạt đến số lần lặp tối đa.

- 6) Tạo ảnh phân đoạn: Gán cho mỗi pixel trong ảnh màu sắc tương ứng với cụm mà nó thuộc về.

k-Means Clustering Results ($k = 16$)



- *k-Means Initialization Methods*

- *Method 1:* Select k random feature points as initial centroids. If two points are very close, resample.
- *Method 2:* Select k uniformly distributed means within the range of the distribution.
- *Method 3:* Perform k -means clustering on a subset of pixels and use the result as the initial means.

- Ưu điểm và hạn chế của K-Means trong phân đoạn ảnh:

- Ưu điểm:

- Đơn giản, dễ hiểu.
- Hiệu quả về mặt tính toán.
- Khả năng xử lý ảnh có nhiễu tốt.
- Tiết kiệm tài nguyên.

- Hạn chế:

- Kết quả phụ thuộc vào việc chọn số lượng cụm K và cách khởi tạo các tâm cụm ban đầu.
- Không đảm bảo tìm được giải pháp tối ưu toàn cục.
- Khó xử lý các ảnh có cấu trúc phức tạp.
- Nhạy cảm với nhiễu.

- **Cải tiến và ứng dụng:**

- **Khởi tạo tâm cụm:** Có nhiều phương pháp khởi tạo tâm cụm khác nhau như K-Means++ để cải thiện kết quả.
- **Chọn số lượng cụm K:** Sử dụng các phương pháp như Elbow Method, Silhouette Coefficient.
- **Phân đoạn theo vùng:** Kết hợp với các kỹ thuật khác như region growing, watershed để cải thiện kết quả.


6. Mô hình Phân đoạn Ngữ nghĩa (Semantic Segmentation)

- Một trong những bài toán quan trọng trong lĩnh vực thị giác máy tính, nhằm phân loại từng pixel trong một hình ảnh thành một trong các lớp semantic (ví dụ: người, xe, cây, đường,...).
- Điều này có nghĩa là, **mỗi pixel sẽ được gán một nhãn cụ thể thể hiện loại đối tượng mà nó thuộc về.**
- Phân đoạn ngữ nghĩa giúp máy tính hiểu sâu hơn về hình ảnh, nội dung hình ảnh, không chỉ nhận biết các đối tượng mà còn hiểu mối quan hệ giữa chúng
- **Các kiến trúc DNN (Deep Neural Networks) phổ biến cho bài toán cho phân đoạn ngữ nghĩa:**
 - **U-Net:** Một kiến trúc mạng đối xứng, bao gồm một phần **encoder để trích xuất đặc trưng** và một phần **decoder để khôi phục lại kích thước ban đầu của ảnh** và tạo ra bản đồ phân đoạn.
 - **Fully Convolutional Networks (FCN):** Mở rộng mạng convolutional để thực hiện phân đoạn pixel-level bằng cách thay thế các lớp fully connected cuối cùng bằng các lớp convolutional.
 - **DeepLab:** Một loạt các mô hình dựa trên **Deep Convolutional Neural Networks (DCNNs)**, sử dụng các kỹ thuật như **atrous convolution** và **spatial pyramid pooling** để cải thiện độ phân giải của bản đồ phân đoạn.
 - **PSPNet:** Sử dụng **Pyramid Pooling Module** để thu thập thông tin từ nhiều cấp độ khác nhau của mạng, cải thiện khả năng nắm bắt ngữ cảnh.
 - **ENet:** Một mạng nhẹ và hiệu quả, được thiết kế đặc biệt cho các **thiết bị di động**.
- **Tại sao Semantic Segmentation lại liên quan đến DNN?**
 - **Mạng nơ-ron sâu (DNNs)** là các mô hình máy tính được xây dựng từ nhiều lớp nơ-ron nhân tạo, mô phỏng cách bộ não con người xử lý thông tin.
 - **"Deep"** đề cập đến số lượng các lớp ẩn trong mạng. Các mạng có nhiều lớp ẩn hơn có thể học các mẫu dữ liệu phức tạp hơn.
 - Các phương pháp như **Phân vùng dựa trên biên** hay **K-Means** chỉ dựa vào các thông tin cấp thấp như độ sáng, màu sắc hoặc cạnh. Chúng không thể phân biệt được "lông mèo" và "thảm lông" nếu màu sắc giống nhau. Ngược lại, Semantic Segmentation yêu cầu máy tính phải **hiểu ngữ cảnh và ý nghĩa (semantic) của vật thể** (ví dụ: biết đây là "người", kia là "xe").
 - DNN, đặc biệt là các kiến trúc như **FCN** hay **U-Net**, có khả năng **tự động học các đặc điểm phức tạp từ dữ liệu**. Nó học theo tầng: **các lớp đầu nhận biết cạnh/góc, các lớp sâu hơn nhận biết mắt/mũi, và lớp cuối cùng nhận biết khuôn mặt**. Điều này giúp nó gán nhãn chính xác cho từng pixel dựa trên hình dáng và bối cảnh chứ không chỉ là màu sắc.

• Quy trình huấn luyện một mô hình phân đoạn ngữ nghĩa:

- **Chuẩn bị dữ liệu:** Thu thập một tập dữ liệu lớn gồm các hình ảnh và các bản đồ phân đoạn tương ứng (ground truth).
 - Để máy học được, con người phải tạo ra **Ground Truth** bằng cách tô màu thủ công từng pixel cho hàng nghìn bức ảnh. Chỉ cần tô lem nhem là máy sẽ học sai ngay.
 - Vì dữ liệu quá quý, các kỹ sư thường dùng kỹ thuật **Data Augmentation (Tăng cường dữ liệu)**. Thay vì chỉ dùng 1 ảnh gốc, họ xoay, lật, cắt, hoặc chỉnh độ sáng của ảnh đó để tạo ra 10 biến thể khác nhau, giúp máy học được nhiều tình huống hơn từ cùng một lượng dữ liệu.
- **Chọn kiến trúc mạng:** Lựa chọn một kiến trúc mạng phù hợp với bài toán và tài nguyên tính toán.
 - **Muốn chính xác nhất (ví dụ: Chẩn đoán Y tế):** Chọn các mạng lớn, sâu, phức tạp (như DeepLabV3+ với backbone ResNet-101). Chậm nhưng "soi" rất kỹ.
 - **Muốn nhanh nhất (ví dụ: Xe tự lái, Robot):** Chọn các mạng nhẹ (như ENet, MobileNet). Chấp nhận sai số nhỏ để phản ứng kịp thời gian thực.
- **Huấn luyện:** Sử dụng một **hàm loss phù hợp** (ví dụ: cross-entropy loss) để huấn luyện mô hình.
 - **Cơ chế:** Máy dự đoán xong, hàm Loss sẽ so sánh từng pixel của máy với *Ground Truth*.
 - Hãy tưởng tượng nó giống như giáo viên chấm điểm từng pixel một: "Pixel này máy tô đỏ, đáp án là xanh -> Phạt điểm!".
 - Nếu pixel đó là "Con mèo" mà máy tô thành "Cỏ", hàm Loss sẽ tạo ra một con số phạt rất lớn. Con số này được dùng để điều chỉnh lại hàng triệu tham số trong mạng (thông qua thuật toán *Backpropagation*), giúp lần sau máy đoán đúng hơn.
- **Đánh giá:** Đánh giá hiệu suất của mô hình **trên tập dữ liệu kiểm thử bằng các chỉ số như IoU (Intersection over Union), pixel accuracy**.
 - Nếu bức ảnh có 90% là bầu trời và 10% là máy bay, một mô hình "lười biếng" cứ đoán tất cả là bầu trời thì vẫn đạt độ chính xác 90% (Pixel Accuracy cao), nhưng IoU của lớp máy bay sẽ bằng 0. Đó là lý do ta cần các chỉ số chuyên biệt như IoU.

An overview of Semantic Image Segmentation



Cách máy tính "biến hình" một bức ảnh màu thông thường thành dữ liệu mà nó có thể hiểu để thực hiện **Semantic Segmentation**.

Giai đoạn 1: Từ Ảnh (Input) sang Nhãn (Semantic Labels)

- **Input:** Là bức ảnh cô gái ngồi trên ghế đá. Với mắt thường, ta thấy màu sắc, hình dáng.
- **Segmented (Phân đoạn):** Máy tính đã phân loại từng pixel và gán cho nó một con số (ID) dựa trên bảng chú giải:
 - **1:** Người (Person) - Màu xanh ngọc.
 - **2:** Ghế (Bench) - Màu tím.
 - **3:** Cây/Cỏ (Plant/Grass) - Màu cam.
 - **4:** Mèo (Cat) - Màu xanh dương đậm (ở góc dưới cùng bên trái).
- **Semantic Labels (Ma trận nhãn):** Đây là cái máy tính thực sự nhìn thấy sau khi xử lý. Nó không còn là ảnh màu nữa, **mà là một ma trận số**. Một vùng rộng lớn toàn số **3** (đại diện cho Cây/Cỏ nền), ở giữa là hình dáng của số **1** (Người), và dưới chân là số **4** (Mèo) và số **2** (Ghế).

Giai đoạn 2: One-hot Encoding (Mã hóa One-hot)


- **Khi đưa vào mạng neuron** (như U-Net hay FCN), máy tính không thích làm việc trực tiếp với một ma trận chứa các số 1, 2, 3, 4 lẫn lộn. Tại sao? **Vì máy có thể hiểu nhầm là số 4 (Mèo) có giá trị "lớn hơn" số 1 (Người), trong khi thực tế chúng chỉ là các loại khác nhau.**
- Giải pháp là **One-hot Encoding**: Thay vì **1 lớp** chứa nhiều số (1, 2, 3, 4), ta tách nó ra thành **nhiều lớp (channels)** riêng biệt, mỗi lớp đại diện cho một vật thể.
 - **Lớp "Person":** Tại vị trí có người, giá trị là **1**, **tất cả chỗ khác là 0**.
 - **Lớp "Plant/Grass":** Tại vị trí có cây, giá trị là **1**, **chỗ của người và ghế sẽ là 0**.
 - **Lớp "Bench":** Tương tự, **chỉ chỗ nào có ghế mới bật lên thành 1**.
- **Kết quả:** Đầu ra của mô hình không phải là ảnh 2D, mà là một khối 3D có kích thước: **Chiều cao (Height) x Chiều rộng (Width) x Số lượng lớp (Class)**.

Phân biệt với các bài toán khác (rất hay nhầm)

Bài toán	Đầu ra
Classification	1 nhãn cho cả ảnh
Detection	Bounding box + nhãn
Segmentation	Nhãn cho từng pixel
Instance Segmentation	Phân biệt từng đối tượng riêng lẻ

7. SegNet, U-Net

- **SegNet** là một kiến trúc **mạng thần kinh đối xứng**, được thiết kế đặc biệt cho các bài toán phân đoạn hình ảnh, bao gồm một phần **encoder để trích xuất đặc trưng** và một phần **decoder để khôi phục lại kích thước ban đầu của ảnh và tạo ra bản đồ phân đoạn²**.
- Là một mô hình **deep learning cho semantic segmentation** (gán nhãn cho từng pixel).
- Gọi là **đối xứng (symmetric architecture)** vì: Phần **encoder** (trích xuất đặc trưng) và **decoder** (phục hồi ảnh) có số tầng tương ứng nhau.



- **Đặc điểm nổi bật của SegNet:**
 - **Bộ nhớ nhỏ.** SegNet sử dụng một cơ chế đơn giản để lưu trữ các chỉ số của các vùng **pooling** trong phần encoder, và sử dụng chúng để **upsample** các đặc trưng trong phần decoder. Điều này giúp giảm đáng kể lượng tham số của mô hình so với các mô hình khác.

- **Pooling** là phép toán **giảm kích thước không gian của feature map**, nhằm: Giảm số lượng dữ liệu, Giữ lại đặc trưng quan trọng, Giảm nhiễu và chi phí tính toán

Ví dụ trực quan (Max Pooling)

Giả sử có một feature map 4x4:

```

1 3 2 0
4 6 1 2
5 2 0 1
1 2 3 4

```

Áp dụng **Max Pooling 2x2**:

```

max(1,3,4,6) = 6
max(2,0,1,2) = 2
max(5,2,1,2) = 5
max(0,1,3,4) = 4

```

Kết quả (2x2):

```

6 2
5 4

```

- **Vì sao cần Pooling?** Giảm $H \times W \rightarrow$ tăng tốc; Tăng tính bất biến với dịch chuyển nhỏ; Tránh overfitting
- SegNet không chỉ pooling mà còn Lưu lại vị trí của giá trị lớn nhất (**pooling indices**) $\rightarrow$ Chỉ số này sẽ được dùng cho upsample ở decoder.

² Bản đồ phân đoạn (segmentation map) là kết quả đầu ra của bài toán phân đoạn ảnh, trong đó mỗi pixel của ảnh được gán một nhãn (label) cụ thể để biểu thị nó thuộc về đối tượng hoặc lớp nào.

Ví dụ: Giá trị max = 6; Vị trí = (1,1)

- **Upsample** là quá trình **tăng kích thước feature map**, nhằm: Khôi phục kích thước ban đầu của ảnh & Tạo ra bản đồ phân đoạn

- Dùng **chỉ số pooling đã lưu**
- Đặt giá trị đúng vị trí cũ
- Các vị trí khác = 0

Ví dụ:

Pooling:

[1 3] max = 3 (vị trí 1)
[2 0]

Upsample:

[0 3]
[0 0]

- **Hiệu quả tính toán.** Nhờ cơ chế đơn giản này, SegNet có **tốc độ huấn luyện và suy luận nhanh hơn** so với các mô hình khác. *Tuy nhiên, thông thường cái gì nhanh thì hiệu quả sẽ thấp hơn.*

- **U-Net** là một kiến trúc **mạng thần kinh đối xứng**, có cấu trúc hình chữ U đặc trưng, phức tạp hơn so với SegNet, với một **phần encoder để trích xuất đặc trưng** và một **phần decoder để khôi phục lại kích thước ban đầu của ảnh và tạo ra bản đồ phân đoạn**.
- U-Net được thiết kế ban đầu cho **segmentation ảnh y tế**.
- **Đặc điểm nổi bật của U-Net:**


- **Khả năng khôi phục chi tiết.** U-Net sử dụng các **kết nối skip** để kết hợp các đặc trưng từ các lớp encoder với các lớp decoder tương ứng, giúp khôi phục lại các chi tiết nhỏ trong hình ảnh.

- **Skip connection là gì? Nối trực tiếp:**

Feature map encoder Với feature map decoder cùng mức

- **Lợi ích:** Decoder nhận được: Thông tin ngữ nghĩa (từ tầng sâu) & Thông tin không gian chi tiết (từ tầng nông) → Đây là lý do U-Net rất mạnh trong việc giữ biên và chi tiết nhỏ.


- **Hiệu quả cao:** U-Net đã đạt được kết quả rất tốt trên nhiều bài toán phân đoạn hình ảnh, đặc biệt là trong lĩnh vực y tế, lane detection...




Tính năng	SegNet	U-Net
Cấu trúc	Đối xứng, sử dụng chỉ số pooling	Đối xứng, sử dụng kết nối skip
Bộ nhớ	Nhỏ	Lớn hơn SegNet
Tốc độ	Nhanh	Chậm hơn SegNet
Khả năng khôi phục chi tiết	Tốt	Rất tốt

8. DeepLab, PSPNet

- **DeepLab** là một loạt các mô hình được phát triển bởi **Google Research**, nhằm *cải thiện độ chính xác của phân đoạn ngữ nghĩa* bằng cách sử dụng các kỹ thuật **atrous convolution và spatial pyramid pooling**.
 - **Atrous convolution**: Thay vì giảm kích thước của feature map bằng cách **tăng stride của lớp convolutional**, atrous convolution giữ nguyên kích thước của feature map bằng cách chèn các zero vào giữa các kernel. Điều này giúp mạng có thể nắm bắt được thông tin ở nhiều tỷ lệ khác nhau mà không cần giảm kích thước của feature map.
 - 🖐️ **Nhìn được xa hơn mà không làm ảnh bị nhỏ đi**
 - Bạn đang nhìn một bức tranh:
 - *Cách 1 (convolution thường + stride lớn)*: Bạn lùi ra xa để nhìn toàn cảnh → nhìn rộng hơn **nhưng chi tiết mờ đi**
 - *Cách 2 (atrous convolution)*: Bạn vẫn đứng nguyên chỗ, nhưng **mở rộng tầm mắt** → nhìn rộng hơn **mà vẫn thấy rõ**
 - **Spatial pyramid pooling**: Mô đun này **chia feature map thành các vùng có kích thước khác nhau và thực hiện pooling trên mỗi vùng**. Sau đó, các feature thu được từ các vùng này được kết hợp lại để tạo ra một biểu diễn ngữ cảnh phong phú hơn.
 - 🖐️ **Nhìn ảnh ở nhiều mức “zoom” cùng lúc**
 - Lấy ảnh đặc trưng (feature map)
 - Chia ra: 1 vùng lớn (toàn ảnh), Vài vùng trung bình, Nhiều vùng nhỏ
 - Với mỗi vùng: Lấy thông tin quan trọng nhất
 - Sau đó ghép tất cả thông tin lại
- **Các phiên bản của DeepLab**:
 - **DeepLabv1**: Sử dụng **atrous convolution** để tăng tỷ lệ lấy mẫu và cải thiện độ phân giải của bản đồ phân đoạn. Nhưng chưa khai thác tốt ngữ cảnh đa tỷ lệ.
 - **DeepLabv2**: Kết hợp **atrous spatial pyramid pooling (ASPP)** để nắm bắt thông tin ngữ cảnh ở nhiều tỷ lệ khác nhau.
 - **DeepLabv3**: Sử dụng một **cấu trúc mạng hiệu quả hơn và kết hợp ASPP** với các module khác. Nhưng không có decoder → Phân đoạn tốt nhưng biên chưa thật sắc.
 - **DeepLabv3+**: **Kết hợp các ưu điểm của DeepLabv3 với một decoder** để cải thiện khả năng khôi phục chi tiết → Đây là phiên bản **hoàn thiện nhất**.



- PSPNet (Pyramid Scene Parsing Network)** là một kiến trúc mạng thần kinh được phát triển bởi nhóm nghiên cứu tại Trung Quốc.
 - PSPNet tập trung vào việc **nắm bắt thông tin ngữ cảnh toàn cục** để **cải thiện khả năng phân đoạn các đối tượng có kích thước khác nhau và các vùng có kết cấu phức tạp**.
 - Pyramid pooling module:**
 - Mô đun này chia feature map thành các vùng có kích thước khác nhau và thực hiện pooling trên mỗi vùng.
 - Sau đó, **các feature thu được từ các vùng này được upsample và kết hợp lại với feature map ban đầu**.
 - Điều này **giúp mạng có thể nắm bắt được thông tin ngữ cảnh ở nhiều tỷ lệ khác nhau** và cải thiện khả năng phân đoạn các đối tượng có kích thước khác nhau.



Tính năng	DeepLab	PSPNet
Atrous convolution	Có	Không
Spatial pyramid pooling	Có	Có
Cấu trúc mạng	Dựa trên các kiến trúc DCNNs phổ biến (ResNet, Xception)	Dựa trên ResNet
Ưu điểm	Khả năng nắm bắt chi tiết, hiệu suất cao	Khả năng nắm bắt ngữ cảnh tốt, phù hợp với các đối tượng có kích thước khác nhau
Nhược điểm	Cấu trúc mạng có thể phức tạp	Tính toán có thể tốn kém hơn

Collaborator: Nguyễn Huỳnh Quốc Tuấn

Danh mục tài liệu sử dụng:

- **Tài liệu học phần:** TS. Nguyễn Thị Khánh Tiên, *Chương 4: Phân đoạn ảnh (Image Segmentation)*, Slide Học phần Xử lý ảnh & Thị giác máy tính, Viện Công Nghệ Thông Tin, Điện & Điện Tử, Trường Đại Học Giao Thông Vận Tải Tp.HCM.
- **Tài liệu tham khảo:**
 - Trần Lê Anh (4/2025), *Chapter 4 – Part 2: Segmentation & Blending*, Slide Image Processing and Computer Vision, Viện Công Nghệ Thông Tin, Điện & Điện Tử, Trường Đại Học Giao Thông Vận Tải Tp.HCM.
 - TS. Nguyễn Thị Khánh Tiên, *Chương 3: Training Deep Neural Networks*, Viện Công Nghệ Thông Tin, Điện & Điện Tử, Trường Đại Học Giao Thông Vận Tải Tp.HCM.
 - Các công cụ AI hỗ trợ.